



دانشگاه تهران — پردیس دانشکده‌های فنی
دانشکده علوم همدانی — گروه الگوریتم‌ها و محاسبات

پیش‌بینی قدرت اتصال دارو-هدف با مدل‌های مولد

مقایسه‌ی کنترل‌شده‌ی یادگیری تعاملی و یادگیری روزنه‌ی
Adversarial vs. Variational Representation Learning for Drug-Target Affinity

ارائه‌دهنده: محسن کاظمی کیا
استاد راهنما: دکتر سیمین میرزایی

گزارش به‌عنوان پایان‌نامه کارشناسی ارشد · شهریور ۱۴۰۵

سلام و تشکر از استاد. در یک جمله بگو: «هدف این جلسه این است که مسیر رسیدن از صورت مسئله تا نوآوری پیشنهادی پایان‌نامه را مرور کنیم.» زمان پیشنهادی کل ارائه: ۲۰ تا ۲۵ دقیقه.

فهرست مطالب

1. تعریف مسئله: از DTI تا DTA	آیا برهمکنش هست؟
2. معیارهای کمی قدرت اتصال	
3. درخت تکاملی روش‌ها: از Knowledge تا مدل‌های بنیادی	DTA — چقدر قوی است؟
4. جایگاه پایان‌نامه در این درخت	مسیر پژوهشی تا مدل‌های مولد
5. مقالای اول: DCGAN-DTA — شاخه‌ی GAN	
6. مقالای دوم: Co-VAE — شاخه‌ی VAE	
7. خلا پژوهشی و نوآوری پیشنهادی	نوآوری پیشنهادی

این اسلاید نقشه‌ی راه است. یک جمله بگو: «ارائه از صورت مسئله شروع می‌شود، به دو مقاله‌ی مرجع می‌رسد و با سؤال پژوهشی پایان‌نامه تمام می‌شود.» روی آن معطل نشو.

—تعریف مسئله

—برهم‌کنش دارو-هدف چیست؟



در فرآیند drug discovery، یکی از مسائل پایه شناسایی ارتباط میان دارو و پروتئین هدف است.

DTI

آیا یک دارو می‌تواند با یک پروتئین هدف برهم‌کنش داشته باشد یا خیر؟

خروجی مسئله DTI: Yes / No

DTI را به عنوان مسئله‌ی پایه معرفی کن: «اگر بخواهیم فضای جستجوی drug discovery را کوچک کنیم، اولین سؤال این است که از میان تعداد زیادی دارو و پروتئین، کدام جفت‌ها احتمالاً با هم برهم‌کنش دارند.» مقاله‌ی Co-VAE هم مقدمه‌اش را از همین نقطه شروع می‌کند.

تعریف مسئله

از تشخیص برهم‌کنش به اندازه‌گیری قدرت آن

از تشخیص برهم‌کنش به اندازه‌گیری قدرت آن
چرا پاسخ بلافاصله کافی نیست؟

پرسش فاضل‌نظر

قدرت اتصال دارو به هدف چقدر است؟ ⇒ مسئله‌ی Drug-Target Binding Affinity (DTA)

نکته‌ی کلیدی: دو دارو می‌توانند هر دو با یک target برهم‌کنش داشته باشند، ولی یکی اتصال بسیار قوی و دیگری اتصال ضعیف. DTI این تفاوت را نمی‌بیند. اینجا گذار از مسئله‌ی دسته‌بندی به مسئله‌ی رگرسیون اتفاق می‌افتد.

—تعریف مسئله

—چرا DTA؟

چرا DTA؟
اطلاعات کمی در برابر اطلاعات دودویی

DTA	DTI
برهمکنش چقدر قوی است؟ خروجی پیوسته (continuous) مقدار عددی affinity	آیا برهمکنش وجود دارد؟ خروجی دودویی (binary) بله / خیر
مناسب رتبه‌بندی و اولویت‌دهی	مناسب غربالگری اولیه

دقت در بیان: اگریم «DTA» میانه بهتر از DTI است؛ این‌ها دو صورت‌بندی متفاوت از مسئله‌اند. اگریم برای هدف این پژوهش، اطلاعات کمی affinity ارزشمندتر است.

مصلحتی کنیدی
DTA علاوه بر وجود برهمکنش، شدت آن را نیز مشخص می‌کند و بنابراین اطلاعات غنی‌تری در اختیار می‌گذازد.

حتماً تأکید کن که DTA و DTI دو formulation متفاوت‌اند، نه اینکه یکی مطلقاً بهتر از دیگری باشد. این جمله از نظر علمی قابل دفاع‌تر است و معمولاً همین‌جا سؤال پرسیده می‌شود. Co-VAE هم پیش‌بینی affinity را چالش‌برانگیزتر از تشخیص interaction می‌داند.

تعریف مسئله

— قدرت اتصال چگونه اندازه گیری می شود؟



در اسلایدهای بعد هر معیار جداگانه تعریف می‌شود تا نام مستور راست و چپ نکته‌های اصلی این بخش است.

این اسلاید «نقشه» است. فقط بگو چهار پنج اصطلاح داریم و مهم‌ترین نکته این است که K_d و K_i معیار binding affinity هستند ولی IC_{50} معیار potency عملکردی است. جزئیات را در اسلایدهای بعد باز می‌کنی.

۱- تعریف مسئله

pKd و Kd —

pKd و Kd
Equilibrium Dissociation Constant

تعریف مجهولی

Kd: حلقه‌ای از ligand است که در شرایط تعادل، تقریباً بهیچ target یا در حالت bound قرار نمی‌دهد.

$$K_d = \frac{[O][I]}{[OI]}$$

10: داری آزاد - 10: هدف آزاد - 10: هدف-10: هدف

معادله تئوریتی

$$pK_d = -\log_{10}(K_d/[M])$$

اگر $K_d = 10^{-8}$ باشد $pK_d = 9$

نکته‌ای که معمولاً پرسیده می‌شود: چرا لگاریتم می‌گیریم؟ چون مقادیر K_d در بازه‌ای بسیار وسیع و بسیار کوچک (نانومولار تا میکرومولار) پخش‌اند و مقیاس لگاریتمی هم عددها را قابل‌مدیریت می‌کند و هم برای رگرسیون مناسب‌تر است. جهت را اشتباه نگو: K_d کمتر یعنی affinity بیشتر.

تعریف مسئله

Ki و pKi

تعریف

Ki معیاری برای بیان affinity یک مهارکننده (inhibitor) نسبت به target یا آنزیم است.

هرچه Ki کوچکتر باشد، inhibitor تمایل بیشتری به اتصال مؤثر به target دارد.

$$pK_i = -\log_{10}(K_i[M])$$

$$\uparrow \text{affinity} \implies pK_i \uparrow \implies K_i \downarrow$$

Ki و Kd یکی هستند

Kd مستقیماً equilibrium dissociation را در یک سامانه‌ای اتصال بیان می‌کند.

Ki: در زمینه‌ی inhibition و برای بیان potency/affinity مهارکننده به کار می‌رود.

هر دو در ادبیات ITC به همان ترتیب affinity استفاده می‌شوند. مجموع داده‌های مختلف برحسب‌های متفاوتی دارند.

اگر استاد پرسید تفاوت Ki و Kd چیست، همین اسلاید جواب است. اضافه کن که در عمل، مجموعه داده‌ها فرق دارند: Davis بر پایه‌ی Kd است و KIBA یک امتیاز ترکیبی است؛ بنابراین مقایسه‌ی اعداد بین مجموعه داده‌ها مستقیماً معنادار نیست.

تعریف مسئله


IC50

تعریف

خطی از inhibitor که باعث 50٪ کاهش فعالیت یک سامانه یا آنزیم می‌شود.

نکته‌ی مهم علمی

IC50 مستقیماً معیار binding affinity نیست؛
یک معیار functional inhibition / potency است
(مثلاً غلظت substrate) وابسته است.



نشی پاسخ به غلظت IC50 نقطه‌ی رسیدن به نیمی حداکثر مهار است.

این تمایز را حتماً بگو، چون از نظر علمی مهم است و نشان می‌دهد ادبیات را دقیق خوانده‌ای: K_d و K_i معیار اتصال‌اند، IC_{50} معیار اثر عملکردی. ادبیات مقایسه‌ی ابزارهای DTA هم صراحتاً روی همین تأکید می‌کند.

تعریف مسئله

جمع‌بندی معیارهای اتصال و مهار


جمع‌بندی معیارهای اتصال و مهار
 کدام معیار چه چیزی را می‌سنجد؟

معیار	نمونه	معیار بیشتر بهتر است
Kd	Dissociation constant	affinity بیشتر
pKd	$-\log_{10}(K_d)$	affinity بیشتر
Ki	Inhibition constant	affinity بیشتر
pKi	$-\log_{10}(K_i)$	affinity بیشتر
IC50	غلظت لازم برای 50٪ مهار	potency بیشتر

نکات در عمل
 در بسیاری از benchmark‌های DTA، معیار affinity به شکل **تک‌ارزشی** مانند pKi یا pKi استفاده می‌شود. برای نمونه DCGAN-DTA روی BindingDB معیار را به pKi تبدیل کرده و PDBBind نیز شامل معیار log-transformed از Ki و Kd است.

این اسلاید پل به بخش بعد است. بگو: «پس برچسبی که مدل‌ها پیش‌بینی می‌کنند معمولاً یک عدد پیوسته در مقیاس لگاریتمی است؛ حالا ببینیم پژوهشگران برای پیش‌بینی این عدد چه مسیری را طی کرده‌اند.»

درخت تکاملی روش‌های پیش‌بینی DTA



مهم‌ترین اسلاید بخش دوم؛ حدود دو تا سه دقیقه رویش وقت بگذار. دو پیام اصلی: (۱) این یک زنجیره‌ی خطی نیست، یک درخت است و شاخه‌های پایینی هم‌زمان‌اند نه پشت سر هم؛ (۲) Generative یک شاخه‌ی هم‌رده‌ی Fusion و Pre-trained است، نه مرحله‌ی بعد از GNN. در پایان انگشت بگذار روی دو برگ پررنگ و بگو «پایان‌نامه دقیقاً اینجاست».

مرحله اول: شباهت و Kernel



نویس اصلی این مدل
اگر دو دارو از نظر شیمیایی شبیه باشند، احتمالاً affinity مشابهی دارند؛ پروتئین‌های مشابه نیز الگوی binding مشابهی دارند.

KronRLS
Kroncker Regularized Least Squares — شباهت دارو-دارو و هدف-هدف را ترکیب می‌کند و مسئله را در قالب regularized least squares حل می‌کند.

محدودیت
مدل فقط به اندازه‌ی کیفیت similarity که انسان تعریف کرده خوب بود؛ نمایش هنوز دستی و از پیش تعریف‌شده است.

کوتاه رد شو. پیام: کیفیت مدل عملاً برابر بود با کیفیت تابع شباهتی که انسان تعریف می‌کرد. KronRLS هنوز هم یکی از baseline‌های استاندارد است و DeepDTA مستقیماً با آن مقایسه می‌شود.

مرحله دوم: یادگیری ماشین ویژگی محور

پیام کوتاه: پیشرفت واقعی بود (مدل سازی غیرخطی)، ولی گلوگاه فقط یک قدم عقب تر رفت. این همان چیزی است که یادگیری عمیق در مرحله ی بعد حذفش می کند.



ویژگی های مربوط به جای شباهت سرف

- دارو: descriptors, fingerprints, ویژگی های ساختاری اتمی
- پروتئین: شباهت توالی، ویژگی های فیزیکی-شیمیایی، اطلاعات تکاملی
- جفت دارو-هدف: ویژگی های شبکه ای

SimBoost به جای kernel مانند از Gradient Boosting Machines استفاده کرد و توانست روابط غیرخطی او را مدل کند.


گلوگاه منحل شد

Feature به Similarity Engineering

Engineering — ولی هنوز انسان در حلقه است.


— مسیر پژوهشی

— مرحله‌ی سوم: ورود یادگیری عمیق



DeepDTA نقطه‌ی عطف این حوزه است و تقریباً همه‌ی مقالات بعدی با آن مقایسه می‌شوند. اگر وقت کم بود، فقط همین اسلاید را از کل بخش بگو.

مرحله چهارم: گراف و نمایش ساختار آگاه




چرا گراف؟
 فقط SMILES فقط یک **سوال-سازی** از مولکول است. در حالی که مولکول ذاتاً یک گراف است: اتم → **Node**، پیوند → **Edge**.
 GraphDTA چند معماری را بررسی کرد: GAT - GNN، GIN - GAT-GCN.

نتیجه
 مسئله فقط همینتر کردن شبکه نبود: **نوع نمایش هم** تأثیر کرد. از **sequence representation** به **structure-aware representation**.

اگر پرسیده شد چرا گراف بهتر است: چون اطلاعات ساختاری (حلقه‌ها، شاخه‌ها، همسایگی اتم‌ها) در SMILES به صورت ضمنی و در گراف به صورت صریح کد می‌شود. وارد جزئیات GNN نشو، موضوع پایان‌نامه نیست.


مرحله ی پنجم: توجه و Transformer



این مرحله در نسخه ی قبلی ارائه غایب بود. نکته ی کلیدی: attention یک نوع نمایش جدید نمی‌سازد، بلکه نحوه ی ترکیب نمایش‌های موجود را یاد می‌گیرد.


مرحله‌ی ششم: چندوجهی و مدل‌های پیش‌آموزش‌دیده

این مرحله هم در نسخه‌ی قبلی غایب بود و اضافه کردنش نشان می‌دهد ادبیات را تا ۲۰۲۶ دنبال کرده‌ای. اگر استاد پرسید چرا از این مسیر استفاده نکرده‌ای، بگو موضوع پایان‌نامه شاخه‌ی مولد است و این شاخه‌ی موازی می‌تواند کار آینده باشد.



مرحله هفتم: یادگیری نمایش مولد


اینجا پل اصلی ارائه است. جمله‌ی گذار: «این دو مقاله دو پاسخ متفاوت به یک پرسش واحدند؛ حالا هر کدام را جداگانه می‌بینیم.» حتماً تأکید کن که Generative از نظر تاریخی بعد از GNN نیامده، بلکه یک شاخه‌ی موازی است.



موضوعات ۲۰۲۶	مسیرهای فعلی امروز
- A meta learning and task adaptive approach for DTA — Nature Communications - binding site — DCI-SiteDTA — ورود اطلاعات - Graph Transformer — GraphTransDTA — برای ترکیب داده‌های چندوجهی	- نمایش‌های pre-trained در مقیاس بزرگ - پادگیری multimodal (توالی + گراف + ساختار) - cross-modal interaction به جای الحاق ساده - تعمیم در شرایط cold-start - task adaptation و meta-learning - مدل‌های binding-site-aware

تکلیف چهار: مسیر متوقف نشده. دانشمندی موارد بزرگی از چند مسیر فعلی است و این پایان‌نامه دقیقاً همان دانش را بررسی می‌کند.

این اسلاید نشان می‌دهد که تصویر کاملی از حوزه داری و می‌دانی پایان‌نامه‌ات کجای آن می‌نشیند. اگر استاد پرسید «چرا سراغ foundation models نرفتی؟» بگو منابع محاسباتی و دامنه‌ی پایان‌نامه محدود است و این مسیر را به‌عنوان کار آینده مطرح می‌کنم.



این اسلاید پاسخ آماده به پرسش «چرا این دو مقاله؟» است. جمله‌ای که نباید بگویی: «روش‌های قبلی ضعیف بودند و من مدل بهتری می‌سازم» — چون اثباتش نیازمند آزمایش گسترده است. جمله‌ای که باید بگویی: «این دو، نماینده‌های شاخص دو زیرشاخه‌ی یک پارادایم‌اند و تاکنون زیر یک پروتکل مشترک مقایسه نشده‌اند.»

DCGAN-DTA
نمایش‌دهی شادمانی GAN — Kalemali et al. — BMC Genomics 2022

ابزار
استفاده از Deep Convolutional Generative Adversarial Network برای یادگیری نمایش دارو و پروتئین.

چالش‌های مورد اشاره نویسنده

- داده‌ی آموزشی محدود (limited training data)
- انتخاب و مه‌نسی ویژگی
- نیاز به اعتبارسنجی قوی‌تر
- generalization به داده‌های دیدم‌شده

چرا این مقاله مهم است
استفاده از DCGAN-DTA را برای یک مدل CNN دیگر دیدم‌شده است. این مدل است که ظرفیت یادگیری نمایش‌دهی مولد را دارد. مسئله‌ی DTA می‌کند و از **generating** — از جمله برای داده‌های دیدم‌شده — برای استخراج نمایش بهره می‌گیرد.

Generator → Discriminator
سیکل یادگیری

جمله‌ی کلیدی این اسلاید: «DCGAN-DTA تلاش می‌کند ظرفیت یادگیری نمایش مدل‌های مولد را وارد مسئله‌ی DTA کند و از pretraining برای استخراج نمایش استفاده کند.» حتماً تأکید کن که GAN اینجا برای تولید دارو به کار نمی‌رود، بلکه برای یادگیری نمایش — این تفاوت ظریف ولی مهمی است و معمولاً همین‌جا سؤال می‌شود.



شکل را از پایین به بالا توضیح بده — همان ترتیبی که در ستون کنارش شماره خورده است. دو شاخه‌ی چپ و راست شکل کاملاً متقارن‌اند؛ تنها تفاوت جدی، BLOSUM encoding در شاخه‌ی پروتئین است که اطلاعات تکاملی (شباهت جانشینی اسیدهای آمینه) را وارد مدل می‌کند. اگر وقت کم بود فقط بگو: کدگذاری، پیش‌آموزش تخصصی، CNN، ادغام، رگرسیون.



نمایندگی ساختاری

این VAE همزمان برای دارو و هدف به همراه یک بخش **co-regularization** که اطلاعاتی نهان را به مقدار **affinity** گروه می‌زند.


چرا این مقاله مهم است

این کار نهان اینجا **احتمالی** است، نه یک بردار ثابت و مدل فقط برای **prediction** طراحی شده — دوستان بدانند می‌تواند برای کارهای داروهای جدید با هدف‌های مشابه نیز استفاده کرد.

تفاوت بنیادی با مقاله‌ی قبل: آنجا نمایش با فرایند تخصیصی و در یک مرحله‌ی پیش‌آموزش جدا ساخته می‌شود؛ اینجا فضای نهان احتمالاتی است و بازسازی، هم‌تنظیمی و رگرسیون هم‌زمان آموزش می‌بینند. همین تقابل — Adversarial در برابر Variational — است که مقایسه‌ی این دو را برای پایان‌نامه ارزشمند می‌کند.

مقاله‌ی دوم: Co-VAE

معماری Co-VAE



مسئله بالا به پایین

۱. دو رگرسیون موازی — $3 \times \text{gateconv}$ — $\text{FC} + \text{max-pool}$

۲. فضای نهان — KL و بازسازی موازی

سه سر خروجی از drug / target feature

- Drug decoder — بازسازی SMILES
- Reg block — پیش‌بینی affinity
- Target decoder — بازسازی توالی هدف

همان دو فضای نهان هم‌زمان بازسازی و رگرسیون را تقابله می‌کنند؛ همین اشتراک بخش co-regularization را بازی می‌کند.

تفاوت ساختاری مهم با DCGAN-DTA: آنجا پیش‌آموزش و رگرسیون دو مرحله‌ی جدا بودند، اینجا بازسازی و رگرسیون هم‌زمان و از یک فضای نهان مشترک آموزش می‌بینند. اگر پرسیده شد co-regularization دقیقاً چیست: یک جمله‌ی اضافه در تابع هزینه، علاوه بر دو جمله‌ی بازسازی و دو جمله‌ی KL، که فضاها را نهان دارو و هدف را طوری شکل می‌دهد که از رویشان بتوان affinity را بازیابی کرد.

— مقایسه و خلأ پژوهشی

— مقایسه‌ی دو رویکرد

مقایسه‌ی دو رویکرد

Co-VAE در برابر DCGAN-DTA

Co-VAE	DCGAN-DTA	تفاوت
VAE	GAN	نوع مدل
Variational learning	Adversarial learning	ایده‌ی اصلی
Decoder + Encoder	Discriminator + Generator	ساختار
احتمالات	تجزیه‌ی مولد	فصلی همان
SMILES	SMILES	نمایش داده
Protein sequence	Protein sequence	نمایش هدف
co-regularization + Prediction	Prediction	خروجی
تولید + یادگیری نمایش	یادگیری نمایش	هدف جانشین

جمله‌ی کلیدی

تفاوت اصلی این دو مقاله فقط در architecture نیست؛ آن‌ها دو دیدگاه متفاوت نسبت به یادگیری نمایش دارند.

این جدول را سطر به سطر نخوان. فقط سه سطر اول را بگو و مستقیم برو سراغ جمله‌ی پایین اسلاید، چون همان جمله ورودی بخش نوآوری است.

— مقایسه و خلأ پژوهشی

— خلأ پژوهشی



اینجا محتاط باش و ادعای بزرگ نکن. نگو «هیچ‌کس این کار را نکرده»؛ بگو «تا جایی که بررسی کرده‌ام، مقایسه‌ی کنترل‌شده‌ی این دو خانواده تحت یک پروتکل یکسان کمتر انجام شده است». این جمله قابل دفاع‌تر است.

— نوآوری پیشنهادی

— نوآوری های پیشنهادی

۱. مقایسه ی نو پارادایم مولد: Generational learning در برابر Variational learning و DTA برای مسئله ی adversarial learning.	۲. بررسی generalization: مقایسه در دو شرایط cold-start و warm-start؛ عملکرد روی random split؛ توان پیش بینی برای داده ها و هدف های واقعاً جدید را نشان نمی دهد.
۳. پروتکل آزمایشی یکسان: حجم داده ها، preprocessing، نمایش ها، split، معیارها و کنترل شده — تا تفاوت عملکرد واقعاً به architecture نسبت داده شود.	۴. تحلیل فراتر از دقت: training, generalization, performance, data efficiency, computational cost, stability.

DCGAN-DTA نیز همین مسئله را با warm-start و cold-start فریزکرهای مشابهی مورد توجه قرار داده است.

مهم ترین اسلاید دفاع از نوآوری. اگر استاد گفت «این فقط مقایسه است، نوآوری نیست»، پاسخ آماده داشته باش: نوآوری در طراحی پروتکل کنترل شده و در تحلیل چندبعدی (نه صرفاً عدد دقت) است، و خروجی آن یک راهنمای انتخاب مدل برای این حوزه است.

— نوآوری پیشنهادی

— سؤال اصلی پژوهش

پرسش اصلی


آیا نوع روش یادگیری مولد — **تخصصی** یا **ورودی** — می‌تواند بر کیفیت یادگیری نمایش و عملکرد پیش‌بینی قدرت اشغال در مسئلهی DFA تأثیر معناداری داشته باشد؟

پرسش‌های فرعی

۱. کدام روش در warm-start عملکرد بهتری دارد؟
۲. کدام روش در cold-start بهتر generalise می‌کند؟
۳. حساسیت هر مدل نسبت به حجم داده چقدر است؟
۴. کدام مدل از نظر computational cost مناسب‌تر است؟
۵. آیا برتری مشاهده‌شده ناشی از architecture است یا از preprocessing / split / dataset؟

ارائه باید با همین اسلاید به اوج برسد. پرسش پنجم مهم‌ترین است و نشان می‌دهد به اعتبار درونی آزمایش فکر کرده‌ای؛ روی همان یک مکث کوتاه کن.

—روایت کلی ارائه



این اسلاید جمع‌بندی بصری است. می‌توانی آن را ۱۵ ثانیه‌ای رد کنی یا اگر جلسه طولانی شد مستقیم از اسلاید ۲۲ به اسلاید پرسش‌ها بروی.

Wang et al., *A unified survey on drug-target interaction and binding affinity prediction*, *Biotechnology Advances*, 2026.

Pablikkula et al., *Toward more realistic drug-target interaction predictions (KosarE5)*, *Brief. Bioinform.*, 2015.

He et al., *SimBoost: a read-across approach using gradient boosting machines*, *J. Cheminformatics*, 2017.

Öztürk et al., *DeepDTA: deep drug-target binding affinity prediction*, *Bioinformatics*, 2018.

Öztürk et al., *WideDTA: prediction of drug-target binding affinity*, *arXiv*, 2019.

Nguyen et al., *CnnpMOTA: predicting drug-target binding affinity with graph neural networks*, *Bioinformatics*, 2021.

Li et al., *Co-BME: Drug-Target Binding Affinity Prediction by Co-Regularized Horizontal Autoencoders*, *IEEE TPAMI*, 2022.

Kalemati et al., *DGGAN-DTA: Predicting drug-target binding affinity with deep convolutional GANs*, *BMC Genomics*, 2024.

فهرست کتابی مراجع در متن با پایزنانه ارائه شده است.

این اسلاید فقط برای مستند بودن است؛ روی آن توقف نکن مگر استاد سؤال کند.

با تشکر از توجه شما

پرسش‌ها و پیشنهادها

محسن کاتانی کیا - استاد راهنما: دکتر سایه میرزایی

آماده باش برای این سه سؤال: (۱) چرا همین دو مقاله را انتخاب کردی؟ (۲) داده و منابع محاسباتی را چگونه تأمین می‌کنی؟ (۳) اگر نتیجه این شد که تفاوت معنادار نیست، دستاورد پایان‌نامه چیست؟ برای سؤال سوم پاسخ بده: نتیجه‌ی منفی هم یافته است، چون نشان می‌دهد تفاوت گزارش‌شده در مقالات ناشی از پروتکل بوده نه معماری.