

دانشگاه تهران — پردیس دانشکده‌های فنی
دانشکده علوم مهندسی — گروه الگوریتم‌ها و محاسبات

پیش‌بینی قدرت اتصال دارو-هدف با مدل‌های مولد


مقایسه‌ی کنترل‌شده‌ی یادگیری تخصصی و یادگیری وردشی

Adversarial vs. Variational Representation Learning for Drug-Target Affinity

ارائه‌دهنده: محسن کاشفی کیا

استاد راهنما: دکتر سایه میرزایی

گزارش پیشرفت پایان‌نامه کارشناسی ارشد · شهریور ۱۴۰۵




۱. تعریف مسئله: از DTI تا DTA
۲. معیارهای کمی قدرت اتصال
۳. درخت تکاملی روش‌ها: از KronRLS تا مدل‌های بنیادی
۴. جایگاه پایان‌نامه در این درخت
۵. مقاله‌ی اول: DCGAN-DTA — شاخه‌ی GAN
۶. مقاله‌ی دوم: Co-VAE — شاخه‌ی VAE
۷. خلاصه پژوهشی و نوآوری پیشنهادی

تعريف مسئله

برهم کنش دارو-هدف چیست؟

Drug-Target Interaction (DTI)




در فرآیند drug discovery، یکی از مسائل پایه شناسایی ارتباط میان **دارو** و **پروتئین هدف** است.

پرسش DTI

آیا یک دارو می‌تواند با یک پروتئین هدف برهم‌کنش داشته باشد یا خیر؟

خروجی مسئله **دودویی** است: بله / خیر.

از تشخیص برهم کنش به اندازه گیری قدرت آن چرا پاسخ بله/خیر کافی نیست؟



پرسش دقیق تر

قدرت اتصال دارو به هدف **چقدر** است؟ $\Rightarrow$ مسئله‌ی Drug-Target Binding Affinity (DTA)

DTI	DTA
آیا برهم‌کنش وجود دارد؟	برهم‌کنش چقدر قوی است؟
خروجی دودویی (binary)	خروجی پیوسته (continuous)
بله / خیر	مقدار عددی affinity
مناسب غربالگری اولیه	مناسب رتبه‌بندی و اولویت‌دهی


دقت در بیان: نگوییم «DTA همیشه بهتر از DTI است»؛ این‌ها دو صورت‌بندی متفاوت از مسئله‌اند. بگوییم برای هدف/این پژوهش، اطلاعات کمی affinity ارزشمندتر است.

جمله‌ی کلیدی

DTA علاوه بر **وجود** برهم‌کنش، **شدت** آن را نیز مشخص می‌کند و بنابراین اطلاعات غنی‌تری در اختیار می‌گذارد.

قدرت اتصال چگونه اندازه گیری می شود؟

نقشه ی معیارهای متداول



در اسلایدهای بعد هر معیار جداگانه تعریف می شود؛ تمایز ستون راست و چپ نکته ی اصلی این بخش است.

اتصال ضعیف

اتصال قوی

Kd بزرگ

Kd کوچک

Drug B
Kd = 100 nM

Drug A
Kd = 1 nM

$$pK_d \uparrow \Rightarrow \uparrow \text{affinity} \Rightarrow K_d \downarrow$$

تعریف مفهومی

Kd غلظتی از ligand است که در شرایط تعادل، تقریباً **نیمی** از targetها را در حالت bound قرار می دهد.

$$K_d = \frac{[D][T]}{[DT]}$$

D: داروی آزاد · T: هدف آزاد · DT: کمپلکس دارو-هدف

مقیاس لگاریتمی

$$pK_d = -\log_{10}(K_d [M])$$

اگر $K_d = 10^{-9} M$ آنگاه $pK_d = 9$

Ki و Kd یکی نیستند

◀ **Kd**: مستقیماً equilibrium dissociation را در یک سامانه‌ی اتصال بیان می‌کند.

◀ **Ki**: در زمینه‌ی inhibition و برای بیان potency/affinity مهارکننده به کار می‌رود.

هر دو در ادبیات DTA به عنوان برچسب affinity استفاده می‌شوند؛ مجموعه‌داده‌های مختلف برچسب‌های متفاوتی دارند.


تعریف

Ki معیاری برای بیان affinity یک **مهارکننده** (inhibitor) نسبت به target یا آنزیم است.

هرچه Ki کوچک‌تر باشد، inhibitor تمایل بیشتری به اتصال مؤثر به target دارد.

$$pK_i = -\log_{10}(K_i [M])$$

$$\uparrow \text{affinity} \implies pK_i \uparrow \implies K_i \downarrow$$



منحنی پاسخ به غلظت؛ IC50 نقطه‌ی رسیدن به نیمه‌ی حداکثر مهار است.

تعریف

غلظتی از inhibitor که باعث ۵۰٪ کاهش فعالیت یک سامانه یا آنزیم می‌شود.

نکته‌ی مهم علمی

IC50 مستقیماً معیار **binding affinity** نیست؛
یک معیار functional inhibition / potency است
و به شرایط آزمایش (مثلاً غلظت substrate)
وابسته است.


جمع‌بندی معیارهای اتصال و مهار کدام معیار چه چیزی را می‌سنجد؟

مقدار کمتر یعنی	مفهوم	معیار
affinity بیشتر	Dissociation constant	Kd
affinity بیشتر	$-\log_{10}(K_d)$	pKd
affinity بیشتر	Inhibition constant	Ki
affinity بیشتر	$-\log_{10}(K_i)$	pKi
potency بیشتر	غلظت لازم برای ۵۰٪ مهار	IC50


کاربرد در عمل

در بسیاری از benchmark‌های DTA، مقادیر affinity به شکل **لگاریتمی** مانند pKd یا pKi استفاده می‌شوند. برای نمونه DCGAN-DTA روی BindingDB مقادیر را به pKd تبدیل کرده و PDBBind نیز شامل مقادیر log-transformed از Ki و Kd است.

مسیر پژوهشی



هر شاخه پاسخی به یک محدودیت متفاوت است — نه جانشین کامل نسل قبلی. دو برگ پررنگ، نقطه‌ی ورود این پایان‌نامه‌اند.



محدودیت


مدل فقط به اندازه‌ی کیفیت similarity ای که **انسان** تعریف کرده خوب بود؛ نمایش هنوز دستی و از پیش تعریف شده است.

فرض اصلی این نسل

اگر دو دارو از نظر شیمیایی شبیه باشند، احتمالاً affinity مشابهی دارند؛ پروتئین‌های مشابه نیز الگوی binding مشابهی دارند.

KronRLS

دارو-دارو و هدف-هدف را ترکیب می‌کند و مسئله را در قالب regularized least squares حل می‌کند. — شباهت Kronecker Regularized Least Squares




گلوگاه جابه‌جا شد

از Similarity Engineering به Feature Engineering — ولی هنوز انسان در حلقه است.

ویژگی‌های صریح به جای شباهت صرف

- دارو: descriptors، fingerprints، ویژگی‌های ساختاری دوبعدی
- پروتئین: شباهت توالی، ویژگی‌های فیزیکوشیمیایی، اطلاعات تکاملی
- جفت دارو-هدف: ویژگی‌های شبکه‌ای

SimBoost به جای kernel ساده از Gradient Boosting Machines استفاده کرد و توانست روابط **غیرخطی‌تر** را مدل کند.



WideDTA — گام بعدی

افزودن protein domains/motifs و maximum common substructure برای نمایشی غنی‌تر.

تغییر بنیادی

نمایش دیگر به‌طور کامل توسط انسان تعریف نمی‌شود؛ شبکه آن را از داده‌ی خام یاد می‌گیرد.


چرا گراف؟


SMILES فقط یک **سریال‌سازی** از مولکول است، در حالی که مولکول ذاتاً یک گراف است: اتم → Node، پیوند → Edge.

GraphDTA چند معماری را بررسی کرد: GAT · GCN · GIN · GAT-GCN.

نتیجه

مسئله فقط عمیق‌تر کردن شبکه نبود؛ **نوع نمایش** هم تغییر کرد: از sequence representation به structure-aware representation.





CNN برای الگوهای local مناسب است؛ attention می تواند وابستگی های دوربرد و میان وجهی را مدل کند.

تمرکز از «چه ویژگی ای استخراج کنیم؟» به «چگونه ویژگی ها را با هم تعامل دهیم؟» منتقل شد.

پرسش تازه


حتی با نمایش خوب، هنوز باید مشخص شود کدام بخش از دارو و کدام بخش از پروتئین برای binding مهم تر است.

FusionDTA

تمرکز بر feature aggregation با attention-based و knowledge distillation و feature polymerization.

مرحله‌ی ششم: چندوجهی و مدل‌های پیش‌آموزش‌دیده

Protein/Chemical Language Models و Multi-modal fusion



ChemBERT · ProtBERT · ESM — در مرور ۲۰۲۶، مدل‌های پیش‌آموزش‌دیده یک **پارادایم مستقل** شمرده می‌شوند.


یک نمایش کافی نیست

- دارو: SMILES، گراف مولکولی، descriptors
- پروتئین: توالی، ساختار، binding site، اطلاعات تکاملی

نمونه‌ها: PocketDTA · MDF-DTA · DeepFusionDTA · GraphTransDTA ·

مرحله هفتم: یادگیری نمایش مولد

شاخه‌ای هم‌رده با Fusion و Pre-trained — نه مرحله‌ی بعد از GNN



پرسش این شاخه

تا اینجا مدل‌ها یک نمایش می‌گیرند و affinity را پیش‌بینی می‌کنند. پرسش تازه: آیا می‌توان از مدل‌های مولد برای یادگیری نمایش بهتر استفاده کرد؟

چرا این شاخه مهم است

- ◀ بهره‌گیری از داده‌ی بدون برچسب
- ◀ فضای نهان ساختارمند و پیوسته
- ◀ امکان pretraining پیش از رگرسیون

نمونه‌های ۲۰۲۶

A meta learning and task adaptive approach for DTA — Nature Communications


binding site — DCI-SiteDTA

Graph Transformer — GraphTransDTA
برای ترکیب داده‌های چندوجهی

نکته‌ی مهم: **مسیر متوقف نشده**. شاخه‌ی مولد یکی از چند مسیر فعال است و این پایان‌نامه دقیقاً همان شاخه را بررسی می‌کند.

مسیرهای فعال امروز

- ◀ نمایش‌های pre-trained در مقیاس بزرگ
- ◀ یادگیری multimodal (توالی + گراف + ساختار)
- ◀ cross-modal interaction به جای الحاق ساده
- ◀ تعمیم در شرایط cold-start
- ◀ task adaptation و meta-learning
- ◀ مدل‌های binding-site-aware



صورتبندی قابل دفاع

این پژوهش ادعا نمی‌کند روش‌های پیشین ضعیف بوده‌اند؛ بلکه بر **شاخه‌ی یادگیری نمایش مولد** در تکامل روش‌های DTA تمرکز می‌کند و دو نماینده‌ی اصلی آن را زیر یک پروتکل مشترک مقایسه می‌کند.

مقاله‌ی اول: DCGAN-DTA

ایده


استفاده از **Deep Convolutional Generative Adversarial Network** برای **یادگیری نمایش** دارو و پروتئین.

چرا این مقاله مهم است

DCGAN-DTA را نباید «یک مدل CNN دیگر» دید. اهمیت آن در این است که ظرفیت **یادگیری نمایش** مدل‌های مولد را وارد مسئله‌ی DTA می‌کند و از **pretraining** — از جمله روی داده‌ی بدون برچسب — برای استخراج نمایش بهره می‌گیرد.

چالش‌های مورد اشاره‌ی نویسندگان

- ◀ داده‌ی آموزشی محدود (limited training data)
- ◀ انتخاب و مهندسی ویژگی
- ◀ نیاز به اعتبارسنجی قوی‌تر
- ◀ generalization به داده‌های دیده‌نشده




پنج مرحله — شکل از پایین به بالا خوانده می‌شود

۱. کدگذاری و تعبیه — Embedding + BLOSUM / Label
۲. پیش‌آموزش DCGAN — Discriminator + Generator
۳. بلوک‌های CNN — استخراج ویژگی
۴. لایه‌ی ادغام دو شاخه — Add
۵. شبکه‌ی پیش‌بینی — FC 1024 → 512

نکته‌ی کلیدی

GAN اینجا برای تولید دارو نیست؛ Discriminator و Generator فقط برای پیش‌آموزش نمایش به کار می‌روند و نمایش آموخته‌شده به سر رگرسیون داده می‌شود.




مقاله‌ی دوم: Co-VAE

ایده‌ی اصلی

دو VAE مجزا برای دارو و هدف، به همراه یک بخش **co-regularization** که فضاها را به هم مرتبط می‌کند. هدف affinity می‌زند.

چرا این مقاله مهم است

فضای نهان اینجا **احتمالاتی** است، نه یک بردار ثابت؛ و مدل فقط برای prediction طراحی نشده — نویسندگان نشان می‌دهند می‌توان از آن برای **تولید داروهای جدید با هدف‌های مشابه** نیز استفاده کرد.




مسیر بالا به پایین

۱. دو رمزگذار موازی — $\text{FC} + \text{max-pool} + 3 \times \text{gatedconv}$
۲. فضای نهان — μ, σ, ϵ و بازپارامتری سازی

سه سر خروجی از drug feature / target feature

- ◀ Drug decoder — بازسازی SMILES
- ◀ Reg block — پیش‌بینی affinity
- ◀ Target decoder — بازسازی توالی هدف

همان دو فضای نهان هم‌زمان **بازسازی** و **رگرسیون** را تغذیه می‌کنند؛ همین اشتراک نقش co-regularization را بازی می‌کند.




مقایسه و خلا پژوهشی

ویژگی	DCGAN-DTA	Co-VAE
نوع مدل	GAN	VAE
ایده‌ی اصلی	Adversarial learning	Variational learning
اجزا	Discriminator + Generator	Decoder + Encoder
فضای نهان	تخصصی / مولد	احتمالاتی
نمایش دارو	SMILES	SMILES
نمایش هدف	Protein sequence	Protein sequence
خروجی	Prediction	co-regularization + Prediction
هدف جانبی	یادگیری نمایش	تولید + یادگیری نمایش

جمله‌ی کلیدی

تفاوت اصلی این دو مقاله فقط در architecture نیست؛ آن‌ها **دو دیدگاه متفاوت** نسبت به یادگیری نمایش دارند.



DCGAN-DTA

تمرکز بر یادگیری نمایش مبتنی بر GAN برای DTA.

Co-VAE

تمرکز بر نمایش وردشی به همراه co-regularization برای DTA.

خلا

مقایسه‌ی **مستقیم و کنترل شده**ی این دو پارادایم تحت یک experimental protocol مشترک، مسئله‌ای است که در این پایان‌نامه بررسی می‌شود.

نوآوری پیشنهادی

۱. مقایسه‌ی دو پارادایم مولد

Adversarial learning در برابر Variational learning
برای مسئله‌ی DTA.

۲. پروتکل آزمایشی یکسان

مجموعه‌داده، preprocessing، نمایش‌ها، split،
معیارها و seedهای کنترل‌شده — تا تفاوت عملکرد
واقعاً به architecture نسبت داده شود.

۳. بررسی generalization

مقایسه در دو شرایط warm-start و cold-start؛
عملکرد روی random split لزوماً توان پیش‌بینی برای
داروها و هدف‌های واقعاً جدید را نشان نمی‌دهد.

۴. تحلیل فزاینده از دقت

علاوه بر performance: generalization، training،
stability، computational cost و data efficiency.


DCGAN-DTA نیز همین مسئله را با warm-start و cold-start فیزیکی‌شیمیایی مورد توجه قرار داده است.

پرسش اصلی

آیا نوع روش یادگیری مولد — **تخاصمی** یا **وردشی** — می‌تواند بر کیفیت یادگیری نمایش و عملکرد پیش‌بینی قدرت اتصال در مسئله‌ی DTA تأثیر معناداری داشته باشد؟

پرسش‌های فرعی

۱. کدام روش در warm-start عملکرد بهتری دارد؟
۲. کدام روش در cold-start بهتر generalize می‌کند؟
۳. حساسیت هر مدل نسبت به حجم داده چقدر است؟
۴. کدام مدل از نظر computational cost مناسب‌تر است؟
۵. آیا برتری مشاهده‌شده ناشی از architecture است یا از preprocessing / split / dataset؟



۱. Wang et al., *A unified survey on drug–target interaction and binding affinity prediction*, Biotechnology Advances, 2026.
۲. Pahikkala et al., *Toward more realistic drug–target interaction predictions (KronRLS)*, Brief. Bioinform., 2015.
۳. He et al., *SimBoost: a read-across approach using gradient boosting machines*, J. Cheminformatics, 2017.
۴. Öztürk et al., *DeepDTA: deep drug–target binding affinity prediction*, Bioinformatics, 2018.
۵. Öztürk et al., *WideDTA: prediction of drug–target binding affinity*, arXiv, 2019.
۶. Nguyen et al., *GraphDTA: predicting drug–target binding affinity with graph neural networks*, Bioinformatics, 2021.
۷. Li et al., *Co-VAE: Drug–Target Binding Affinity Prediction by Co-Regularized Variational Autoencoders*, IEEE TPAMI, 2022.
۸. Kalematis et al., *DCGAN-DTA: Predicting drug–target binding affinity with deep convolutional GANs*, BMC Genomics, 2024.

با تشکر از توجه شما

پرسش‌ها و پیشنهادات

محسن کاشفی کیا . استاد راهنما: دکتر سایه میرزایی