



دانشکده فنی



دانشگاه تهران

دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده علوم مهندسی
گروه الگوریتم‌ها و محاسبات

مطالعه مقایسه‌ای خودرمزگذارهای تقابلی و خودرمزگذارهای متغیر در پیش‌بینی فعل و انفعالات
دارو-دارو و دارو-پروتئین

پایان‌نامه یا رساله برای دریافت درجه کارشناسی ارشد
در رشته مهندسی کامپیوتر - گرایش الگوریتم‌ها و محاسبات

محسن کاشفی کیا

استاد راهنما:

دکتر سایه میرزایی

شهریور ماه ۱۴۰۵

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ



دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده مهندسی

گواهی دفاع از پایان‌نامه کارشناسی ارشد

هیأت داوران پایان‌نامه کارشناسی ارشد آقای / خانم به شماره
دانشجویی در رشته گرایش را در تاریخ
عنوان
.....

به عدد	به حروف
با نمره نهایی	
و درجه	ارزیابی کرد.

ردیف	مشخصات هیأت داوران	نام و نام خانوادگی	مرتبه دانشگاهی	دانشگاه یا مؤسسه	اعضاء
۱	استاد راهنما استاد راهنمای دوم (حسب مورد)				
۲	استاد مشاور				
۳	استاد داور داخلی				
۴	استاد مدعو				
۵	نماینده کمیته تحصیلات تکمیلی دانشکده / گروه				

نام و نام خانوادگی معاون آموزشی و تحصیلات تکمیلی
پردیس دانشکده‌های فنی:
تاریخ و امضاء:

نام و نام خانوادگی معاون تحصیلات تکمیلی و
پژوهشی دانشکده / گروه:
تاریخ و امضاء:

تعهدنامه اصالت اثر

باسمه تعالی

اینجانب **محسن کاشفی کیا** تأیید می‌کنم که مطالب مندرج در این پایان‌نامه حاصل کار پژوهشی اینجانب است و به دستاوردهای پژوهشی دیگران که در این نوشته از آنها استفاده شده است مطابق مقررات ارجاع گردیده است. این پایان‌نامه قبلاً برای احراز هیچ مدرک هم سطح یا بالاتر ارائه نشده است. کلیه حقوق مادی و معنوی این اثر متعلق به دانشکده فنی دانشگاه تهران می‌باشد.

تقديم به يار مهربانم

تشکر و قدردانی

– با تشکر و سپاس از استاد دانشمند و پر مایه ام جناب سرکار خانم سایه میرزایی که از محضر

پر فیض تدریستان ، بهره ها برده ام.

– با امتنان بیکران از مساعدت های بی شائبه ی جناب سرکار خانم نگین باقرپور ریاست

محترم دانشکده

چکیده

پیش‌بینی میل اتصال دارو به هدف (Drug-Target Affinity Binding Prediction) یکی از مسائل مهم در کشف و توسعه محاسباتی دارو است که هدف آن تخمین کمی قدرت اتصال میان یک ترکیب دارویی و پروتئین هدف است. هزینه و زمان بالای روش‌های آزمایشگاهی و گستردگی فضای ترکیبات و اهداف زیستی، استفاده از روش‌های یادگیری ماشین و یادگیری عمیق را به‌عنوان رویکردی مکمل برای این مسئله ضروری ساخته است.

در این پژوهش، روش‌های یادگیری عمیق برای پیش‌بینی میل اتصال دارو-هدف با تمرکز بر مدل‌های مولد و یادگیری بازنمایی بررسی می‌شوند. در این راستا، نحوه بازنمایی داروها و پروتئین‌ها، معماری مدل‌ها، فرایند آموزش و روش‌های ارزیابی مورد مطالعه قرار گرفته و دو رویکرد مبتنی بر شبکه‌های مولد تخصصی و خودرمزگذارهای واریاسیونی، به‌ترتیب در قالب مدل‌های DCGAN-DTA و Co-VAE مورد تحلیل و مقایسه قرار می‌گیرند.

یکی از اهداف اصلی پژوهش، بررسی دقیق بازتولیدپذیری و مقایسه منصفانه این روش‌ها است. به این منظور، مراحل پیش‌پردازش داده، تقسیم مجموعه داده، معماری شبکه، پارامترهای آموزش و معیارهای ارزیابی به‌صورت نظام‌مند بررسی و مستندسازی می‌شوند. همچنین عملکرد مدل‌ها بر روی مجموعه داده‌های رایج در پیش‌بینی میل اتصال، از جمله Davis و KIBA، ارزیابی و مقایسه خواهد شد. در نهایت، نقاط قوت و محدودیت‌های روش‌های مورد بررسی از نظر کیفیت بازنمایی، عملکرد پیش‌بینی، پیچیدگی آموزش و بازتولیدپذیری تحلیل شده و مبنایی برای توسعه روش‌های مؤثرتر در پیش‌بینی میل اتصال دارو-هدف ارائه می‌شود.

کلمات کلیدی : پیش‌بینی میل اتصال دارو-هدف، یادگیری عمیق، یادگیری مولد، شبکه مولد تخصصی، خودرمزگذار واریاسیونی

فهرست مطالب

۱۷	۱ کلیات پژوهش
۱۷	۱-۱ مقدمه
۱۸	۲-۱ بیان مسئله
۲۰	۳-۱ پیش‌بینی میل اتصال دارو-هدف
۲۱	۴-۱ تفاوت برهم‌کنش دارو-هدف و پیش‌بینی میل اتصال
۲۱	۵-۱ اهمیت پیش‌بینی میل اتصال دارو-هدف
۲۲	۶-۱ چالش‌های محاسباتی پیش‌بینی میل اتصال
۲۲	۱-۶-۱ پیچیدگی ساختار دارو
۲۲	۲-۶-۱ پیچیدگی توالی پروتئین
۲۲	۳-۶-۱ محدودیت داده‌های برچسب‌دار
۲۳	۴-۶-۱ نحوه تقسیم داده‌ها
۲۳	۷-۱ یادگیری عمیق در پیش‌بینی میل اتصال
۲۴	۸-۱ مدل‌های مولد
۲۴	۹-۱ شبکه‌های مولد تخصصی
۲۵	۱۰-۱ شبکه‌های مولد تخصصی عمیق کانولوشنی
۲۵	۱۱-۱ خودرمزگذارهای تغییرپذیر
۲۶	۱۲-۱ مدل Co-VAE
۲۷	۱۳-۱ مسئله مقایسه GAN و VAE در DTA
۲۸	۱۴-۱ ضرورت انجام پژوهش
۲۸	۱۵-۱ اهداف پژوهش

۲۸	۱- ۱۵- اهداف اصلی
۲۸	۱- ۱۵- ۲ اهداف فرعی
۲۹	۱- ۱۶- پرسش های پژوهش
۳۰	۱- ۱۷- فرضیه های پژوهش
۳۰	۱- ۱۸- نوآوری و سهم پژوهش
۳۱	۱- ۱۹- محدوده پژوهش
۳۱	۱- ۲۰- ساختار پایان نامه
۳۳	۲ مبانی نظری و پیشینه پژوهش
۳۳	۲- ۱ مقدمه
۳۴	۲- ۲ مفاهیم پایه در پیش بینی میل اتصال دارو-هدف
۳۴	۲- ۲- ۱ دارو و لیگاند
۳۴	۲- ۲- ۲ پروتئین هدف
۳۴	۲- ۳ برهم کنش دارو-هدف
۳۵	۲- ۴ میل اتصال
۳۶	۲- ۵ فرمول بندی ریاضی مسئله DTA
۳۶	۲- ۶ نمایش دارو
۳۷	۲- ۶- ۱ نمایش SMILES
۳۷	۲- ۶- ۲ نمایش مبتنی بر ویژگی های مولکولی
۳۸	۲- ۷ نمایش گرافی دارو
۳۹	۲- ۸ نمایش پروتئین
۳۹	۲- ۸- ۱ توالی اسیدهای آمینه
۳۹	۲- ۸- ۲ ویژگی های تکاملی پروتئین
۳۹	۲- ۸- ۳ ساختار سه بعدی پروتئین
۴۰	۲- ۹ روش های سنتی پیش بینی میل اتصال
۴۰	۲- ۱۰ یادگیری عمیق در DTA

۴۰		۱۱-۲ مدل DeepDTA
۴۱		۱۲-۲ مدل GraphDTA
۴۲		۱۳-۲ مدل‌های مولد
۴۲		۱۴-۲ شبکه‌های مولد تخصصی
۴۳		۱۵-۲ فرایند آموزش GAN
۴۳		۱۶-۲ شبکه مولد تخصصی کانولوشنی عمیق
۴۴		۱۷-۲ خودرمزگذار
۴۴		۱۸-۲ خودرمزگذار تغییرپذیر
۴۵		۱۹-۲ ترفند بازپارامتری‌سازی
۴۵		۲۰-۲ تابع هدف VAE
۴۶		۲۱-۲ مقایسه مفهومی GAN و VAE
۴۶		۲۲-۲ مدل Co-VAE
۴۷		۲۳-۲ ایده هم‌منظم‌سازی
۴۷		۲۴-۲ کاربرد Co-VAE در DTA
۴۸		۲۵-۲ مدل DCGAN-DTA
۴۸		۲۶-۲ مرحله کدگذاری و تعبیه‌سازی در DCGAN-DTA
۴۸		۲۷-۲ استخراج ویژگی در DCGAN-DTA
۴۹		۲۸-۲ ادغام نمایش‌های نهفته
۴۹		۲۹-۲ بخش پیش‌بینی DCGAN-DTA
۵۰		۳۰-۲ داده‌های مورد استفاده در مطالعات DTA
۵۰		۳۱-۲ مجموعه داده Davis
۵۱		۳۲-۲ مجموعه داده KIBA
۵۱		۳۳-۲ مجموعه داده BindingDB
۵۱		۳۴-۲ مجموعه داده PDBbind
۵۲		۳۵-۲ روش‌های تقسیم داده
۵۲		۳۶-۲ معیارهای ارزیابی

۵۳	 ۲- ۳۶- میانگین مربعات خطا
۵۳	 ۲- ۳۶- شاخص سازگاری
۵۳	 ۲- ۳۶- مساحت زیر منحنی دقت-فراخوانی
۵۴	 ۲- ۳۷- مقایسه کلی مدل‌های مورد بررسی
۵۴	 ۲- ۳۸- مقایسه Co-VAE و DCGAN-DTA
۵۴	 ۲- ۳۹- جایگاه پژوهش حاضر
۵۶	 ۲- ۴۰- جمع‌بندی فصل

فصل ۱

کلیات پژوهش

۱-۱ مقدمه

فرآیند کشف و توسعه دارو یکی از پیچیده‌ترین و پرهزینه‌ترین فرایندهای حوزه علوم پزشکی و داروسازی است. یکی از مراحل مهم در این فرایند، شناسایی و بررسی برهم‌کنش میان ترکیبات دارویی و پروتئین‌های هدف است. یک دارو معمولاً از طریق اتصال به یک یا چند پروتئین هدف در بدن اثر خود را ایجاد می‌کند و ویژگی‌های این اتصال می‌تواند اطلاعات مهمی درباره اثربخشی، انتخاب‌پذیری و عملکرد احتمالی دارو ارائه دهد.

در مطالعات محاسباتی، مسئله شناسایی برهم‌کنش دارو و هدف پروتئینی با عنوان برهم‌کنش دارو-هدف^۱ یا DTI شناخته می‌شود. در ساده‌ترین حالت، هدف این مسئله تعیین وجود یا عدم وجود برهم‌کنش میان یک دارو و یک هدف پروتئینی است. با این حال، وجود یک رابطه میان دارو و پروتئین به تنهایی اطلاعات کاملی درباره شدت این برهم‌کنش ارائه نمی‌کند. شدت اتصال میان دارو و هدف را می‌توان با مفهومی تحت عنوان **میل اتصال**^۲ توصیف کرد [۸].

پیش‌بینی میل اتصال دارو-هدف^۳ که به اختصار DTA نامیده می‌شود، مسئله‌ای متفاوت از تشخیص صرف وجود یک برهم‌کنش است. در این مسئله، هدف یک مدل یادگیری ماشین یا یادگیری عمیق آن است که با دریافت اطلاعات مربوط به دارو و پروتئین هدف، مقدار پیوسته‌ای را به عنوان میزان میل اتصال پیش‌بینی کند. چنین رویکردی می‌تواند اطلاعات دقیق‌تری نسبت به یک طبقه‌بندی دودویی در اختیار پژوهشگر قرار دهد [۸].

با افزایش حجم داده‌های زیستی و توسعه پایگاه‌های داده‌ای حاوی اطلاعات مربوط به برهم‌کنش دارو-پروتئین، استفاده از روش‌های یادگیری ماشین و به‌ویژه یادگیری عمیق برای حل این مسئله مورد توجه قرار گرفته است.

^۱Drug-Target Interaction (DTI)

^۲Binding Affinity

^۳Drug-Target Binding Affinity Prediction (DTA)

مدلهایی مانند DeepDTA نشان دادند که می‌توان بدون استفاده مستقیم از ساختار سه‌بعدی کمپلکس دارو-پروتئین، از نمایش‌هایی مانند SMILES برای دارو و توالی اسیدهای آمینه برای پروتئین استفاده کرده و یک مدل عمیق برای پیش‌بینی میل اتصال آموزش داد [۸].

در سال‌های اخیر، علاوه بر مدل‌های متداول یادگیری عمیق، مدل‌های مولد نیز وارد حوزه پیش‌بینی و مدل‌سازی داده‌های زیستی شده‌اند. دو خانواده مهم در این زمینه شبکه‌های مولد تخصصی^۴ و خودرمزگذارهای تغییرپذیر^۵ هستند. این دو خانواده از نظر نحوه یادگیری نمایش داده، ساختار مدل و فرایند آموزش تفاوت‌های بنیادی دارند. GAN‌ها از یک فرآیند رقابتی میان مولد و تشخیص‌دهنده استفاده می‌کنند، در حالی که VAE‌ها بر پایه یک مدل احتمالی و فضای نهفته متغیر بنا شده‌اند [۱، ۳].

این تفاوت بنیادی، مقایسه این دو رویکرد را در مسئله پیش‌بینی میل اتصال دارو-هدف به موضوعی قابل بررسی تبدیل می‌کند. در این پژوهش، دو مدل مبتنی بر این دو خانواده، یعنی DCGAN-DTA به عنوان رویکرد مبتنی بر GAN و Co-VAE به عنوان رویکرد مبتنی بر VAE، مورد بررسی و مقایسه قرار می‌گیرند [۲، ۴].

۱-۲ بیان مسئله

برهم‌کنش میان دارو و پروتئین‌های هدف یکی از مفاهیم اساسی در کشف دارو و طراحی داروهای جدید است. شناسایی ترکیباتی که بتوانند به یک پروتئین خاص متصل شوند، می‌تواند در مراحل مختلف توسعه دارو مورد استفاده قرار گیرد. با این حال، بررسی تجربی تمام ترکیبات دارویی احتمالی در برابر تعداد زیادی از پروتئین‌های موجود، از نظر زمانی و محاسباتی و آزمایشگاهی بسیار پرهزینه است.

به همین دلیل، روش‌های محاسباتی برای محدود کردن فضای جست‌وجو و اولویت‌بندی ترکیبات مناسب توسعه یافته‌اند. یکی از این رویکردها، پیش‌بینی برهم‌کنش دارو-هدف است. روش‌های اولیه در این حوزه عمدتاً مسئله را به صورت طبقه‌بندی دودویی تعریف می‌کردند؛ یعنی مدل باید تعیین کند که آیا یک دارو با یک هدف خاص برهم‌کنش دارد یا خیر. این نوع مدل‌سازی، اگرچه اطلاعات مفیدی ارائه می‌دهد، اما شدت برهم‌کنش را در نظر نمی‌گیرد [۸].

در مقابل، میل اتصال یک کمیت پیوسته است که می‌تواند میزان قدرت اتصال میان یک لیگاند و پروتئین هدف را توصیف کند. این مقدار می‌تواند با کمیت‌هایی مانند K_i ، K_d و IC_{50} بیان شود که هرکدام در شرایط

^۴Generative Adversarial Networks (GANs)

^۵Variational Autoencoders (VAEs)

آزمایشگاهی مشخصی برای توصیف ویژگی‌های اتصال مورد استفاده قرار می‌گیرند [۸].

بنابراین، مسئله اصلی در DTA را می‌توان به صورت یک مسئله رگرسیون تعریف کرد. در این مسئله، برای یک جفت دارو و پروتئین (d, t) که به ترتیب دارو و هدف پروتئینی را نشان می‌دهند، مدل باید مقدار پیوسته‌ای مانند y را پیش‌بینی کند:

$$f(d, t) \rightarrow y \quad (1-1)$$

که در آن y نشان‌دهنده مقدار میل اتصال متناظر با زوج دارو-هدف است.

یکی از چالش‌های اصلی این مسئله، نحوه نمایش دارو و پروتئین برای ورود به مدل یادگیری ماشین است. یک دارو را می‌توان با نمایش‌هایی مانند SMILES، ساختار مولکولی یا گراف مولکولی نمایش داد. از طرف دیگر، پروتئین را می‌توان بر اساس توالی اسیدهای آمینه یا ساختار سه‌بعدی آن نمایش داد. انتخاب نمایش مناسب می‌تواند بر توانایی مدل در استخراج الگوهای مرتبط با میل اتصال تأثیر بگذارد [۷، ۸].

DeepDTA یکی از مدل‌های مهم در این حوزه است که با استفاده از نمایش SMILES برای دارو و توالی پروتئین، ویژگی‌های مربوط به هر دو ورودی را با شبکه‌های عصبی کانولوشنی استخراج می‌کند و سپس مقدار میل اتصال را پیش‌بینی می‌کند [۸]. پس از آن، معماری‌های دیگری مانند GraphDTA تلاش کردند ساختار مولکولی دارو را به صورت یک گراف مدل‌سازی کنند تا روابط میان اتم‌ها و پیوندهای شیمیایی مستقیماً در مدل لحاظ شوند [۷].

با وجود پیشرفت‌های حاصل‌شده، استفاده از روش‌های یادگیری عمیق همچنان با چالش‌هایی مانند محدودیت داده‌های برچسب‌دار، پیچیدگی روابط دارو-پروتئین و دشواری یادگیری نمایش‌های مناسب مواجه است. در همین راستا، مدل‌های مولد می‌توانند به عنوان یک مسیر متفاوت برای یادگیری نمایش داده‌ها مورد استفاده قرار گیرند. DCGAN-DTA با استفاده از شبکه‌های مولد تخصصی عمیق کانولوشنی، تلاش می‌کند نمایش‌های مربوط به توالی‌های پروتئینی و SMILES دارو را یاد بگیرد و از این نمایش‌ها در پیش‌بینی میل اتصال استفاده کند [۲]. از سوی دیگر، Co-VAE یک معماری مبتنی بر خودرمزگذار تغییرپذیر است که دو VAE را برای مدل‌سازی دارو و هدف پروتئینی به کار می‌گیرد و از یک بخش هم‌منظم‌سازی^۶ برای مدل‌سازی ارتباط میان این دو و پیش‌بینی میل اتصال استفاده می‌کند [۴].

بنابراین، مسئله اصلی این پژوهش عبارت است از:

^۶Co-regularization

با توجه به تفاوت بنیادین میان رویکردهای GAN و VAE، عملکرد این دو خانواده مدل در مسئله پیش‌بینی میل اتصال دارو-هدف چگونه است و هر یک تحت شرایط ارزیابی مختلف چه ویژگی‌ها، مزایا و محدودیت‌هایی دارند؟

۱-۳ پیش‌بینی میل اتصال دارو-هدف

پیش‌بینی میل اتصال دارو-هدف یکی از مسائل مهم در کاربرد یادگیری ماشین برای کشف دارو محسوب می‌شود. ورودی اصلی این مسئله یک زوج شامل دارو و هدف پروتئینی است و خروجی مدل، مقدار پیوسته‌ای است که میزان میل اتصال میان این دو را نشان می‌دهد [۸].

به صورت مفهومی می‌توان این مسئله را به شکل زیر نمایش داد:

$$\text{Drug} + \text{Target} \rightarrow \text{Binding Affinity} \quad (۱-۲)$$

در این چارچوب، دارو می‌تواند به صورت یک رشته SMILES یا یک ساختار مولکولی و پروتئین نیز می‌تواند به صورت توالی اسیدهای آمینه یا ساختار سه‌بعدی نمایش داده شود. یکی از مزایای مدل‌سازی DTA نسبت به مدل‌سازی صرفاً دودویی DTI، حفظ اطلاعات مربوط به شدت برهم‌کنش است. برای مثال، دو ترکیب ممکن است هر دو با یک پروتئین برهم‌کنش داشته باشند، اما قدرت اتصال آن‌ها یکسان نباشد. یک مدل DTA می‌تواند تلاش کند این تفاوت را به صورت یک مقدار پیوسته مدل کند [۸]. از دیدگاه یادگیری ماشین، مسئله DTA معمولاً به صورت یک مسئله رگرسیون تعریف می‌شود. اگر مجموعه داده شامل N نمونه باشد، می‌توان آن را به شکل زیر نمایش داد:

$$D = \{(d_i, t_i, y_i)\}_{i=1}^N \quad (۱-۳)$$

که در آن d_i نمایش داروی i ، t_i نمایش پروتئین هدف و y_i مقدار میل اتصال مشاهده‌شده است. مدل یادگیری تلاش می‌کند تابعی مانند

$$\hat{y}_i = f(d_i, t_i; \theta) \quad (۱-۴)$$

را یاد بگیرد که در آن θ پارامترهای مدل و $\hat{y}_i$ مقدار پیش‌بینی شده است.

۴-۱ تفاوت برهم‌کنش دارو-هدف و پیش‌بینی میل اتصال

در ادبیات مربوط به محاسبات دارویی، اصطلاح Drug-Target Binding و Drug-Target Interaction Affinity Prediction گاهی در کنار یکدیگر استفاده می‌شوند، اما این دو مسئله از نظر نوع خروجی یکسان نیستند.

در مسئله DTI، خروجی معمولاً یک مقدار دودویی $y \in \{0, 1\}$ است که نشان می‌دهد آیا برهم‌کنشی میان دارو و پروتئین وجود دارد یا خیر. اما در DTA، خروجی یک مقدار پیوسته $y \in \mathbb{R}$ است که میزان میل اتصال را نشان می‌دهد.

به همین دلیل، اطلاعات موجود در داده‌های DTA از نظر مقدار شدت اتصال غنی‌تر است. در مقاله DeepDTA نیز بر این تفاوت تأکید شده و بیان شده است که بخش قابل توجهی از روش‌های اولیه بر تشخیص دودویی برهم‌کنش تمرکز داشته‌اند، در حالی که میل اتصال اطلاعاتی درباره قدرت این برهم‌کنش ارائه می‌کند [۸]. در این پایان‌نامه، تمرکز اصلی بر پیش‌بینی مقدار میل اتصال است و نه صرفاً تشخیص وجود یا عدم وجود برهم‌کنش.

۵-۱ اهمیت پیش‌بینی میل اتصال دارو-هدف

پیش‌بینی دقیق میل اتصال می‌تواند در بخش‌هایی از فرایند کشف و توسعه دارو مورد استفاده قرار گیرد. یکی از کاربردهای مهم، کاهش تعداد ترکیباتی است که باید در مراحل آزمایشگاهی مورد بررسی قرار گیرند. در یک فضای جست‌وجوی بزرگ، آزمایش تجربی تمام ترکیبات ممکن در برابر اهداف مختلف عملاً امکان‌پذیر نیست. یک مدل محاسباتی می‌تواند به عنوان یک مرحله غربالگری اولیه، ترکیبات را بر اساس مقدار پیش‌بینی‌شده میل اتصال مرتب کند.

این مسئله به ویژه در بازآفرینی کاربرد دارو^۷ نیز اهمیت دارد؛ زیرا در این فرایند می‌توان داروهای موجود را برای اهداف یا بیماری‌های جدید بررسی کرد. مدل‌های محاسباتی DTA می‌توانند با پیش‌بینی قدرت احتمالی اتصال، در اولویت‌بندی چنین بررسی‌هایی نقش داشته باشند [۲، ۷].

با این حال، خروجی یک مدل محاسباتی نباید به عنوان جایگزین کامل آزمایش‌های زیستی در نظر گرفته شود. پیش‌بینی محاسباتی بیشتر به عنوان ابزاری برای کاهش فضای جست‌وجو و انتخاب نمونه‌های مناسب برای

^۷Drug Repurposing

بررسی‌های بعدی مورد استفاده قرار می‌گیرد.

۱-۶ چالش‌های محاسباتی پیش‌بینی میل اتصال

با وجود مزایای روش‌های محاسباتی، پیش‌بینی DTA با چالش‌های متعددی مواجه است.

۱-۶-۱ پیچیدگی ساختار دارو

مولکول‌های دارویی دارای ساختارهای شیمیایی پیچیده‌ای هستند. نمایش یک مولکول به صورت یک رشته SMILES اطلاعات ساختاری آن را به شکلی متنی و ترتیبی بیان می‌کند، در حالی که ساختار واقعی مولکول شامل اتم‌ها، پیوندها و روابط فضایی میان آن‌ها است.

به همین دلیل، روش‌هایی مانند GraphDTA تلاش کرده‌اند دارو را به صورت گراف مولکولی نمایش دهند تا ارتباط میان اتم‌ها و پیوندها به صورت مستقیم در مدل قابل استفاده باشد [۷].

۱-۶-۲ پیچیدگی توالی پروتئین

پروتئین‌ها از توالی‌هایی از اسیدهای آمینه تشکیل شده‌اند و طول این توالی‌ها می‌تواند بسیار متفاوت باشد. استخراج ویژگی‌های مرتبط با محل اتصال و برهم‌کنش دارو از چنین توالی‌هایی یک چالش مهم در طراحی مدل‌های DTA است.

مدل‌هایی مانند DeepDTA از شبکه‌های CNN برای استخراج الگوهای محلی از توالی پروتئین استفاده می‌کنند [۸].

۱-۶-۳ محدودیت داده‌های برچسب‌دار

آموزش مدل‌های عمیق به داده‌های مناسب نیاز دارد. در مسئله DTA، داده‌های دارای مقدار تجربی میل اتصال محدودتر از فضای بالقوه تمام ترکیبات دارویی و اهداف پروتئینی هستند.

از این رو، روش‌هایی که بتوانند از داده‌های بدون برچسب یا ساختار نهفته داده‌ها نیز استفاده کنند، می‌توانند مورد توجه قرار گیرند. DCGAN-DTA نیز استفاده از شبکه‌های مولد را با هدف یادگیری نمایش از داده‌های توالی و SMILES مطرح می‌کند [۲].

۱-۶-۴ نحوه تقسیم داده‌ها

نحوه تقسیم داده به مجموعه‌های آموزش و آزمون می‌تواند تأثیر قابل توجهی بر ارزیابی یک مدل DTA داشته باشد. در حالت شروع گرم^۸، نمونه‌های موجود در مجموعه آزمون ممکن است شامل داروها و پروتئین‌هایی باشند که نمونه‌هایی از آن‌ها در مجموعه آموزش وجود داشته است. این وضعیت بیشتر توانایی مدل را در تعمیم به زوج‌های جدید از اجزای شناخته‌شده بررسی می‌کند.

در مقابل، در شروع سرد^۹ تلاش می‌شود مدل در شرایطی ارزیابی شود که دارو یا هدف جدیدی در زمان پیش‌بینی وارد مسئله می‌شود. مقاله DCGAN-DTA نیز علاوه بر تقسیم‌بندی شروع گرم، ارزیابی‌هایی بر اساس تقسیم‌بندی شروع سرد ارائه کرده است [۲].

بنابراین، صرف گزارش یک عدد عملکرد برای ارزیابی یک مدل DTA کافی نیست و شرایطی که آن عدد در آن به دست آمده است نیز باید مورد توجه قرار گیرد.

۱-۷ یادگیری عمیق در پیش‌بینی میل اتصال

افزایش حجم داده‌های زیستی و توسعه سخت‌افزارهای محاسباتی باعث شده است روش‌های یادگیری عمیق به یکی از رویکردهای مهم در پیش‌بینی ویژگی‌های مولکولی و زیستی تبدیل شوند.

یکی از نمونه‌های اولیه و اثرگذار در DTA، مدل DeepDTA است. این مدل از نمایش SMILES برای دارو و توالی اسیدهای آمینه برای پروتئین استفاده کرده و با بهره‌گیری از شبکه‌های CNN، نمایش‌های سطح بالاتری از این ورودی‌ها استخراج می‌کند [۸].

بعد از آن، معماری‌های دیگری نیز برای بهبود نمایش دارو و پروتئین توسعه داده شدند. برای نمونه، GraphDTA به جای نمایش دارو به صورت رشته، آن را به شکل یک گراف مولکولی در نظر می‌گیرد و از شبکه‌های عصبی گرافی برای استخراج ویژگی‌های ساختاری استفاده می‌کند [۷].

این روند نشان می‌دهد که یکی از مسائل مهم در DTA، تنها انتخاب یک الگوریتم پیش‌بینی نیست، بلکه یادگیری نمایش مناسب برای دارو و پروتئین نیز بخش مهمی از مسئله است.

در این پژوهش، تمرکز بر دو رویکردی است که از مدل‌های مولد برای یادگیری نمایش استفاده می‌کنند:

DCGAN-DTA و Co-VAE

^۸Warm-start

^۹Cold-start

۸-۱ مدل‌های مولد

مدل‌های مولد^{۱۰} خانواده‌ای از روش‌های یادگیری ماشین هستند که هدف آن‌ها یادگیری ساختار آماری داده‌ها و مدل‌سازی توزیع آن‌ها است.

در یک مدل مولد، هدف صرفاً پیش‌بینی یک خروجی برای یک ورودی نیست؛ بلکه مدل تلاش می‌کند اطلاعاتی درباره توزیع داده‌ها و ساختار نهفته آن‌ها یاد بگیرد.

دو خانواده مهم از مدل‌های مولد که در یادگیری عمیق مورد توجه قرار گرفته‌اند عبارت‌اند از:

۱. شبکه‌های مولد تخصصی یا GAN‌ها؛

۲. خودرمزگذارهای تغییرپذیر یا VAE‌ها.

این دو رویکرد از نظر ساختار و روش آموزش تفاوت اساسی دارند و هرکدام مسیر متفاوتی برای یادگیری فضای داده ارائه می‌کنند.

۹-۱ شبکه‌های مولد تخصصی

شبکه‌های مولد تخصصی یا GAN نخستین بار توسط Goodfellow و همکاران معرفی شدند [۱].

ساختار اصلی GAN از دو شبکه تشکیل می‌شود:

• مولد^{۱۱}؛

• تشخیص‌دهنده^{۱۲}.

مولد وظیفه تولید نمونه‌هایی را دارد که تلاش می‌کنند شبیه نمونه‌های واقعی باشند. تشخیص‌دهنده نیز تلاش می‌کند نمونه‌های واقعی را از نمونه‌های تولیدشده توسط مولد تشخیص دهد.

فرآیند آموزش GAN را می‌توان به صورت یک بازی رقابتی میان این دو شبکه در نظر گرفت. مولد تلاش می‌کند تشخیص‌دهنده را فریب دهد و تشخیص‌دهنده تلاش می‌کند نمونه‌های واقعی و جعلی را از یکدیگر تشخیص دهد [۱].

¹⁰Generative Models

¹¹Generator

¹²Discriminator

به صورت ساده:

$$z \rightarrow G(z) \rightarrow D(G(z)) \quad (۵-۱)$$

که در آن z یک بردار تصادفی و $G(z)$ نمونه تولیدشده توسط مولد است.

تابع هدف اصلی GAN به صورت یک مسئله کمینه-بیشینه^{۱۳} تعریف می‌شود:

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] \\ + \mathbb{E}_{z \sim p_z(z)} [\log (1 - D(G(z)))] \quad (۶-۱)$$

این ساختار باعث می‌شود مولد و تشخیص‌دهنده به صورت همزمان و رقابتی آموزش ببینند [۱].

۱۰-۱ شبکه‌های مولد تخصصی عمیق کانولوشنی

DCGAN^{۱۴} گونه‌ای از GAN است که از معماری‌های کانولوشنی عمیق برای مولد و تشخیص‌دهنده استفاده می‌کند.

Radford و همکاران نشان دادند که می‌توان با اعمال محدودیت‌های معماری مشخص، شبکه‌های کانولوشنی را با چارچوب GAN ترکیب کرد و نمایش‌های سلسله‌مراتبی مناسبی از داده‌ها یاد گرفت [۱۰]. ایده استفاده از CNN در GAN در ابتدا عمدتاً در حوزه‌هایی مانند پردازش تصویر مورد استفاده قرار گرفت، اما مفهوم یادگیری نمایش از طریق ساختار مولد و تخصصی می‌تواند در حوزه‌های دیگر نیز مورد بررسی قرار گیرد. DCGAN-DTA با الهام از این خانواده، ساختاری برای استفاده از شبکه‌های DCGAN در یادگیری نمایش دارو و پروتئین ارائه می‌کند. در این مدل، DCGAN برای استخراج نمایش از SMILES دارو و توالی پروتئین مورد استفاده قرار می‌گیرد و سپس این نمایش‌ها برای پیش‌بینی DTA به بخش‌های بعدی مدل منتقل می‌شوند [۲].

۱۱-۱ خودرمزگذارهای تغییرپذیر

خودرمزگذار تغییرپذیر یا VAE یکی دیگر از چارچوب‌های مهم مدل‌های مولد است.

VAE از دو بخش اصلی تشکیل می‌شود:

- رمزگذار^{۱۵}؛

¹³Minimax

¹⁴Deep Convolutional Generative Adversarial Network

¹⁵Encoder

• رمزگشا^{۱۶}.

رمزگذار داده ورودی را به یک توزیع احتمالی در فضای نهفته نگاشت می‌کند و رمزگشا تلاش می‌کند نمونه‌ای از این فضای نهفته را به داده‌ای مشابه ورودی بازسازی کند.

در چارچوب VAE، به جای آنکه هر ورودی مستقیماً به یک نقطه ثابت در فضای نهفته نگاشت شود، رمزگذار پارامترهای یک توزیع احتمالی، معمولاً میانگین و واریانس، را تولید می‌کند.

اگر توزیع نهفته به صورت $q_\phi(z|x)$ تعریف شود، نمونه z با استفاده از روش بازپارامتری‌سازی^{۱۷} از این توزیع استخراج می‌شود [۳].

هدف آموزش VAE ترکیبی از بازسازی داده و منظم‌سازی توزیع فضای نهفته است. فرم رایج تابع هدف را می‌توان به صورت زیر نوشت:

$$\mathcal{L} = \mathcal{L}_{reconstruction} + D_{KL}(q_\phi(z|x) \parallel p(z)) \quad (۷-۱)$$

که در آن جمله اول کیفیت بازسازی و جمله دوم فاصله میان توزیع نهفته یادگرفته‌شده و توزیع پیشین را کنترل می‌کند.

چارچوب VAE توسط Kingma و Welling معرفی شد و امکان یادگیری احتمالی فضای نهفته را با استفاده از روش‌های مبتنی بر گرادینت فراهم کرد [۳].

۱۲-۱ مدل Co-VAE

Co-VAE یک مدل مبتنی بر خودرمزگذار تغییرپذیر است که به صورت اختصاصی برای پیش‌بینی میل اتصال دارو-هدف توسعه داده شده است.

در این معماری، دو VAE برای مدل‌سازی دو نوع داده استفاده می‌شوند: یکی برای دارو و دیگری برای هدف پروتئینی. سپس یک بخش هم‌منظم‌سازی ارتباط میان این دو فضای نهفته را در نظر می‌گیرد تا اطلاعات مربوط به میل اتصال نیز مدل‌سازی شود [۴].

به بیان مفهومی، معماری Co-VAE را می‌توان به صورت زیر نمایش داد:

$$\text{Drug} \rightarrow \text{VAE}_{drug} \rightarrow z_d, \quad \text{Target} \rightarrow \text{VAE}_{target} \rightarrow z_t \quad (۸-۱)$$

¹⁶Decoder¹⁷Reparameterization

سپس نمایش‌های نهفته دارو و پروتئین در بخش مشترک مدل برای پیش‌بینی میل اتصال مورد استفاده قرار می‌گیرند.

بر اساس مقاله اصلی، Co-VAE علاوه بر پیش‌بینی میل اتصال، قابلیت تولید داروهای جدید با ویژگی‌های مرتبط با اهداف ورودی را نیز بررسی می‌کند [۴].

در این پایان‌نامه، تمرکز اصلی بر بخش **پیش‌بینی میل اتصال** مدل Co-VAE است و قابلیت تولید داروی جدید به عنوان هدف اصلی ارزیابی در نظر گرفته نمی‌شود.

۱-۱۳ مسئله مقایسه GAN و VAE در DTA

GAN و VAE هر دو در خانواده مدل‌های مولد قرار دارند، اما فلسفه طراحی و روش آموزش آن‌ها متفاوت است. در GAN، یادگیری بر اساس رقابت میان مولد و تشخیص‌دهنده انجام می‌شود. در مقابل، VAE با تعریف یک مدل احتمالی و یادگیری فضای نهفته منظم‌شده، تلاش می‌کند توزیع داده را مدل کند [۱، ۳]. این تفاوت می‌تواند بر ویژگی‌های مختلف مدل تأثیر بگذارد؛ از جمله:

- نحوه یادگیری نمایش داده؛
- ساختار فضای نهفته؛
- پایداری فرایند آموزش؛
- حساسیت به پارامترهای آموزشی؛
- هزینه محاسباتی؛
- توانایی تعمیم به داده‌های جدید.

با توجه به این تفاوت‌ها، مقایسه این دو رویکرد صرفاً بر اساس یک معیار دقت نمی‌تواند تصویر کاملی از رفتار مدل‌ها ارائه کند.

از این رو، در پژوهش حاضر تلاش می‌شود DCGAN-DTA و Co-VAE در یک چارچوب تجربی مشخص و با در نظر گرفتن معیارهای عملکرد، شرایط تقسیم داده و هزینه محاسباتی مورد بررسی قرار گیرند.

۱-۱۴ ضرورت انجام پژوهش

با وجود توسعه روش‌های متعدد برای DTA، مقایسه مستقیم مدل‌های متعلق به خانواده‌های مختلف مدل‌های مولد هنوز نیازمند توجه به شرایط ارزیابی و جزئیات پیاده‌سازی است.

مقاله Co-VAE این مدل را با روش‌های موجودی مانند DeepDTA و DeepAffinity مقایسه کرده است [۴]. از طرف دیگر، DCGAN-DTA یک معماری مبتنی بر GAN ارائه کرده و آن را بر روی مجموعه داده‌هایی مانند BindingDB [۵] و PDBbind [۱۱] و تحت شرایط مختلف ارزیابی بررسی کرده است [۲].

بنابراین، قرار دادن این دو مدل در یک مطالعه مقایسه‌ای می‌تواند امکان بررسی تفاوت میان دو رویکرد مولد را در یک مسئله یکسان فراهم کند.

هدف این پژوهش، ادعای ارائه یک معماری مولد جدید نیست؛ بلکه هدف اصلی، بررسی تجربی و مقایسه روش‌های دو رویکرد موجود و تحلیل نقاط قوت و محدودیت‌های آن‌ها در مسئله پیش‌بینی میل اتصال دارو-هدف است.

در این مقایسه، علاوه بر معیارهای معمول عملکرد، شرایط تقسیم داده، پایداری نتایج و هزینه محاسباتی نیز مورد توجه قرار خواهند گرفت.

۱-۱۵ اهداف پژوهش

۱-۱۵-۱ هدف اصلی

هدف اصلی این پژوهش، مقایسه عملکرد دو رویکرد مبتنی بر مدل‌های مولد، یعنی DCGAN-DTA و Co-VAE، در مسئله پیش‌بینی میل اتصال دارو-هدف است.

۱-۱۵-۲ اهداف فرعی

اهداف فرعی پژوهش عبارت‌اند از:

۱. بررسی مبانی نظری مدل‌های GAN و VAE در زمینه یادگیری نمایش و مدل‌سازی داده‌ها.

۲. بررسی معماری و نحوه عملکرد DCGAN-DTA در پیش‌بینی میل اتصال دارو-هدف.

۳. بررسی معماری و نحوه عملکرد Co-VAE در پیش‌بینی میل اتصال دارو-هدف.

۴. بررسی عملکرد مدل‌ها بر روی مجموعه داده‌های مورد استفاده در این مطالعه.
۵. مقایسه عملکرد مدل‌ها در شرایط مختلف تقسیم داده.
۶. بررسی معیارهای ارزیابی متداول در مسئله DTA.
۷. بررسی پایداری عملکرد مدل‌ها در اجرای آزمایش‌ها.
۸. مقایسه هزینه و زمان محاسباتی مدل‌ها.
۹. تحلیل نقاط قوت و محدودیت‌های هر یک از دو رویکرد.
۱۰. بررسی عواملی که می‌توانند باعث تفاوت عملکرد GAN و VAE در مسئله DTA شوند.

۱-۱۶ پرسش‌های پژوهش

پژوهش حاضر به دنبال پاسخ به پرسش‌های زیر است:

پرسش اصلی

آیا تفاوت معماری میان رویکردهای مبتنی بر GAN و VAE می‌تواند باعث تفاوت معناداری در عملکرد پیش‌بینی میل اتصال دارو-هدف شود؟

پرسش‌های فرعی

۱. عملکرد DCGAN-DTA و Co-VAE در معیارهای مختلف ارزیابی DTA چگونه با یکدیگر مقایسه می‌شود؟
۲. آیا عملکرد دو مدل تحت شرایط مختلف تقسیم داده یکسان باقی می‌ماند؟
۳. کدام مدل از نظر پایداری نتایج عملکرد بهتری دارد؟
۴. تفاوت هزینه محاسباتی و زمان آموزش دو مدل چگونه است؟
۵. آیا برتری یک مدل در یک معیار ارزیابی، در سایر معیارها نیز مشاهده می‌شود؟
۶. هر یک از دو معماری چه نقاط قوت و محدودیت‌هایی در مسئله DTA دارند؟

۱۷-۱ فرضیه‌های پژوهش

با توجه به تفاوت ساختاری میان GAN و VAE و نتایج گزارش شده در مطالعات پیشین، فرضیه‌های پژوهش به صورت زیر تعریف می‌شوند:

فرضیه اول: عملکرد DCGAN-DTA و Co-VAE در پیش‌بینی میل اتصال دارو-هدف یکسان نیست و تفاوت عملکرد میان آن‌ها قابل اندازه‌گیری است.

فرضیه دوم: شرایط تقسیم داده می‌تواند بر عملکرد مشاهده‌شده هر دو مدل تأثیر بگذارد.

فرضیه سوم: مدل‌های مبتنی بر GAN و VAE از نظر هزینه محاسباتی و زمان آموزش رفتار یکسانی ندارند.

فرضیه چهارم: تفاوت میان دو معماری تنها در مقدار نهایی یک معیار عملکرد خلاصه نمی‌شود و می‌تواند در پایداری آموزش و توانایی تعمیم مدل نیز مشاهده شود.

لازم به تأکید است که این فرضیه‌ها در این مرحله به عنوان فرضیه‌های پژوهش مطرح می‌شوند و پذیرش یا رد آن‌ها تنها پس از اجرای آزمایش‌ها و تحلیل نتایج انجام خواهد شد.

۱۸-۱ نوآوری و سهم پژوهش

سهم اصلی این پژوهش در توسعه یک معماری جدید برای پیش‌بینی میل اتصال نیست. در عوض، این پژوهش بر مطالعه مقایسه‌ای کنترل‌شده دو رویکرد موجود تمرکز دارد.

مهم‌ترین جنبه‌های این مطالعه عبارت‌اند از:

۱. مقایسه یک روش مبتنی بر GAN یعنی DCGAN-DTA با یک روش مبتنی بر VAE یعنی Co-VAE در مسئله مشترک DTA.

۲. بررسی مدل‌ها با تأکید بر تفاوت واقعی معماری و فرایند یادگیری آن‌ها.

۳. توجه به شرایط تقسیم داده و تفاوت میان ارزیابی‌های شروع گرم و شروع سرد، در مواردی که داده و پیاده‌سازی مدل اجازه چنین ارزیابی‌ای را فراهم کند.

۴. بررسی عملکرد مدل‌ها در کنار هزینه محاسباتی و زمان آموزش.

۵. توجه به تکرارپذیری آزمایش‌ها و ثبت جزئیات پیاده‌سازی.
 ۶. تفکیک ادعاهای مطرح‌شده در مقالات اصلی از رفتار مشاهده‌شده در کد و آزمایش‌های انجام‌شده در این پژوهش.
- در نتیجه، ارزش اصلی پژوهش در ارائه یک مقایسه تجربی و قابل تحلیل میان دو خانواده مدل مولد در یک مسئله مشخص است.

۱-۱۹ محدودۀ پژوهش

- این پژوهش بر مسئله پیش‌بینی میل اتصال دارو-هدف تمرکز دارد.
- در این مطالعه:
- مسئله اصلی، پیش‌بینی مقدار میل اتصال است؛
 - تمرکز اصلی بر مدل‌های DCGAN-DTA و Co-VAE است؛
 - داده‌های مورد استفاده بر اساس مجموعه داده‌های قابل استفاده برای این دو مدل انتخاب می‌شوند؛
 - عملکرد مدل‌ها با معیارهای مناسب مسئله DTA ارزیابی می‌شود؛
 - شرایط تقسیم داده در ارزیابی مدل‌ها مورد توجه قرار می‌گیرد؛
 - هزینه محاسباتی و پایداری آموزش نیز تا حد امکان بررسی می‌شود.
- این پژوهش به دنبال مدل‌سازی کامل فرآیند کشف دارو، جایگزینی آزمایش‌های آزمایشگاهی یا طراحی یک سیستم بالینی نیست.
- همچنین، تولید مولکول‌های دارویی جدید هدف اصلی این پایان‌نامه نیست، حتی اگر برخی مدل‌های مورد بررسی مانند Co-VAE دارای قابلیت‌های مولد اضافی باشند [۴].

۱-۲۰ ساختار پایان‌نامه

ساختار این پایان‌نامه در پنج فصل تنظیم شده است.

فصل اول به کلیات پژوهش اختصاص دارد. در این فصل، مسئله پیش‌بینی میل اتصال دارو-هدف معرفی شده، تفاوت آن با مسئله تشخیص برهم‌کنش دارو-هدف توضیح داده شده و ضرورت استفاده از روش‌های یادگیری عمیق و مدل‌های مولد بررسی می‌شود. همچنین اهداف، پرسش‌ها، فرضیه‌ها، سهم پژوهش و محدوده مطالعه ارائه می‌شوند.

فصل دوم به مبانی نظری و پیشینه پژوهش اختصاص دارد. در این فصل، مفاهیم مرتبط با میل اتصال دارو-هدف، نمایش دارو و پروتئین، روش‌های یادگیری عمیق، GAN، DCGAN، VAE و مدل‌های DTA پیشین بررسی می‌شوند. همچنین مطالعات مرتبط با DeepDTA، GraphDTA، Co-VAE و DCGAN-DTA مورد بررسی قرار خواهند گرفت.

فصل سوم روش پژوهش را ارائه می‌کند. در این فصل، مجموعه داده‌ها، مراحل پیش‌پردازش، نحوه نمایش دارو و پروتئین، معماری DCGAN-DTA و Co-VAE، روش تقسیم داده، معیارهای ارزیابی و محیط اجرای آزمایش‌ها توضیح داده می‌شوند.

فصل چهارم به نتایج و تحلیل آزمایش‌ها اختصاص دارد. در این فصل عملکرد دو مدل بر اساس معیارهای تعریف‌شده مقایسه شده و نتایج مربوط به شرایط مختلف ارزیابی، پایداری و هزینه محاسباتی تحلیل می‌شوند.

فصل پنجم شامل جمع‌بندی، نتیجه‌گیری و پیشنهادهایی برای پژوهش‌های آینده خواهد بود. در این فصل، یافته‌های اصلی پژوهش جمع‌بندی شده و محدودیت‌های مطالعه و مسیرهای احتمالی ادامه پژوهش بیان می‌شوند.

فصل ۲

مبانی نظری و پیشینه پژوهش

۱-۲ مقدمه

پیش‌بینی میل اتصال دارو-هدف یکی از مسائل مهم در کاربرد روش‌های یادگیری ماشین و یادگیری عمیق در کشف دارو است. همان‌طور که در فصل نخست بیان شد، هدف در مسئله پیش‌بینی میل اتصال دارو-هدف، پیش‌بینی یک مقدار پیوسته برای شدت اتصال میان یک ترکیب دارویی و یک هدف پروتئینی است.

برای طراحی و تحلیل مدل‌های یادگیری عمیق در این حوزه، ابتدا باید نحوه نمایش داده‌های دارویی و پروتئینی، ماهیت مسئله پیش‌بینی میل اتصال، روش‌های سنتی و عمیق موجود و سپس مدل‌های مولد مورد استفاده در این پژوهش بررسی شوند.

در این فصل ابتدا مفاهیم مربوط به دارو، پروتئین، برهم‌کنش دارو-هدف و میل اتصال معرفی می‌شوند. سپس نمایش‌های متداول دارو و پروتئین، از جمله SMILES، توالی اسیدهای آمینه و نمایش‌های گراف، بررسی خواهند شد. در ادامه، روش‌های یادگیری ماشین و یادگیری عمیق در DTA و مدل‌های مهمی مانند DeepDTA و GraphDTA معرفی می‌شوند.

پس از آن، دو خانواده اصلی مدل‌های مولد مورد استفاده در این پژوهش، یعنی شبکه‌های مولد تخصصی و خودرمزگذارهای تغییرپذیر، تشریح خواهند شد. در نهایت، معماری Co-VAE و DCGAN-DTA به صورت جداگانه بررسی شده و جایگاه این دو روش در میان روش‌های پیش‌بینی میل اتصال دارو-هدف مشخص می‌شود.

۲-۲ مفاهیم پایه در پیش‌بینی میل اتصال دارو-هدف

۱-۲-۲ دارو و لیگاند

دارو یا ترکیب دارویی در مسئله DTA معمولاً به صورت یک مولکول کوچک در نظر گرفته می‌شود که می‌تواند با یک پروتئین هدف برهم‌کنش داشته باشد.

در ادبیات محاسباتی، واژه لیگاند^۱ نیز برای اشاره به مولکولی که به یک مولکول زیستی، مانند پروتئین، متصل می‌شود به کار می‌رود.

ساختار شیمیایی یک دارو شامل اتم‌ها و پیوندهای مختلفی است که آرایش آن‌ها می‌تواند بر ویژگی‌های فیزیکی و شیمیایی مولکول و همچنین نحوه اتصال آن به پروتئین تأثیر بگذارد.

در روش‌های محاسباتی، لازم است این ساختار به یک نمایش قابل استفاده برای الگوریتم یادگیری ماشین تبدیل شود. یکی از متداول‌ترین نمایش‌ها، SMILES است که ساختار مولکول را به صورت یک رشته متنی نمایش می‌دهد [۷].

۲-۲-۲ پروتئین هدف

پروتئین‌های هدف مولکول‌های زیستی هستند که داروها می‌توانند با آن‌ها برهم‌کنش داشته باشند. یک پروتئین از زنجیره‌ای از اسیدهای آمینه تشکیل شده است. بنابراین یکی از ساده‌ترین روش‌های نمایش یک پروتئین، استفاده از توالی اسیدهای آمینه آن است. برای مثال، یک توالی پروتئینی را می‌توان به شکل زیر نمایش داد:

$$P = [A, C, D, E, F, \dots] \quad (۱-۲)$$

که در آن هر حرف نشان‌دهنده یک اسید آمینه است.

در روش‌هایی مانند DeepDTA، توالی پروتئین به صورت مستقیم به عنوان ورودی مدل مورد استفاده قرار می‌گیرد و شبکه عصبی تلاش می‌کند الگوهای مرتبط با میل اتصال را از این توالی استخراج کند [۸].

۳-۲ برهم‌کنش دارو-هدف

برهم‌کنش دارو-هدف یا DTI به برهم‌کنش میان یک ترکیب دارویی و یک هدف زیستی اشاره دارد.

¹Ligand

در مطالعات اولیه، مسئله DTI معمولاً به صورت یک مسئله طبقه‌بندی تعریف می‌شد؛ به این صورت که مدل باید تعیین کند آیا یک دارو با یک پروتئین برهم‌کنش دارد یا خیر.

در چنین حالتی خروجی مدل معمولاً به صورت $y \in \{0, 1\}$ تعریف می‌شود که در آن مقدار یک نشان‌دهنده وجود برهم‌کنش و مقدار صفر نشان‌دهنده عدم وجود برهم‌کنش است.

با این حال، چنین نمایش دودویی اطلاعاتی درباره شدت برهم‌کنش ارائه نمی‌کند. به همین دلیل، استفاده از داده‌های میل اتصال امکان تعریف دقیق‌تر مسئله را فراهم می‌کند [۸].

۲-۴ میل اتصال

میل اتصال معیاری برای توصیف قدرت اتصال میان یک لیگاند و یک هدف زیستی است. در داده‌های تجربی، این ویژگی می‌تواند با کمیت‌هایی مانند:

- K_d ؛

- K_i ؛

- IC_{50} .

اندازه‌گیری یا گزارش شود [۸].

برای مثال، K_d یا ثابت تفکیک^۲ در بسیاری از مطالعات به عنوان معیاری برای توصیف قدرت اتصال استفاده می‌شود.

مقادیر پایین‌تر برخی از این ثابت‌ها معمولاً نشان‌دهنده اتصال قوی‌تر هستند. برای ایجاد مقیاس مناسب‌تر در مدل‌سازی، مقادیر ثابت‌های اتصال می‌توانند به صورت لگاریتم منفی تبدیل شوند. برای نمونه:

$$pK_d = -\log_{10}(K_d) \quad (2-2)$$

این تبدیل باعث می‌شود مقادیر میل اتصال در یک مقیاس مناسب‌تر برای استفاده در مدل‌های یادگیری ماشین قرار گیرند.

DeepDTA نیز برای داده‌های مربوط به میل اتصال از مقادیر تبدیل‌شده مانند pK_d و pK_i استفاده می‌کند

[۸].

²Dissociation Constant

۵-۲ فرمول بندی ریاضی مسئله DTA

فرض کنیم مجموعه داده شامل N نمونه باشد:

$$D = \{(d_i, t_i, y_i)\}_{i=1}^N \quad (۳-۲)$$

که در آن:

- d_i : نمایش داروی i ؛
- t_i : نمایش پروتئین هدف i ؛
- y_i : مقدار تجربی میل اتصال.

هدف مدل یادگیری ماشین، یادگیری تابعی به صورت زیر است:

$$f(d_i, t_i; \theta) \rightarrow \hat{y}_i \quad (۴-۲)$$

که در آن θ مجموعه پارامترهای قابل یادگیری مدل و $\hat{y}_i$ مقدار پیش‌بینی شده است.

در یک مدل رگرسیون، هدف کاهش اختلاف میان مقدار واقعی و مقدار پیش‌بینی شده است. یکی از توابع خطای متداول برای این مسئله میانگین مربعات خطا^۳ است:

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (۵-۲)$$

با این حال، در مطالعات DTA تنها MSE مورد استفاده قرار نمی‌گیرد و معیارهایی مانند شاخص سازگاری^۴ نیز اهمیت زیادی دارند [۷، ۸].

۶-۲ نمایش دارو

یکی از مراحل مهم در طراحی یک مدل DTA، تبدیل ساختار دارو به یک نمایش عددی مناسب است. سه رویکرد اصلی را می‌توان در این زمینه در نظر گرفت:

۱. نمایش رشته‌ای؛

^۳Mean Squared Error (MSE)

^۴Concordance Index (CI)

۲. نمایش مبتنی بر ویژگی‌های دستی یا محاسبه‌شده؛

۳. نمایش گرافی.

۲-۶-۱ نمایش SMILES

SMILES^۵ روشی برای نمایش ساختار مولکول به صورت یک رشته متنی است.

برای مثال، یک مولکول می‌تواند به شکل CCO نمایش داده شود که یک نمایش متنی از ساختار مولکولی است.

مزیت مهم SMILES این است که اطلاعات ساختاری مولکول را در قالبی نسبتاً فشرده و قابل پردازش برای کامپیوتر ارائه می‌کند.

در DeepDTA، SMILES به صورت یک توالی از کاراکترها وارد شبکه می‌شود و CNN تلاش می‌کند الگوهای محلی موجود در این توالی را یاد بگیرد [۸].

DCGAN-DTA نیز از SMILES به عنوان یکی از ورودی‌های اصلی خود استفاده می‌کند [۲].

۲-۶-۲ نمایش مبتنی بر ویژگی‌های مولکولی

در برخی روش‌ها، به جای استفاده مستقیم از SMILES، مجموعه‌ای از ویژگی‌های شیمیایی و ساختاری برای هر دارو محاسبه می‌شود.

این ویژگی‌ها می‌توانند شامل اطلاعاتی مانند موارد زیر باشند:

- وزن مولکولی؛
- تعداد اتم‌ها؛
- ویژگی‌های مربوط به پیوندها؛
- توصیفگرهای شیمیایی؛
- شباهت میان مولکول‌ها.

⁵Simplified Molecular Input Line Entry System

این رویکرد می‌تواند اطلاعات مفیدی فراهم کند، اما معمولاً نیازمند انتخاب یا استخراج ویژگی‌های مناسب است.

یکی از انگیزه‌های استفاده از یادگیری عمیق در DTA این است که مدل بتواند بخشی از این نمایش را مستقیماً از داده خام یاد بگیرد [۸].

۲-۲ نمایش گرافی دارو

از دیدگاه شیمیایی، یک مولکول را می‌توان به صورت یک گراف در نظر گرفت. در این نمایش:

$$G = (V, E) \quad (۲-۶)$$

که در آن:

- V مجموعه اتم‌ها؛

- E مجموعه پیوندهای میان اتم‌ها است.

در نتیجه، ویژگی هر گره می‌تواند بیانگر ویژگی‌های یک اتم و یال‌ها نشان‌دهنده نوع یا وجود پیوند میان اتم‌ها باشند.

GraphDTA با استفاده از همین ایده، دارو را به صورت یک گراف مولکولی نمایش می‌دهد و از شبکه‌های عصبی گرافی^۶ برای استخراج نمایش آن استفاده می‌کند [۷].

این روش از این جهت اهمیت دارد که روابط ساختاری میان اتم‌ها را مستقیماً در مدل وارد می‌کند.

GraphDTA چهار نوع معماری مبتنی بر GNN را بررسی می‌کند:

- GCN؛

- GAT؛

- GIN؛

- GAT-GCN.

^۶Graph Neural Networks (GNNs)

در بخش مربوط به پروتئین نیز از CNN برای استخراج نمایش توالی استفاده می‌شود [۷].

۸-۲ نمایش پروتئین

پروتئین را نیز می‌توان با روش‌های مختلف نمایش داد.

۱-۸-۲ توالی اسیدهای آمینه

ساده‌ترین روش، استفاده از توالی اسیدهای آمینه است. برای مثال:

$$P = A - C - D - E - F - G - \dots \quad (۷-۲)$$

در این حالت هر اسید آمینه را می‌توان به یک عدد یا بردار نهفته^۷ تبدیل کرد.

این روش مزیت مهمی دارد؛ زیرا برای استفاده از آن نیازی به داشتن ساختار سه‌بعدی پروتئین نیست.

DeepDTA از همین رویکرد استفاده می‌کند [۸].

۲-۸-۲ ویژگی‌های تکاملی پروتئین

توالی خام پروتئین تنها بخشی از اطلاعات زیستی موجود در داده را نمایش می‌دهد.

یکی از روش‌های استفاده از اطلاعات تکاملی، استفاده از ماتریس‌های جایگزینی^۸ مانند BLOSUM است.

BLOSUM نوعی ماتریس امتیازدهی برای جایگزینی اسیدهای آمینه است که می‌تواند اطلاعاتی درباره

شباهت‌های تکاملی میان اسیدهای آمینه ارائه کند.

DCGAN-DTA برای نمایش پروتئین علاوه بر کدگذاری توالی، از کدگذاری BLOSUM نیز استفاده می‌کند

و هر اسید آمینه را به یک بردار ویژگی ۲۵ بعدی تبدیل می‌کند [۲].

۳-۸-۲ ساختار سه‌بعدی پروتئین

روش دیگر، استفاده از ساختار سه‌بعدی پروتئین است.

در این رویکرد، اطلاعات فضایی اتم‌ها و اسیدهای آمینه نیز وارد مدل می‌شود.

^۷Embedding

^۸Substitution Matrix

اگرچه ساختار سه‌بعدی می‌تواند اطلاعات بسیار غنی‌ای درباره محل اتصال ارائه کند، دسترسی به ساختار دقیق سه‌بعدی همه پروتئین‌ها دشوار است. به همین دلیل، بسیاری از روش‌های DTA از توالی پروتئین استفاده می‌کنند [۷، ۸].

۹-۲ روش‌های سنتی پیش‌بینی میل اتصال

پیش از گسترش یادگیری عمیق، روش‌های مختلفی برای پیش‌بینی میل اتصال دارو-هدف ارائه شده بودند. یکی از روش‌های شناخته‌شده، KronRLS است که از حداقل مربعات منظم‌شده^۹ برای پیش‌بینی میل اتصال استفاده می‌کند. روش دیگر SimBoost است که از ویژگی‌های مربوط به شبکه دارو-هدف و شباهت میان داروها و پروتئین‌ها استفاده می‌کند. DeepDTA این روش‌ها را به عنوان خط مبنا^{۱۰} بررسی کرد و نشان داد که استفاده از نمایش‌های یادگرفتنی و CNN می‌تواند عملکرد قابل توجهی در پیش‌بینی میل اتصال ایجاد کند [۸].

۱۰-۲ یادگیری عمیق در DTA

با افزایش حجم داده‌های زیستی، روش‌های یادگیری عمیق به یکی از رویکردهای اصلی در DTA تبدیل شدند. یکی از دلایل اصلی استفاده از یادگیری عمیق این است که می‌توان استخراج ویژگی را مستقیماً در فرآیند آموزش مدل انجام داد. در روش‌های کلاسیک، پژوهشگر معمولاً باید مجموعه‌ای از ویژگی‌های مناسب را انتخاب یا محاسبه کند. در مقابل، یک شبکه عمیق می‌تواند نمایش نهفته‌ای از ورودی را یاد بگیرد. این ویژگی به‌خصوص برای داده‌هایی مانند SMILES و توالی پروتئین اهمیت دارد؛ زیرا هر دو را می‌توان به عنوان توالی‌هایی با الگوهای محلی و سلسله‌مراتبی در نظر گرفت.

۱۱-۲ مدل DeepDTA

DeepDTA یکی از روش‌های اثرگذار در استفاده از یادگیری عمیق برای DTA است که توسط Öztürk و

^۹Regularized Least Squares

^{۱۰}Baseline

همکاران ارائه شد [۸].

ایده اصلی DeepDTA این است که می‌توان بدون استفاده مستقیم از ساختار سه‌بعدی کمپلکس دارو-پروتئین، از نمایش‌های یک‌بعدی دارو و پروتئین استفاده کرد. در این مدل:

- دارو با SMILES نمایش داده می‌شود؛
- پروتئین با توالی اسیدهای آمینه نمایش داده می‌شود؛
- برای هر دو ورودی از CNN استفاده می‌شود؛
- نمایش‌های حاصل با یکدیگر ترکیب می‌شوند؛
- در نهایت مقدار میل اتصال پیش‌بینی می‌شود [۸].

ساختار کلی را می‌توان به صورت زیر نمایش داد:

$$\text{Drug} \rightarrow \text{CNN} \rightarrow z_d, \quad \text{Protein} \rightarrow \text{CNN} \rightarrow z_t \quad (۸-۲)$$

سپس:

$$[z_d, z_t] \rightarrow \text{FC} \rightarrow \hat{y} \quad (۹-۲)$$

DeepDTA روی دو مجموعه داده Davis و KIBA ارزیابی شد و نویسندگان گزارش کردند که استفاده از CNN برای یادگیری نمایش دارو و پروتئین عملکرد مدل را نسبت به برخی خطوط مبنای مورد بررسی بهبود می‌دهد [۸].

۱۲-۲ مدل GraphDTA

GraphDTA در ادامه مسیر مدل‌های عمیق DTA، تلاش کرد یکی از محدودیت‌های نمایش رشته‌ای دارو را برطرف کند.

در DeepDTA، SMILES به عنوان یک رشته وارد مدل می‌شود. در حالی که SMILES یک نمایش متنی از ساختار مولکول است، خود مولکول ذاتاً یک ساختار گرافی دارد.

GraphDTA بنابراین دارو را به صورت گراف مولکولی نمایش می‌دهد و از شبکه‌های عصبی گرافی برای یادگیری نمایش آن استفاده می‌کند [۷].

برای پروتئین، GraphDTA همچنان از توالی و CNN استفاده می‌کند. در نتیجه، ساختار کلی آن شامل دو مسیر است:

$$\text{Drug Graph} \rightarrow \text{GNN} \rightarrow z_d, \quad \text{Protein Sequence} \rightarrow \text{CNN} \rightarrow z_t \quad (۱۰-۲)$$

سپس دو نمایش برای پیش‌بینی میل اتصال ترکیب می‌شوند.

GraphDTA چهار معماری GCN، GAT، GIN و GAT-GCN را بررسی کرد و آن‌ها را روی مجموعه داده‌های Davis و KIBA ارزیابی نمود [۷].

اهمیت GraphDTA برای این پژوهش در این است که نشان می‌دهد انتخاب نمایش ورودی، به اندازه انتخاب مدل پیش‌بینی اهمیت دارد.

۲-۱۳ مدل‌های مولد

مدل‌های مولد دسته‌ای از مدل‌های یادگیری ماشین هستند که هدف آن‌ها یادگیری ساختار توزیع داده و تولید یا مدل‌سازی نمونه‌هایی از آن است.

در مدل‌های تمایزی^{۱۱} معمولاً هدف اصلی یادگیری رابطه‌ای مانند $P(y|x)$ است.

اما مدل‌های مولد تلاش می‌کنند ساختار توزیع داده را نیز مدل کنند، برای مثال $P(x)$ یا توزیع مشترک $P(x, y)$. دو خانواده مهم از مدل‌های مولد که در این پژوهش اهمیت دارند عبارت‌اند از:

۱. شبکه‌های مولد تخصصی؛

۲. خودرمزگذارهای تغییرپذیر.

۲-۱۴ شبکه‌های مولد تخصصی

شبکه مولد تخصصی یا GAN توسط Goodfellow و همکاران معرفی شد [۱].

GAN شامل دو شبکه اصلی است:

¹¹Discriminative Models

مولد

مولد وظیفه تولید نمونه‌هایی را دارد که از نظر توزیع آماری شبیه داده‌های واقعی باشند.

تشخیص‌دهنده

تشخیص‌دهنده وظیفه تشخیص نمونه‌های واقعی از نمونه‌های تولیدشده را بر عهده دارد.

در نتیجه، این دو شبکه در یک فرآیند رقابتی آموزش می‌بینند.

اگر G مولد و D تشخیص‌دهنده باشد، تابع هدف کلاسیک GAN به شکل زیر تعریف می‌شود:

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{data}} [\log D(x)] + \mathbb{E}_{z \sim p_z} [\log (1 - D(G(z)))] \quad (11-2)$$

مولد تلاش می‌کند نمونه‌هایی تولید کند که تشخیص‌دهنده آن‌ها را واقعی تشخیص دهد، در حالی که تشخیص‌دهنده تلاش می‌کند میان داده واقعی و مصنوعی تمایز ایجاد کند [۱].

۱۵-۲ فرایند آموزش GAN

در حالت ساده، آموزش GAN را می‌توان در دو مرحله در نظر گرفت.

ابتدا تشخیص‌دهنده با داده واقعی و داده تولیدشده آموزش می‌بیند.

سپس مولد با توجه به بازخورد تشخیص‌دهنده به‌روزرسانی می‌شود.

این فرایند به صورت تکراری ادامه پیدا می‌کند.

بنابراین، برخلاف یک شبکه رگرسیون معمولی، GAN تنها با یک تابع زیان ساده برای یک شبکه آموزش داده

نمی‌شود؛ بلکه دو مدل به صورت همزمان در حال تغییر هستند.

این ساختار مزایای خاصی برای یادگیری نمایش دارد، اما آموزش آن می‌تواند پیچیده‌تر و حساس‌تر از مدل‌های

متعارف باشد.

۱۶-۲ شبکه مولد تخصصی کانولوشنی عمیق

DCGAN^{۱۲} گونه‌ای از GAN است که از معماری‌های کانولوشنی عمیق استفاده می‌کند.

¹²Deep Convolutional Generative Adversarial Network

Chintala و Metz، Radford نشان دادند که اعمال محدودیت‌های معماری مناسب به شبکه‌های کانولوشنی در چارچوب GAN می‌تواند برای یادگیری نمایش‌های سلسله‌مراتبی مفید باشد [۱۰].

اگرچه DCGAN در ابتدا عمدتاً در حوزه داده‌های تصویری مورد استفاده قرار گرفت، ایده اصلی آن یعنی استفاده از یک معماری کانولوشنی در چارچوب تخصصی می‌تواند به داده‌های توالی نیز تعمیم داده شود.

DCGAN-DTA از یک نسخه سفارشی‌شده از این ایده برای داده‌های مربوط به SMILES و توالی پروتئین استفاده می‌کند [۲].

۱۷-۲ خودرمزگذار

خودرمزگذار^{۱۳} یک معماری یادگیری عمیق است که معمولاً از دو بخش تشکیل می‌شود:

- رمزگذار^{۱۴}؛
- رمزگشا^{۱۵}.

رمزگذار ورودی را به یک نمایش نهفته تبدیل می‌کند ($x \rightarrow z$) و رمزگشا تلاش می‌کند ورودی را از این نمایش بازسازی کند ($z \rightarrow \hat{x}$).

بنابراین هدف کلی خودرمزگذار کاهش خطای بازسازی است:

$$L_{rec} = L(x, \hat{x}) \quad (۱۲-۲)$$

فضای z در این معماری می‌تواند اطلاعات فشرده‌ای از ورودی را در خود جای دهد.

۱۸-۲ خودرمزگذار تغییرپذیر

خودرمزگذار تغییرپذیر یا VAE توسعه‌ای احتمالاتی از خودرمزگذار است که توسط Kingma و Welling معرفی شد [۳].

در خودرمزگذار معمولی، رمزگذار معمولاً ورودی را به یک بردار قطعی تبدیل می‌کند.

¹³Autoencoder

¹⁴Encoder

¹⁵Decoder

اما در VAE، رمزگذار به جای یک نقطه مشخص در فضای نهفته، پارامترهای یک توزیع احتمالی را تولید می‌کند. برای نمونه:

$$q_{\phi}(z|x) = \mathcal{N}(\mu(x), \sigma^2(x)) \quad (۱۳-۲)$$

در نتیجه، برای یک ورودی x ، مدل میانگین و واریانس توزیع نهفته را یاد می‌گیرد. سپس یک نمونه z از این توزیع انتخاب شده و به رمزگشا داده می‌شود.

۱۹-۲ ترفند بازپارامتری‌سازی

یکی از مسائل اصلی در VAE این است که نمونه‌گیری تصادفی مستقیم از یک توزیع چگونه می‌تواند با پس‌انتشار^{۱۶} آموزش داده شود.

Kingma و Welling برای این مسئله از ترفند بازپارامتری‌سازی^{۱۷} استفاده کردند [۳].

به جای آنکه مستقیماً بنویسیم $z \sim \mathcal{N}(\mu, \sigma^2)$ ، می‌توان نوشت:

$$z = \mu + \sigma \odot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I) \quad (۱۴-۲)$$

در این حالت، تصادفی بودن در ϵ قرار می‌گیرد و عملیات مربوط به μ و σ قابل مشتق‌گیری باقی می‌ماند.

این ترفند امکان استفاده از روش‌های استاندارد بهینه‌سازی مبتنی بر گرادیان را در VAE فراهم می‌کند [۳].

۲۰-۲ تابع هدف VAE

هدف VAE را می‌توان به دو بخش اصلی تقسیم کرد:

۱. خطای بازسازی؛

۲. منظم‌سازی فضای نهفته.

فرم کلی تابع هدف به صورت زیر است:

$$\mathcal{L} = \mathcal{L}_{reconstruction} + D_{KL}(q_{\phi}(z|x) \parallel p(z)) \quad (۱۵-۲)$$

¹⁶Backpropagation

¹⁷Reparameterization Trick

جمله اول مدل را تشویق می‌کند که داده ورودی را به خوبی بازسازی کند.

جمله دوم توزیع نهفته را به یک توزیع پیشین، معمولاً توزیع نرمال استاندارد، نزدیک می‌کند [۳].

در نتیجه، VAE نه تنها یک نمایش فشرده از داده ایجاد می‌کند، بلکه ساختار فضای نهفته را نیز کنترل می‌کند.

۲-۲۱ مقایسه مفهومی GAN و VAE

GAN و VAE هر دو مدل مولد هستند، اما تفاوت‌های مهمی دارند. جدول ۲-۱ این تفاوت‌ها را خلاصه می‌کند.

جدول ۲-۱: مقایسه مفهومی GAN و VAE

ویژگی	GAN	VAE
ساختار اصلی	مولد + تشخیص‌دهنده	رمزگذار + رمزگشا
مبنای یادگیری	رقابت تخصصی	استنتاج احتمالاتی
فضای نهفته	لزوماً به صورت صریح منظم نمی‌شود	به صورت صریح منظم می‌شود
آموزش	رقابتی	مبتنی بر بهینه‌سازی ELBO
نمونه‌گیری	از مولد	از فضای نهفته
پیچیدگی آموزش	معمولاً حساس به تعادل دو شبکه	معمولاً پایدارتر از GAN
هدف اصلی	یادگیری توزیع و تولید نمونه	مدل‌سازی احتمالاتی و بازسازی

این تفاوت‌ها از نظر نظری می‌توانند باعث رفتار متفاوت این دو خانواده در یادگیری نمایش و تعمیم به داده‌های جدید شوند.

با این حال، برتری یکی از این دو رویکرد را نمی‌توان صرفاً بر اساس ویژگی نظری آن‌ها تعیین کرد و نیاز به ارزیابی تجربی وجود دارد.

۲-۲۲ مدل Co-VAE

Co-VAE توسط Li و Zhao، Li برای پیش‌بینی میل اتصال دارو-هدف معرفی شد [۴].

ایده اصلی این مدل استفاده از دو VAE برای مدل‌سازی همزمان دارو و هدف پروتئینی است.

بر اساس مقاله، مدل شامل سه بخش اصلی است:

۱. VAE مربوط به دارو؛

۲. VAE مربوط به هدف؛

۳. بخش هم‌منظم‌سازی برای مدل‌سازی میل اتصال [۴].

به صورت مفهومی:

$$\text{Drug} \rightarrow \text{VAE}_d \rightarrow z_d, \quad \text{Target} \rightarrow \text{VAE}_t \rightarrow z_t \quad (۱۶-۲)$$

سپس اطلاعات مربوط به دو فضای نهفته در بخش هم‌منظم‌سازی برای پیش‌بینی میل اتصال استفاده می‌شوند.

۲-۲۳ ایده هم‌منظم‌سازی

یکی از تفاوت‌های اصلی Co-VAE با یک VAE ساده این است که هدف تنها بازسازی جداگانه دارو و پروتئین نیست.

در مسئله DTA، اطلاعات مربوط به دارو و پروتئین باید به گونه‌ای مدل شوند که رابطه میان آن‌ها نیز قابل استفاده باشد.

بنابراین Co-VAE تلاش می‌کند اطلاعات مربوط به دارو، هدف و میل اتصال را به صورت مشترک مدل کند:

$$\text{Drug}, \quad \text{Target}, \quad \text{Affinity} \quad (۱۷-۲)$$

نویسندگان Co-VAE بیان می‌کنند که مدل آن‌ها را می‌توان از دیدگاه نظری به صورت پیشینه‌سازی یک کران پایین^{۱۸} برای درست‌نمایی^{۱۹} مشترک دارو، پروتئین و میل اتصال تفسیر کرد [۴]. این ویژگی یکی از تفاوت‌های مهم Co-VAE با یک VAE مستقل برای هر نوع داده است.

۲-۲۴ کاربرد Co-VAE در DTA

Co-VAE برای دو هدف اصلی طراحی شده است:

۱. پیش‌بینی میل اتصال دارو-هدف؛
 ۲. تولید داروهای جدیدی که ویژگی‌های مشابهی با داروهای دارای هدف مشابه داشته باشند [۴].
- در این پایان‌نامه، هدف اصلی بررسی بخش نخست یعنی پیش‌بینی میل اتصال است. مقاله Co-VAE عملکرد مدل را روی دو مجموعه داده ارزیابی کرده و آن را با روش‌هایی از جمله DeepDTA و DeepAffinity مقایسه کرده است [۴].
- بنابراین Co-VAE را می‌توان یکی از روش‌های مهم مبتنی بر VAE در حوزه DTA دانست.

¹⁸Lower Bound

¹⁹Likelihood

۲-۲۵ مدل DCGAN-DTA

DCGAN-DTA در سال ۲۰۲۴ توسط Kalemati Emani، Zamani Emani و Koohi ارائه شد [۲]. این روش با هدف استفاده از شبکه‌های مولد تخصصی کانولوشنی عمیق برای یادگیری نمایش دارو و پروتئین در مسئله DTA طراحی شده است. معماری DCGAN-DTA بر اساس مقاله از چهار مرحله اصلی تشکیل می‌شود:

۱. کدگذاری و تعبیه‌سازی؛

۲. استخراج ویژگی با DCGAN و CNN؛

۳. ادغام نمایش‌های نهفته؛

۴. پیش‌بینی میل اتصال [۲].

۲-۲۶ مرحله کدگذاری و تعبیه‌سازی در DCGAN-DTA

در مرحله اول، SMILES دارو و توالی پروتئین به شکل عددی تبدیل می‌شوند. برای این منظور، نویسندگان از کدگذاری برچسبی^{۲۰} استفاده می‌کنند. سپس نمایش حاصل وارد لایه تعبیه‌سازی^{۲۱} می‌شود. برای پروتئین، علاوه بر کدگذاری معمولی، کدگذاری BLOSUM نیز مورد استفاده قرار می‌گیرد تا ویژگی‌های تکاملی توالی نیز در مدل لحاظ شوند [۲]. بنابراین ورودی مدل تنها یک نمایش ساده از کاراکترهای توالی نیست، بلکه اطلاعات BLOSUM نیز در مسیر پردازش پروتئین قرار می‌گیرد.

۲-۲۷ استخراج ویژگی در DCGAN-DTA

پس از کدگذاری و تعبیه‌سازی، DCGAN-DTA از شبکه‌های مولد تخصصی کانولوشنی برای استخراج نمایش استفاده می‌کند.

²⁰Label Encoding

²¹Embedding Layer

برای دارو و پروتئین، شبکه‌های DCGAN به صورت جداگانه مورد استفاده قرار می‌گیرند. در این فرایند، مولد تلاش می‌کند نمونه‌هایی از داده‌های توالی ایجاد کند و تشخیص دهنده تلاش می‌کند نمونه‌های واقعی را از نمونه‌های تولیدشده تشخیص دهد [۲].

بر اساس مقاله، مولد شامل سه لایه کانولوشن ترانهاده^{۲۲} و تشخیص دهنده شامل پنج لایه CNN است [۲]. نویسندگان معماری DCGAN-DTA را برای داده‌های توالی سفارشی کرده‌اند و آن را دقیقاً معادل DCGAN استاندارد مورد استفاده در تصاویر نمی‌دانند.

۲-۲۸ ادغام نمایش‌های نهفته

پس از استخراج نمایش دارو و پروتئین، این دو نمایش باید برای پیش‌بینی میل اتصال با یکدیگر ترکیب شوند. در بسیاری از معماری‌های DTA، نمایش‌ها با عملیات به‌هم‌چسبانی^{۲۳} به یکدیگر متصل می‌شوند. DCGAN-DTA از یک لایه جمع^{۲۴} برای ترکیب بردارهای نهفته استفاده می‌کند [۲]. به صورت ساده می‌توان این عملیات را به شکل زیر نمایش داد:

$$z = z_d + z_t \quad (۱۸-۲)$$

سپس بردار حاصل به بخش پیش‌بینی منتقل می‌شود. نویسندگان این انتخاب را یکی از اجزای طراحی مدل خود معرفی می‌کنند.

۲-۲۹ بخش پیش‌بینی DCGAN-DTA

پس از ترکیب نمایش دارو و پروتئین، بردار حاصل وارد یک بلوک تمام‌متصل^{۲۵} می‌شود. این بخش وظیفه تبدیل نمایش مشترک به مقدار نهایی میل اتصال را بر عهده دارد. در معماری گزارش‌شده، این بخش شامل سه لایه تمام‌متصل است [۲]. در نهایت مدل یک مقدار پیوسته به عنوان پیش‌بینی میل اتصال تولید می‌کند:

$$\hat{y} = f(z_d + z_t) \quad (۱۹-۲)$$

^{۲۲}Convolutional Transpose

^{۲۳}Concatenation

^{۲۴}Add Layer

^{۲۵}Fully Connected Block

بنابراین جریان کلی DCGAN-DTA را می‌توان به شکل زیر خلاصه کرد:

$$\text{SMILES} \rightarrow \text{Encoding} \rightarrow \text{Embedding} \rightarrow \text{DCGAN/CNN} \rightarrow z_d \quad (20-2)$$

$$\text{Protein} \rightarrow \text{Encoding} + \text{BLOSUM} \rightarrow \text{Embedding} \rightarrow \text{DCGAN/CNN} \rightarrow z_t$$

و سپس:

$$z_d + z_t \rightarrow \text{FC} \rightarrow \hat{y} \quad (21-2)$$

۳۰-۲ داده‌های مورد استفاده در مطالعات DTA

مجموعه داده نقش بسیار مهمی در ارزیابی مدل‌های DTA دارد.

دو مجموعه داده مهم که در مطالعات این حوزه به صورت گسترده مورد استفاده قرار گرفته‌اند عبارت‌اند از:

• Davis؛

• KIBA.

DeepDTA از هر دو مجموعه برای ارزیابی استفاده کرد [۸] و GraphDTA نیز از آن‌ها برای مقایسه مدل‌های گرافی استفاده کرد [۷].

در مطالعات جدیدتر، مجموعه داده‌هایی مانند BindingDB و PDBbind نیز مورد استفاده قرار گرفته‌اند.

۳۱-۲ مجموعه داده Davis

مجموعه داده Davis مربوط به تعامل داروها و کینازهای پروتئینی است.

این مجموعه یکی از محک‌های^{۲۶} شناخته‌شده در مطالعات DTA محسوب می‌شود و DeepDTA و GraphDTA از آن برای ارزیابی مدل‌های خود استفاده کرده‌اند [۷، ۸].

ویژگی مهم این مجموعه آن است که مقادیر میل اتصال برای زوج‌های دارو-پروتئین در آن موجود است و می‌توان مسئله را به صورت رگرسیون تعریف کرد.

²⁶Benchmark

۳۲-۲ مجموعه داده KIBA

KIBA یکی دیگر از مجموعه داده‌های مهم DTA است که اطلاعات مربوط به فعالیت زیستی^{۲۷} داروها و اهداف پروتئینی را شامل می‌شود.

DeepDTA از نسخه KIBA برای ارزیابی مدل استفاده کرد و گزارش کرد که عملکرد مدل در این مجموعه بزرگ‌تر نسبت به Davis به بهبود قابل توجهی داشته است [۸].

KIBA بعدها در بسیاری از مطالعات DTA به عنوان محک مورد استفاده قرار گرفت.

۳۳-۲ مجموعه داده BindingDB

BindingDB یک پایگاه داده عمومی برای اطلاعات تجربی مربوط به برهم‌کنش میان پروتئین‌ها و لیگاندها است [۵].

DCGAN-DTA از نسخه به‌روزشده BindingDB استفاده کرده و مشخصاً نسخه مبتنی بر K_d را برای ارزیابی انتخاب کرده است [۲].

طبق مقاله DCGAN-DTA، پس از مراحل پالایش داده، مجموعه مورد استفاده شامل:

- ۹۸۶۴ مولکول کوچک؛

- ۱۰۸۸ هدف پروتئینی؛

بوده و مقادیر میل اتصال به صورت لگاریتمی pK_d تبدیل شده‌اند [۲].

۳۴-۲ مجموعه داده PDBbind

PDBbind مجموعه‌ای از داده‌های مربوط به کمپلکس‌های پروتئین-لیگاند با ساختار سه‌بعدی شناخته‌شده و اطلاعات میل اتصال است [۱۱].

DCGAN-DTA از نسخه پالایش‌شده^{۲۸} مجموعه PDBbind 2020 استفاده کرده است [۲].

پس از پالایش داده‌ها، مجموعه مورد استفاده در مقاله DCGAN-DTA شامل:

- ۴۲۳۱ ترکیب؛

²⁷Bioactivity

²⁸Refined Set

• ۱۶۰۶ توالی پروتئینی؛

گزارش شده است [۲].

وجود ساختارهای سه‌بعدی در PDBbind باعث می‌شود این مجموعه از نظر اطلاعات ساختاری با مجموعه‌هایی مانند BindingDB تفاوت داشته باشد.

۳۵-۲ روش‌های تقسیم داده

نحوه تقسیم داده یکی از عوامل مهم در ارزیابی مدل‌های DTA است. اگر نمونه‌های آموزش و آزمون از نظر داروها و پروتئین‌ها بسیار مشابه باشند، مدل ممکن است مسئله ساده‌تری برای تعمیم داشته باشد. به همین دلیل، مطالعات DTA از روش‌های مختلف تقسیم داده استفاده می‌کنند. دو مفهوم مهم عبارت‌اند از:

شروع گرم

در این حالت، داروها و پروتئین‌های موجود در آزمون می‌توانند نمونه‌هایی مشابه یا مرتبط در مجموعه آموزش داشته باشند.

شروع سرد

در این حالت، هدف بررسی توانایی مدل در مواجهه با داروها یا پروتئین‌هایی است که در آموزش حضور نداشته‌اند. DCGAN-DTA علاوه بر شروع گرم، از تقسیم‌بندی شروع سرد مبتنی بر ویژگی‌های فیزیکوشیمیایی ترکیبات نیز استفاده می‌کند [۲].

۳۶-۲ معیارهای ارزیابی

برای ارزیابی مدل‌های DTA نمی‌توان تنها به یک معیار اکتفا کرد. سه معیار مهم که در مطالعات DTA مورد استفاده قرار می‌گیرند عبارت‌اند از:

• میانگین مربعات خطا؛

- شاخص سازگاری؛
- مساحت زیر منحنی دقت-فراخوانی.

۲-۳۶-۱ میانگین مربعات خطا

میانگین مربعات خطا یا MSE میانگین مربع اختلاف میان مقدار واقعی و پیش‌بینی شده است:

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (22-2)$$

هرچه مقدار MSE کمتر باشد، مقدار خطای عددی مدل کمتر است.

DeepDTA نیز از MSE در کنار CI برای ارزیابی عملکرد استفاده کرده است [۸].

۲-۳۶-۲ شاخص سازگاری

شاخص سازگاری یا CI یکی از معیارهای مهم برای ارزیابی مدل‌های پیش‌بینی میل اتصال است.

این معیار بررسی می‌کند که آیا ترتیب پیش‌بینی‌های مدل با ترتیب واقعی نمونه‌ها سازگار است یا خیر. به صورت مفهومی، اگر $y_i > y_j$ باشد، مدل نیز باید مقدار متناظر با i را بزرگ‌تر از مقدار مربوط به j پیش‌بینی کند.

در نتیجه، CI بیشتر بر توانایی مدل در حفظ ترتیب نسبی میل اتصال تمرکز دارد.

DeepDTA و GraphDTA هر دو از CI به عنوان معیار اصلی ارزیابی استفاده کرده‌اند [۷، ۸].

۲-۳۶-۳ مساحت زیر منحنی دقت-فراخوانی

AUPR^{۲۹} معیار دیگری است که در برخی مطالعات DTA برای بررسی عملکرد مدل استفاده می‌شود.

دقت^{۳۰} و فراخوانی^{۳۱} را می‌توان به شکل زیر تعریف کرد:

$$Precision = \frac{TP}{TP + FP}, \quad Recall = \frac{TP}{TP + FN} \quad (23-2)$$

AUPR مساحت زیر منحنی دقت-فراخوانی است.

DCGAN-DTA نیز CI، AUPR و MSE را در ارزیابی‌های خود گزارش می‌کند [۲].

²⁹Area Under the Precision-Recall Curve

³⁰Precision

³¹Recall

۳۷-۲ مقایسه کلی مدل‌های مورد بررسی

با توجه به مطالب این فصل، می‌توان مسیر تکامل روش‌های مورد استفاده در این پژوهش را به صورت زیر خلاصه کرد:

Traditional Methods → DeepDTA → GraphDTA → Generative Models (۲۴-۲)

DeepDTA استفاده از CNN را برای یادگیری نمایش دارو و پروتئین از داده‌های توالی مطرح کرد [۸]. GraphDTA تلاش کرد نمایش دارو را از یک رشته به یک گراف مولکولی تغییر دهد و از GNN استفاده کند [۷].

در ادامه، مدل‌هایی مانند Co-VAE و DCGAN-DTA از مدل‌های مولد برای یادگیری نمایش و پیش‌بینی میل اتصال استفاده کردند [۴، ۲]. این دو مدل از یک خانواده یکسان نیستند:

Co-VAE → VAE , DCGAN-DTA → GAN (۲۵-۲)

بنابراین مقایسه این دو مدل می‌تواند از دیدگاه تفاوت دو رویکرد مولد نیز مورد توجه قرار گیرد.

۳۸-۲ مقایسه Co-VAE و DCGAN-DTA

جدول ۲-۲ مقایسه‌ای میان دو مدل اصلی این پژوهش ارائه می‌دهد. این جدول نشان می‌دهد که تفاوت اصلی این دو روش صرفاً در نام معماری نیست؛ بلکه در نحوه یادگیری نمایش دارو و پروتئین نیز تفاوت دارند.

۳۹-۲ جایگاه پژوهش حاضر

مطالعات پیشین نشان داده‌اند که یادگیری عمیق می‌تواند برای پیش‌بینی میل اتصال مؤثر باشد. DeepDTA نشان داد که می‌توان از توالی خام دارو و پروتئین برای یادگیری نمایش استفاده کرد [۸]. GraphDTA نشان داد که نمایش گرافی دارو نیز می‌تواند در بهبود مدل‌سازی ساختار مولکولی مؤثر باشد [۷].

جدول ۲-۲: مقایسه DCGAN-DTA و Co-VAE

ویژگی	Co-VAE	DCGAN-DTA
خانواده مدل	VAE	GAN
هدف اصلی	DTA و تولید دارو	DTA
نمایش دارو	SMILES	SMILES
نمایش پروتئین	توالی	توالی + BLOSUM
یادگیری مولد	رمزگذار/رمزگشا	مولد/تشخیص دهنده
فضای نهفته	احتمالاتی	نمایش نهفته
روش ترکیب	هم‌منظم‌سازی	لایه جمع
استفاده از داده بدون برچسب	بخشی از چارچوب مدل	بخش مهم روش یادگیری نمایش
ارزیابی اصلی	محک‌های DTA	PDBbind و BindingDB
ارزیابی شروع سرد	مطابق طراحی مطالعه Co-VAE	بله، در مقاله DCGAN-DTA
معیارها	معیارهای DTA گزارش شده در مقاله	MSE، AUPR، CI

Co-VAE رویکرد VAE را وارد مسئله DTA کرد و دو VAE را برای مدل‌سازی دارو و هدف و یک بخش هم‌منظم‌سازی برای میل اتصال به کار گرفت [۴].

DCGAN-DTA نیز رویکرد مبتنی بر GAN را برای یادگیری نمایش دارو و پروتئین ارائه کرد و آن را با روش‌های مختلف و تحت چند روش تقسیم داده ارزیابی نمود [۲].

با وجود این مطالعات، مقایسه مستقیم این دو مدل به عنوان نماینده دو خانواده متفاوت از مدل‌های مولد نیازمند طراحی یک چارچوب ارزیابی مشخص است.

بنابراین، پژوهش حاضر به جای معرفی معماری مولد جدید، بر یک مطالعه مقایسه‌ای کنترل‌شده تمرکز می‌کند.

در این مقایسه، موارد زیر اهمیت دارند:

۱. عملکرد پیش‌بینی؛

۲. معیارهای مختلف ارزیابی؛

۳. شرایط تقسیم داده؛

۴. پایداری نتایج؛

۵. هزینه محاسباتی؛

۶. زمان آموزش؛

۷. رفتار مدل در شرایط مختلف داده.

۲-۴۰ جمع بندی فصل

در این فصل، مبانی نظری لازم برای بررسی مسئله پیش بینی میل اتصال دارو-هدف ارائه شد.

ابتدا تفاوت میان برهم کنش دارو-هدف و پیش بینی میل اتصال دارو-هدف بررسی شد و مشخص شد که مسئله DTA یک مسئله رگرسیونی است که هدف آن پیش بینی مقدار پیوسته ای از قدرت اتصال میان دارو و پروتئین است. سپس نمایش های مختلف دارو و پروتئین مورد بررسی قرار گرفتند. SMILES به عنوان یک نمایش رشته ای از ساختار مولکولی، توالی اسیدهای آمینه به عنوان نمایش پروتئین و نمایش گرافی به عنوان روشی برای مدل سازی مستقیم ساختار مولکولی معرفی شدند.

در ادامه، مسیر توسعه مدل های یادگیری عمیق در DTA با بررسی DeepDTA و GraphDTA توضیح داده شد. DeepDTA از CNN برای یادگیری نمایش دارو و پروتئین استفاده می کند، در حالی که GraphDTA دارو را به صورت گراف مولکولی مدل می کند.

سپس مدل های مولد مورد نیاز برای پژوهش بررسی شدند. در بخش GAN، مفاهیم مولد، تشخیص دهنده و فرآیند آموزش تخصصی توضیح داده شد. سپس DCGAN به عنوان نسخه کانولوشنی GAN معرفی شد. در بخش VAE نیز رمزگذار، رمزگشا، فضای نهفته، ترفند بازپارامتری سازی و تابع هدف VAE بررسی شدند. در نهایت، دو مدل اصلی پژوهش یعنی Co-VAE و DCGAN-DTA معرفی شدند. Co-VAE از دو VAE و یک بخش هم منظم سازی برای مدل سازی مشترک دارو، پروتئین و میل اتصال استفاده می کند، در حالی که DCGAN-DTA از DCGAN های سفارشی شده، کدگذاری BLOSUM و لایه جمع برای یادگیری نمایش و پیش بینی میل اتصال استفاده می کند.

بر اساس این مبانی، فصل بعدی به روش پژوهش اختصاص خواهد داشت. در فصل سوم، مجموعه داده های مورد استفاده، مراحل پیش پردازش، نحوه اجرای مدل های DCGAN-DTA و Co-VAE، روش تقسیم داده، معیارهای ارزیابی و پروتکل مقایسه تجربی به صورت دقیق تشریح خواهند شد.

کتابنامه

- [1] GOODFELLOW, I. J., POUGET-ABADIE, J., MIRZA, M., XU, B., WARDE-FARLEY, D., OZAIR, S., COURVILLE, A., AND BENGIO, Y. Generative adversarial nets. in *Advances in Neural Information Processing Systems (NeurIPS)* (2014), volume 27.
- [2] KALEMATI, M., EMANI, M. Z., AND KOOHI, S. DCGAN-DTA: Predicting drug-target binding affinity with deep convolutional generative adversarial networks. *BMC Genomics* 25 (2024), 411.
- [3] KINGMA, D. P., AND WELLING, M. Auto-encoding variational bayes. in *International Conference on Learning Representations (ICLR)* (2014).
- [4] LI, T., ZHAO, X.-M., AND LI, L. Co-VAE: Drug-target binding affinity prediction by co-regularized variational autoencoders. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 44, 12 (2022), 8861–8873.
- [5] LIU, T., LIN, Y., WEN, X., JORISSEN, R. N., AND GILSON, M. K. BindingDB: a web-accessible database of experimentally determined protein-ligand binding affinities. *Nucleic Acids Research* 35, suppl. 1 (2007), D198–D201.
- [6] MAYR, A., KLAMBAUER, G., UNTERTHINER, T., AND HOCHREITER, S. DeepTox: toxicity prediction using deep learning. *Frontiers in Environmental Science* (2016).
- [7] NGUYEN, T., LE, H., QUINN, T. P., NGUYEN, T., LE, T. D., AND VENKATESH, S. GraphDTA: predicting drug–target binding affinity with graph neural networks. *Bioinformatics* 37, 8 (2021), 1140–1147.
- [8] ÖZTÜRK, H., ÖZGÜR, A., AND OZKIRIMLI, E. DeepDTA: deep drug–target binding affinity prediction. *Bioinformatics* 34, 17 (2018), i821–i829.
- [9] ÖZTÜRK, H., OZKIRIMLI, E., AND ÖZGÜR, A. WideDTA: prediction of drug-target binding affinity with deep learning. *Bioinformatics* 35, 4 (2019), 575–582.
- [10] RADFORD, A., METZ, L., AND CHINTALA, S. Unsupervised representation learning with deep convolutional generative adversarial networks. in *International Conference on Learning Representations (ICLR)* (2016).
- [11] WANG, R., FANG, X., LU, Y., AND WANG, S. The PDBbind database: collection of binding affinities for protein-ligand complexes with known three-dimensional structures. *Journal of Medicinal Chemistry* 47, 12 (2004), 2977–2980.

Abstract

Drug–Target Binding Affinity (DTA) prediction is an important problem in computational drug discovery, aiming to quantitatively estimate the binding strength between a drug compound and a target protein. The high cost and time requirements of experimental approaches, together with the large space of potential compounds and biological targets, have motivated the use of machine learning and deep learning methods as complementary approaches to this problem. This thesis investigates deep learning methods for drug–target binding affinity prediction, with a particular focus on generative models and representation learning. In this context, the representation of drugs and proteins, model architectures, training procedures, and evaluation methods are studied. Two generative approaches based on Generative Adversarial Networks and Variational Autoencoders are analyzed and compared through the DCGAN-DTA and Co-VAE models, respectively. A main objective of this study is to systematically examine the reproducibility and fair comparability of these approaches. To this end, data preprocessing, dataset splitting, model architectures, training parameters, and evaluation procedures are carefully investigated and documented. The models are also evaluated and compared on commonly used DTA benchmark datasets, including Davis and KIBA. Finally, the strengths and limitations of the investigated approaches are analyzed in terms of representation quality, predictive performance, training complexity, and reproducibility, providing a basis for the development of more effective methods for drug–target binding affinity prediction.

Keywords : Drug–Target Binding Affinity Prediction, Deep Learning, Generative Learning, Generative Adversarial Network, Variational Autoencoder



University of Tehran
College of Engineering
Faculty of Engineering Science



A Comparative Study of Adversarial Autoencoders and Variation-al Autoencoders for Drug-Drug and Drug-Protein Interaction Pre-diction

A thesis submitted to the Graduate Studies Office

In partial fulfillment of the requirements for

The degree of master in

Algorithms and Computation

By:

Mohsen Kashefikia

Supervisor:

Dr. Sayeh Mirzaei

September 2026