

دانشکده فنی



دانشگاه تهران

دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده علوم مهندسی
گروه الگوریتم‌ها و محاسبات

مطالعه مقایسه‌ای خودرمزگذارهای تقابلی و خودرمزگذارهای متغیر در پیش‌بینی فعل و انفعالات
دارو-دارو و دارو-پروتئین

پایان‌نامه یا رساله برای دریافت درجه کارشناسی ارشد
در رشته مهندسی کامپیوتر - گرایش الگوریتم‌ها و محاسبات

محسن کاشفی کیا

استاد راهنما:

دکتر سایه میرزایی

شهریور ماه ۱۴۰۵

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ



دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده مهندسی

گواهی دفاع از پایان‌نامه کارشناسی ارشد

هیأت داوران پایان‌نامه کارشناسی ارشد آقای / خانم به شماره
دانشجویی در رشته گرایش را در تاریخ
عنوان
.....

به عدد	به حروف
با نمره نهایی	
و درجه	ارزیابی
	کرد.

ردیف	مشخصات هیأت داوران	نام و نام خانوادگی	مرتبه دانشگاهی	دانشگاه یا مؤسسه	اعضاء
۱	استاد راهنما استاد راهنمای دوم (حسب مورد)				
۲	استاد مشاور				
۳	استاد داور داخلی				
۴	استاد مدعو				
۵	نماینده کمیته تحصیلات تکمیلی دانشکده / گروه				

نام و نام خانوادگی معاون آموزشی و تحصیلات تکمیلی
پردیس دانشکده‌های فنی:
تاریخ و امضاء:

نام و نام خانوادگی معاون تحصیلات تکمیلی و
پژوهشی دانشکده / گروه:
تاریخ و امضاء:

تعهدنامه اصالت اثر

باسمه تعالی

اینجانب **محسن کاشفی کیا** تأیید می‌کنم که مطالب مندرج در این پایان‌نامه حاصل کار پژوهشی اینجانب است و به دستاوردهای پژوهشی دیگران که در این نوشته از آنها استفاده شده است مطابق مقررات ارجاع گردیده است. این پایان‌نامه قبلاً برای احراز هیچ مدرک هم سطح یا بالاتر ارائه نشده است. کلیه حقوق مادی و معنوی این اثر متعلق به دانشکده فنی دانشگاه تهران می‌باشد.

تقديم به يار مهربانم

تشکر و قدردانی

– با تشکر و سپاس از استاد دانشمند و پر مایه ام جناب سرکار خانم سایه میرزایی که از محضر

پر فیض تدریستان ، بهره ها برده ام.

– با امتنان بیکران از مساعدت های بی شائبه ی جناب سرکار خانم نگین باقرپور ریاست

محترم دانشکده

چکیده

پیش‌بینی میل اتصال دارو به هدف (Drug-Target Affinity Binding Prediction) یکی از مسائل مهم در کشف و توسعه محاسباتی دارو است که هدف آن تخمین کمی قدرت اتصال میان یک ترکیب دارویی و پروتئین هدف است. هزینه و زمان بالای روش‌های آزمایشگاهی و گستردگی فضای ترکیبات و اهداف زیستی، استفاده از روش‌های یادگیری ماشین و یادگیری عمیق را به‌عنوان رویکردی مکمل برای این مسئله ضروری ساخته است.

در این پژوهش، روش‌های یادگیری عمیق برای پیش‌بینی میل اتصال دارو-هدف با تمرکز بر مدل‌های مولد و یادگیری بازنمایی بررسی می‌شوند. در این راستا، نحوه بازنمایی داروها و پروتئین‌ها، معماری مدل‌ها، فرایند آموزش و روش‌های ارزیابی مورد مطالعه قرار گرفته و دو رویکرد مبتنی بر شبکه‌های مولد تخصصی و خودرمزگذارهای واریاسیونی، به‌ترتیب در قالب مدل‌های DCGAN-DTA و Co-VAE مورد تحلیل و مقایسه قرار می‌گیرند.

یکی از اهداف اصلی پژوهش، بررسی دقیق بازتولیدپذیری و مقایسه منصفانه این روش‌ها است. به این منظور، مراحل پیش‌پردازش داده، تقسیم مجموعه داده، معماری شبکه، پارامترهای آموزش و معیارهای ارزیابی به‌صورت نظام‌مند بررسی و مستندسازی می‌شوند. همچنین عملکرد مدل‌ها بر روی مجموعه داده‌های رایج در پیش‌بینی میل اتصال، از جمله Davis و KIBA ارزیابی و مقایسه خواهد شد. در نهایت، نقاط قوت و محدودیت‌های روش‌های مورد بررسی از نظر کیفیت بازنمایی، عملکرد پیش‌بینی، پیچیدگی آموزش و بازتولیدپذیری تحلیل شده و مبنایی برای توسعه روش‌های مؤثرتر در پیش‌بینی میل اتصال دارو-هدف ارائه می‌شود.

کلمات کلیدی : پیش‌بینی میل اتصال دارو-هدف، یادگیری عمیق، یادگیری مولد، شبکه مولد تخصصی، خودرمزگذار واریاسیونی

فهرست مطالب

۱۶	۱ کلیات پژوهش
۱۶	۱-۱ مقدمه
۱۷	۲-۱ بیان مسئله
۱۸	۳-۱ تعریف موضوع و کمیت خروجی پژوهش
۱۸	۱-۳-۱ DDI و DTA DTI، مرز
۱۸	۲-۳-۱ تعریف محاسباتی مسئله
۱۸	۳-۳-۱ بازنمایی و روش ترکیبی مورد نظر
۱۹	۴-۱ اهمیت و ضرورت پژوهش
۱۹	۵-۱ هدف اصلی و اهداف فرعی
۲۰	۶-۱ پرسش‌های پژوهش
۲۱	۷-۱ سهم پیشنهادی و شکاف پژوهشی
۲۱	۸-۱ دامنه، فرض‌ها و وضعیت روش پیشنهادی
۲۲	۹-۱ چارچوب ارزیابی پژوهش
۲۲	۱۰-۱ ساختار پایان‌نامه
۲۳	۲ مبانی نظری و پیشینه پژوهش
۲۳	۱-۲ مقدمه
۲۳	۲-۲ مبانی زیستی و معنای میل اتصال
۲۳	۱-۲-۲ دارو، هدف و اتصال
۲۴	۲-۲-۲ تفاوت ثابت‌های اتصال و کمیت‌های مهار

۲۵	۲-۲-۳ واحد و تبدیل لگاریتمی
۲۵	۳-۲ داده‌های DTA و شرایط تعمیم
۲۵	۲-۳-۱ منشأ داده و نسخه آماده شده
۲۶	۲-۳-۲ زوج جدید و موجودیت جدید
۲۶	۲-۳-۳ اعتبارسنجی و مقایسه
۲۷	۴-۲ نمایش دارو و پروتئین
۲۷	۲-۴-۱ رشته SMILES و نمایش گرافی دارو
۲۷	۲-۴-۲ توالی پروتئین، تعبیه و کانولوشن
۲۷	۲-۴-۳ ورودی خام، ویژگی میانی و پیش‌بینی
۲۸	۵-۲ از روش‌های مبتنی بر شباهت تا یادگیری عمیق
۲۸	۲-۵-۱ کرنل و فاکتورگیری ماتریس
۲۸	۲-۵-۲ ویژگی‌های مهندسی شده و SimBoost
۲۸	۲-۵-۳ DeepDTA
۲۹	۲-۵-۴ WideDTA و GraphDTA
۲۹	۲-۵-۵ جمع‌بندی مسیر روش‌ها
۳۰	۶-۲ یادگیری تخصصی و DCGAN
۳۰	۲-۶-۱ انگیزه و منطق GAN
۳۱	۲-۶-۲ هدف و آموزش متناوب
۳۱	۲-۶-۳ از GAN به DCGAN
۳۳	۷-۲ خودرمزگذار واریاسیونی و بازنمایی نهان
۳۳	۲-۷-۱ از بازسازی به مدل احتمالاتی
۳۴	۲-۷-۲ کران پایین شواهد
۳۴	۲-۷-۳ بازپارامتردهی و نقش نمادها
۳۵	۸-۲ معماری و روش DCGAN-DTA
۳۵	۲-۸-۱ مسیر چهارمرحله‌ای پیش‌بینی
۳۵	۲-۸-۲ پیش‌آموزش تخصصی و استخراج ویژگی

۳۵	۲-۸-۳ ادغام و خروجی رگرسیون
۳۷	۲-۸-۴ دامنه نتایج منتشرشده
۴۱	۲-۹-۹ معماری و هدف یادگیری Co-VAE
۴۱	۲-۹-۱ دو مسیر واریاسیونی و یک پیش‌بینی مشترک
۴۲	۲-۹-۲ کران مشترک و تابع هدف
۴۳	۲-۹-۳ آزمون موجودیت جدید و حدود نتایج
۴۶	۲-۱۰-۱۰ معیارهای ارزیابی پیش‌بینی اتصال
۴۶	۲-۱۰-۱۰-۲ اکمیت ارزیابی و قرارداد نمادها
۴۶	۲-۱۰-۲-۱ خطای مربعی، خطای مطلق و RMSE
۴۷	۲-۱۰-۲-۳ تشخیص توافق رتبه‌ای
۴۸	۲-۱۰-۲-۴ معیار r_m^2
۴۹	۲-۱۰-۲-۵ AUPR و معیارهای طبقه‌بندی مکمل
۵۰	۲-۱۰-۲-۶ معیارهای موجود در اجرای پروژه
۵۱	۲-۱۱-۱ مقایسه مفهومی و مبنای ترکیب بازنمایی‌ها
۵۱	۲-۱۱-۲ تفاوت هدف‌ها و محل ترکیب
۵۱	۲-۱۱-۲-۱ معنای محدب بودن در مسئله وزن
۵۲	۲-۱۲ جمع‌بندی پیشینه و پیوند با پژوهش

فصل ۱

کلیات پژوهش

۱-۱ مقدمه

مطالعه اتصال یک مولکول کوچک به پروتئین، بخشی از شناخت رابطه میان ساختار شیمیایی و فعالیت زیستی است. در پژوهش دارویی، صرف دانستن اینکه یک زوج دارو-هدف می‌تواند تعامل داشته باشد، برای مقایسه همه نامزدها کافی نیست؛ شدت اتصال نیز اهمیت دارد. پیش‌بینی میل اتصال دارو-هدف، با اختصار، DTA این پرسش کمی را مطرح می‌کند که از اطلاعات دارو و پروتئین چگونه می‌توان مقدار یک شاخص تجربی اتصال را برآورد کرد. مقاله DeepDTA این مسئله را به‌صورت یادگیری یک خروجی پیوسته از نمایش‌های توالی‌محور دارو و پروتئین دنبال می‌کند [۱۵].

مدل محاسباتی در این چارچوب جایگزین اندازه‌گیری زیستی نیست، بلکه می‌تواند برآوردی برای رتبه‌بندی زوج‌ها و انتخاب موارد مناسب بررسی فراهم کند. اعتبار این برآورد به منشأ برجسب، نمایش ورودی و شرایط آزمون وابسته است. برای مثال، آزمودن یک زوج تازه میان داروها و اهداف دیده‌شده با پیش‌بینی برای داروی کاملاً جدید یک پرسش تعمیم واحد نیست [۱۷]. از این رو، مسئله DTA هم به یادگیری نگاشت ورودی به خروجی مربوط است و هم به تعریف درست شرایطی که قرار است آن نگاشت در آن‌ها به کار رود.

یک تصمیم اساسی در این یادگیری، ساخت بازنمایی است: دارو و پروتئین باید به ویژگی‌هایی عددی تبدیل شوند که اطلاعات مناسب پیش‌بینی را حفظ کنند. روش‌های عمیق این تبدیل را همراه با آموزش شبکه می‌آموزند. در میان آن‌ها، مدل‌های مولد امکان استفاده از هدف‌هایی فراتر از خطای مستقیم رگرسیون را فراهم می‌کنند. آموزش تخصصی و یادگیری واریاسیونی دو مبنای متفاوت برای این کار هستند [۶، ۱۰].

این پایان‌نامه بر DCGAN-DTA و Co-VAE تمرکز دارد. مدل نخست از بازنمایی‌های حاصل از آموزش تخصصی کانونلوشنی در پیش‌بینی اتصال بهره می‌گیرد؛ مدل دوم بازسازی دارو و پروتئین را با یک مؤلفه پیش‌بینی

مشترک در چارچوب دو خودرمزگذار واریاسیونی پیوند می‌دهد [۹، ۱۱]. پرسش پژوهش آن است که آیا می‌توان بازنمایی‌های این دو مسیر را در یک روش مشخص ترکیب کرد و وزن ترکیب را با بهینه‌سازی تعیین نمود. این فصل مسئله و سهم پیشنهادی را تعریف می‌کند؛ مبانی نظری و شواهد روش‌ها در فصل ۲ آموزش داده می‌شوند.

۱-۲ بیان مسئله

ورودی‌های DTA ناهمگون‌اند. نمایش دارو اطلاعات ساختار مولکولی را بیان می‌کند، درحالی‌که نمایش پروتئین می‌تواند از توالی اسیدهای آمینه حاصل شود. مدل باید از این دو ورودی، اطلاعات مناسب رابطه اتصال را استخراج و به یک برجسب پیوسته مرتبط کند. مسئله تنها یافتن یک رگرسور پرفریت نیست: انتخاب نمایش و شیوه یادگیری آن تعیین می‌کند کدام اطلاعات به رگرسور می‌رسند. DeepDTA و GraphDTA با دو انتخاب متفاوت برای نمایش دارو، این نقش را در طراحی مدل نشان می‌دهند [۱۵، ۱۴].

مسئله دوم به برجسب مربوط است. «میل اتصال» نام یک مفهوم زیستی است، اما در داده‌ها با کمیت‌ها و مقیاس‌های مختلف بیان می‌شود. ثابت تفکیک، ثابت مهار و غلظت ایجادکننده مهار پنجاه درصدی تعریف‌های یکسانی ندارند. تبدیل واحد یا لگاریتم‌گیری نیز تفاوت معنای آن‌ها را از بین نمی‌برد [۸، ۱]. بنابراین، پیش‌بینی یک عدد بدون مشخص کردن کمیت و مقیاس آن، تعریف کامل مسئله محسوب نمی‌شود.

در این پژوهش، مسئله روش‌شناختی مشخص‌تر است: دو خانواده بازنمایی با هدف‌های یادگیری متفاوت در دسترس‌اند، اما معلوم نیست ترکیب آن‌ها چه اثری بر DTA خواهد داشت. تفاوت هدف‌های مولد به‌تنهایی اثبات مکمل بودن اطلاعات نیست. ممکن است ویژگی‌ها هم‌پوشان، دارای مقیاس ناسازگار یا برای یک سناریوی تعمیم مناسب‌تر باشند. بررسی ترکیب باید با تعریف محل استخراج ویژگی، سازگار کردن ابعاد و انتخاب رگرسور همراه شود.

مسئله تعیین وزن نیز باید از مقایسه ساده دو مدل جدا شود. اگر وزن صرفاً بر اساس نتیجه آزمون نهایی انتخاب شود، ارزیابی دیگر مستقل نخواهد بود. وزن باید در مرحله آموزش یا اعتبارسنجی تعیین شود و عملکرد روش روی بخشی سنجیده شود که در انتخاب وزن دخالت نکرده است. صورت دقیق تابع هدف و قیود، تعیین می‌کند آیا مسئله انتخاب وزن واقعاً محدب است؛ وجود یک وزن اسکالر این ویژگی را تضمین نمی‌کند [۲].

۳-۱ تعریف موضوع و کمیت خروجی پژوهش

۱-۳-۱ DDI و DTA، DTI، مرز

در پیش‌بینی دودویی تعامل دارو-هدف، با اختصار DTI، خروجی بیان می‌کند که زوج مورد نظر در تعریف داده تعامل دارد یا ندارد. NRLMF نمونه‌ای از مدل‌سازی احتمالی همین نوع خروجی است [۱۳]. در مقابل، DTA مقدار یک برچسب پیوسته اتصال را پیش‌بینی می‌کند. یک مدل می‌تواند ترتیب زوج‌ها را درست پیش‌بینی کند، اما در مقدار عددی خطا داشته باشد؛ این تفاوت در ارزیابی رگرسیون اهمیت دارد.

DTI گاهی به عنوان اصطلاحی عام برای مطالعه تعامل نیز به کار می‌رود. در این متن، عبارت «DTI» دودویی «مشخصاً به طبقه‌بندی وجود تعامل اشاره دارد و DTA برای مسئله رگرسیونی استفاده می‌شود. پیش‌بینی تعامل دارو-دارو یا DDI، به رابطه دو دارو مربوط است و در دامنه این پژوهش قرار ندارد.

۲-۳-۱ تعریف محاسباتی مسئله

برای بیان مسئله با نمادگذاری این پایان‌نامه، مجموعه مشاهده‌ها و پیش‌بینی مدل را به صورت

$$\mathcal{D} = \{(d_i, t_i, y_i)\}_{i=1}^n, \quad \hat{y}_i = f_{\theta}(d_i, t_i) \quad (1-1)$$

تعریف می‌کنیم. در این رابطه، d_i نمایش دارو، t_i نمایش هدف پروتئینی، y_i برچسب اندازه‌گیری شده یا آماده‌شده زوج i ، $\hat{y}_i$ پیش‌بینی و θ پارامترهای مدل است؛ n تعداد مشاهده‌هاست. این رابطه تعریف مسئله در این متن است و رونویسی تابع هدف یک مقاله نیست.

واحد و معنای y_i بخشی از تعریف داده‌اند. اگر برچسب pK_d باشد، مدل منفی لگاریتم ثابت تفکیک مولار را پیش‌بینی می‌کند؛ اگر برچسب امتیاز KIBA باشد، خروجی در مقیاس همان امتیاز تفسیر می‌شود. فرمول تبدیل و تفاوت این کمیت‌ها در بخش ۲-۲ آمده است. مقیاس لگاریتمی برای مقادیر مثبت تعریف می‌شود و جهت تفسیر آن با کمیت غلظتی اولیه معکوس است: pK_d بزرگ‌تر با K_d کوچک‌تر متناظر است [۱، ۱۵].

۳-۳-۱ بازنمایی و روش ترکیبی مورد نظر

در این پایان‌نامه، بازنمایی به ویژگی میانی استخراج شده از یک مدل اطلاق می‌شود؛ این ویژگی با ورودی خام، برچسب و خروجی نهایی رگرسیون تفاوت دارد. موضوع روش پیشنهادی، ترکیب بازنمایی‌های DCGAN-DTA و Co-VAE برای تشکیل ورودی بخش پیش‌بینی است. میانگین‌گیری از دو پیش‌بینی نهایی، یک روش مقایسه‌ای متفاوت خواهد بود و نباید جای تعریف ترکیب بازنمایی را بگیرد.

وزن ترکیب قرار است از یک مسئله بهینه‌سازی تعیین شود. مسیر مورد نظر، صورت‌بندی مسئله‌ای محدب است تا تعیین وزن بر مبنای تابع هدف و قیود روشن انجام گیرد. با این حال، تا انتخاب بازنمایی‌ها، رگرسیون و تابع هزینه، این ویژگی موضوع بررسی ریاضی است. صورت نهایی روش و شرایط محدب بودن در بخش ۱-۸ مشخص شده‌اند.

۴-۱ اهمیت و ضرورت پژوهش

اهمیت DTA در فراهم کردن یک خروجی کمی برای مطالعه و اولویت‌بندی زوج‌های دارو-هدف است. این خروجی اطلاعاتی فراتر از برچسب وجود تعامل ارائه می‌کند و امکان ارزیابی هم‌زمان خطای عددی و ترتیب پیش‌بینی را می‌دهد [۱۵]. ارزش کاربردی مدل به آن وابسته است که این اطلاعات در شرایط آزمونی متناسب با کاربرد به دست آمده باشد.

ضرورت روش‌شناختی پژوهش از سه موضوع ناشی می‌شود. نخست، یادگیری بازنمایی می‌تواند از هدف‌های متفاوتی هدایت شود و لازم است اثر آن‌ها در یک وظیفه ثابت بررسی شود. دوم، ترکیب ویژگی‌ها به سازگاری ابعاد، مقیاس و اطلاعات آن‌ها وابسته است؛ ادغام بدون تعریف این اجزا تفسیر نتیجه را دشوار می‌کند. سوم، نتیجه مقایسه به سناریوی تعمیم وابسته است. چارچوب ارزیابی واقع‌بینانه DTA میان آزمون زوج‌های جدید، داروی جدید و هدف جدید تمایز می‌گذارد [۱۷].

انتخاب GAN و VAE برای این مطالعه، فرصت بررسی دو منطق یادگیری را فراهم می‌کند: یکی ویژگی‌ها را از رقابت مولد و تمایزگر می‌آموزد و دیگری از مدل‌سازی احتمالاتی و بازسازی واریاسیونی بهره می‌گیرد [۶، ۱۰]. سود احتمالی ترکیب آن‌ها باید در آزمایش سنجیده شود. همچنین ارزیابی هزینه محاسباتی اهمیت دارد؛ افزایش پیچیدگی تنها هنگامی توجیه روش‌شناختی دارد که نسبت آن با کیفیت پیش‌بینی روشن باشد.

۵-۱ هدف اصلی و اهداف فرعی

هدف اصلی، طراحی و ارزیابی روشی برای ترکیب بازنمایی‌های DCGAN-DTA و Co-VAE در پیش‌بینی میل اتصال دارو-هدف و تعیین وزن ترکیب از یک مسئله بهینه‌سازی با بررسی شرایط محدب بودن است. این هدف، تدوین روش، تحلیل ریاضی و ارزیابی تجربی را در بر می‌گیرد.

اهداف فرعی در مسیر تحقق این هدف عبارت‌اند از:

۱. تبیین معماری، معنای بازنمایی و هدف آموزش دو مدل بر اساس مقاله‌های اصلی؛

۲. تعریف داده و برچسب مشترک و انتخاب سناریوهای آزمونی که مقایسه مدل‌ها را معتبر کنند؛
۳. تعیین لایه استخراج ویژگی و سازوکار سازگار کردن ابعاد و مقیاس دو بازنمایی؛
۴. مشخص کردن تابع هزینه، قیود وزن و پارامترهای ثابت در مرحله بهینه‌سازی؛
۵. مقایسه روش ترکیبی با مدل‌های پایه و ترکیب‌های ساده، همراه با بررسی نقش اجزا، حساسیت به وزن و هزینه اجرا.

این اهداف به ترتیب از شناخت منابع به تعریف روش و سپس ارزیابی می‌رسند. بازتولید نتیجه یک مقاله، بررسی اجرای محلی و آزمون مشترک پایان‌نامه سه فعالیت متمایزند؛ هرکدام باید با داده و پروتکل خودش مستند شود.

۱-۶ پرسش‌های پژوهش

پرسش اصلی این است: آیا ترکیب مشخص بازنمایی‌های آموخته‌شده با DCGAN-DTA و Co-VAE، با وزن تعیین شده از داده آموزش یا اعتبارسنجی، کیفیت پیش‌بینی DTA را نسبت به مدل‌های پایه تغییر می‌دهد؟ برای پاسخ، پرسش‌های زیر دنبال می‌شوند:

۱. کدام بازنمایی‌های دو مدل برای ترکیب مناسب‌اند و پس از سازگار کردن ابعاد و مقیاس، چه اطلاعاتی را در اختیار رگرسور قرار می‌دهند؟
۲. تعیین وزن بر اساس کدام تابع هزینه و قیود انجام می‌شود و تحت چه فرض‌هایی مسئله حاصل محدب است؟
۳. تغییرات خطای عددی و توافق رتبه‌ای در یک داده و سناریوی آزمون مشترک چه الگویی دارند؟
۴. نتیجه تا چه اندازه به تقسیم داده، وزن ترکیب و حضور هر جزء وابسته است؟
۵. افزایش هزینه آموزش و پیش‌بینی چه نسبتی با تغییر کیفیت خروجی دارد؟

این پرسش‌ها پاسخ مثبت از پیش تعیین شده ندارند. هدف آزمایش، سنجش اثر ترکیب و مشخص کردن دامنه کارایی آن است.

۱-۷ سهم پیشنهادی و شکاف پژوهشی

سهم پیشنهادی، ساخت یک مسیر مشخص از دو بازنمایی مبتنی بر یادگیری تخصصی و واریاسیونی به پیش‌بینی مشترک و تعیین وزن آن با بهینه‌سازی است. مقایسه دو مدل پایه، زمینه این طراحی و ابزار ارزیابی آن است؛ سهم پژوهش صرفاً به گزارش اختلاف دو عدد عملکرد محدود نمی‌شود.

شکاف عملی این پژوهش، نیاز به تعریف و ارزیابی این ترکیب در یک چارچوب مشترک است. دو مقاله منتخب، روش‌ها و آزمایش‌های خود را ارائه می‌کنند، اما پاسخ اثر ترکیب مورد نظر باید از تعریف و آزمایش همان ترکیب به دست آید [۹، ۱۱]. تفاوت معماری‌ها، انگیزه پژوهش را فراهم می‌کند و به‌تنهایی اثبات مکمل بودن ویژگی‌ها نیست.

ادعای تازگی قطعی به بررسی اختصاصی پیشینه ترکیب بازنمایی‌های مولد در DTA نیاز دارد [نیازمند منبع]. همچنین «روش مبتنی بر بهینه‌سازی محدب» عنوان مسیر طراحی است؛ اثبات محدب بودن باید برای تابع هدف و مجموعه شدنی نهایی ارائه شود [۲]. نتیجه پژوهش می‌تواند بهبود، نبود بهبود یا محدودیت ترکیب را نشان دهد. سهم علمی باید بر روش روشن و ارزیابی معتبر استوار بماند.

۱-۸ دامنه، فرض‌ها و وضعیت روش پیشنهادی

دامنه پژوهش، پیش‌بینی برجسب پیوسته اتصال از نمایش محاسباتی دارو و پروتئین است. خروجی DTA به‌تنهایی شاهد کارایی درمانی، سمیت، فراهمی زیستی یا تأیید بالینی یک مولکول نیست. تولید ساختار دارویی جدید نیز وظیفه اصلی این پایان‌نامه نیست؛ مدل‌های مولد در اینجا به‌عنوان مسیر یادگیری بازنمایی بررسی می‌شوند.

فرض طراحی آن است که دو بازنمایی پس از تعریف تبدیل‌های لازم بتوانند به یک بخش پیش‌بینی مشترک داده شوند. این فرض، انتخاب اجرایی کامل نیست. تصمیم‌های باز عبارت‌اند از محل استخراج ویژگی، نحوه هم‌بعد و هم‌مقیاس کردن آن‌ها، ثابت یا آموزش‌پذیر بودن رگرسور در مرحله تعیین وزن، تابع هزینه و قیود وزن [نیازمند تعیین روش]. بررسی محدب بودن نیز باید با همان انتخاب‌ها انجام شود.

در وضعیت فعلی، اجرای محلی DCGAN-DTA روی PDBbind و اجرای Co-VAE روی Davis وجود دارد، اما این دو اجرا آزمون مشترک مقایسه‌ای نیستند. برای نتیجه‌گیری درباره اثر ترکیب، داده، تبدیل برجسب، تقسیم‌ها و روش انتخاب مدل باید یکسان و مستند شوند. مقایسه مشترک، تحلیل نقش اجزا و ارزیابی روش ترکیبی، شواهد تجربی باقی‌مانده‌اند [نیازمند آزمایش].

۹-۱ چارچوب ارزیابی پژوهش

ارزیابی باید دو جنبه را از هم جدا کند: نزدیکی مقدار پیش‌بینی به برجسب و حفظ ترتیب زوج‌ها. MAE و MSE به خطای عددی مربوط‌اند؛ CI توافق ترتیب‌ها را می‌سنجد. بنابراین، یک معیار به‌تنهایی همه رفتار مدل را توصیف نمی‌کند. معیار r_m^2 یا RM^2 نیز در منابع DTA برای ارزیابی توافق پیش‌بینی و مشاهده گزارش شده است [۴، ۱۵]. تعریف‌ها، نمادها و حدود تفسیر در بخش ۲-۱۰ ارائه می‌شوند.

اگر از برجسب پیوسته، با آستانه‌ای مشخص، یک وظیفه دودویی ساخته شود، AUPR می‌تواند کیفیت رتبه‌بندی زوج‌های مثبت را در همان وظیفه مشتق‌شده بررسی کند. انتخاب آستانه، نسبت مثبت‌ها و روش محاسبه مساحت منحنی جزئی از تعریف این ارزیابی‌اند [۱۹]. این معیار مکمل است و جای ارزیابی خطای رگرسیون را نمی‌گیرد. در آزمایش مشترک، انتخاب وزن و ابرپارامترها باید از آزمون نهایی جدا باشد. همچنین تکرار تقسیم‌ها، گزارش پراکندگی و مقایسه مدل‌ها روی تقسیم‌های یکسان برای تفسیر پایداری لازم است. فهرست نهایی معیارها، سناریوهای آزمون، تعداد تکرارها و روش گزارش عدم قطعیت باید در پروتکل پژوهش تثبیت شوند [نیازمند تعیین روش]. اعداد مقاله‌های پیشین مبنای آموزشی و زمینه مقایسه‌اند، نه نتیجه این ارزیابی.

۱۰-۱ ساختار پایان‌نامه

فصل اول مسئله DTA، کمیت خروجی، ضرورت پژوهش، اهداف، پرسش‌ها و سهم پیشنهادی را تعریف می‌کند. فصل دوم از مبانی اتصال و داده آغاز می‌شود، نمایش‌های دارو و پروتئین و روش‌های پیشین را آموزش می‌دهد، مبانی GAN و VAE و معماری دو مدل منتخب را توضیح می‌دهد و معیارهای ارزیابی و جمع‌بندی پیشینه را ارائه می‌کند.

در ساختار مقصد، فصل سوم صورت دقیق روش پیشنهادی، استخراج و ترکیب بازنمایی‌ها و مسئله تعیین وزن را بیان می‌کند. فصل چهارم به داده، پروتکل مشترک و نتایج آزمایش‌ها اختصاص دارد و فصل پنجم جمع‌بندی، محدودیت‌ها و مسیرهای ادامه پژوهش را مطرح می‌کند. این تقسیم‌بندی، مسیر ارائه پژوهش را مشخص می‌سازد و تکمیل آزمایش‌های بعدی را فرض نمی‌گیرد.

فصل ۲

مبانی نظری و پیشینه پژوهش

۱-۲ مقدمه

پیش‌بینی میل اتصال از کنار هم گذاشتن دو توالی آغاز می‌شود، اما فهم آن به شناخت سه لایه نیاز دارد: معنای زیستی و آزمایشگاهی برجسب، نمایش محاسباتی مولکول‌ها و منطق یادگیری مدل. اگر یکی از این لایه‌ها مبهم بماند، خروجی عددی شبکه نیز به‌درستی تفسیر نمی‌شود. برای مثال، تغییر نمایش یک دارو از رشته به گراف، اطلاعات در دسترس مدل را تغییر می‌دهد؛ تغییر برجسب از ثابت تفکیک به امتیاز ترکیبی نیز معنای خروجی را عوض می‌کند.

این فصل ابتدا کمیت‌های اتصال و داده‌های رایج را معرفی می‌کند، سپس به نمایش دارو و پروتئین و مسیر تحول مدل‌های DTA می‌پردازد. بعد از آموزش مبانی، DCGAN GAN و VAE معماری و هدف یادگیری دو مدل منتخب بررسی می‌شوند. معیارهای ارزیابی و جمع‌بندی پیشینه، پیوند این مبانی با طراحی روش پیشنهادی را کامل می‌کنند. مرور اخیر Zeng و همکاران برای دسته‌بندی نمایش‌ها و روش‌های عمیق به کار می‌رود؛ شرح سازوکار هر روش بر مقاله اصلی همان روش تکیه دارد [۲۳].

۲-۲ مبانی زیستی و معنای میل اتصال

۱-۲-۲ دارو، هدف و اتصال

در این متن، دارو نام کوتاهی برای مولکول کوچک مورد مطالعه است و الزاماً به معنای یک فرآورده تأییدشده درمانی نیست. هدف، پروتئینی است که اتصال به آن اندازه‌گیری یا پیش‌بینی می‌شود. پروتئین از زنجیره اسیدهای آمینه تشکیل شده است؛ ترتیب این واحدها، توالی اولیه را می‌سازد، درحالی‌که جایگاه اتصال در ساختار فضایی پروتئین شکل می‌گیرد. بنابراین، توالی یک نمایش مفید از پروتئین است، اما با توصیف کامل هندسه جایگاه اتصال

یکسان نیست. پایگاه PDBbind نمونه‌ای از گردآوری اطلاعات اتصال در کنار ساختار سه‌بعدی کمپلکس‌های پروتئین-لیگاند است [۲۱].

میل اتصال، تمایل مولکول و هدف به تشکیل کمپلکس را بیان می‌کند. در یک مدل ساده اتصال یک‌به‌یک در تعادل، ثابت تفکیک K_d نسبت حاصل ضرب غلظت‌های آزاد دو طرف به غلظت کمپلکس است؛ کوچک‌تر بودن آن با اتصال قوی‌تر متناظر است. این تفسیر به فرض تعادل و مدل اتصال وابسته است. تغییر شرایط آزمایش، ناهمگنی جایگاه‌ها یا کم شدن محسوس غلظت آزاد لیگاند می‌تواند تفسیر اندازه‌گیری را تغییر دهد [۸]. پس یک مقدار اتصال باید همراه با نوع سنجش، واحد و شرایط آن خوانده شود.

۲-۲-۲ تفاوت ثابت‌های اتصال و کمیت‌های مهار

ثابت K_d کمیتی غلظتی برای تعادل اتصال است. ثابت K_i به ثابت مهار در مدل مربوط به آزمایش مهار اشاره دارد و تفسیر آن به سازوکار مهار وابسته است. در مقابل، IC_{50} غلظتی است که در یک سنجش مشخص، پاسخ یا فعالیت اندازه‌گیری شده را به میزان پنجاه درصد مهار می‌کند. این غلظت می‌تواند به مقدار سوبسترا یا لیگاند رقیب و شرایط آزمون وابسته باشد؛ از این رو، مستقیماً معادل K_i نیست. تبدیل آن به ثابت مهار به یک مدل و فرض‌های آزمایشگاهی مناسب نیاز دارد [۸، ۳].

جدول ۲-۱ نقش این کمیت‌ها را خلاصه می‌کند. قرار گرفتن آن‌ها در یک ستون فعالیت زیستی در پایگاه داده، تفاوت معنایی‌شان را حذف نمی‌کند. به همین دلیل، ادغام رکوردهای چند نوع سنجش نیازمند تصمیمی مستند درباره نوع برچسب است.

جدول ۲-۱: کمیت‌های رایج اتصال و مهار؛ خلاصه تعاریف منابع سنجش و پایگاه داده [۸، ۳، ۱].

کمیت	معنای اصلی	مقیاس و جهت تفسیر
K_d	ثابت تفکیک در مدل تعادل اتصال	واحد غلظت؛ مقدار کمتر، اتصال قوی‌تر
K_i	ثابت مهار در مدل سنجش مهار	واحد غلظت؛ تفسیر وابسته به مدل مهار
IC_{50}	غلظت ایجادکننده مهار پنجاه درصدی	واحد غلظت؛ وابسته به شرایط سنجش
pK_d و pK_i	منفی لگاریتم مقدار مولار ثابت مربوط	بی‌بعد؛ مقدار بیشتر، ثابت غلظتی کوچک‌تر
pIC_{50}	منفی لگاریتم IC_{50} مولار	بی‌بعد؛ همچنان کمیت مربوط به همان سنجش

۳-۲-۲ واحد و تبدیل لگاریتمی

برای لگاریتم‌گیری باید ابتدا واحد مشخص شود. قرارداد منفی لگاریتم فعالیت مولار در معرفی pChEMBL توضیح داده شده است [۱]. با نمادگذاری این متن، برای هر کمیت غلظتی مثبت X داریم

$$pX = -\log_{10} \left(\frac{X}{1 \text{ mol L}^{-1}} \right). \quad (۱-۲)$$

نسبت داخل لگاریتم بی‌بعد است. اگر x_{mM} مقدار عددی X بر حسب نانومولار باشد، تبدیل واحد نتیجه می‌دهد

$$pX = -\log_{10} (x_{\text{mM}} \times 10^{-9}) = 9 - \log_{10} (x_{\text{mM}}). \quad (۲-۲)$$

رابطه دوم بازنویسی واحد رابطه اول است. برای $X = K_d$ ، K_i یا IC_{50} ، به ترتیب pK_d ، pK_i یا pIC_{50} حاصل می‌شود. کاهش ده‌برابری کمیت مولار، مقدار pX را یک واحد افزایش می‌دهد. این تبدیل فقط مقیاس را تغییر می‌دهد و IC_{50} را به K_i تبدیل نمی‌کند.

مقادیر صفر یا منفی در این قرارداد لگاریتم تعریف نمی‌شوند. همچنین رکوردهایی مانند «بیشتر از» یا «کمتر از» یک آستانه، اندازه‌گیری دقیق یک عدد نیستند. شیوه برخورد با این رکوردها باید در آماده‌سازی داده مشخص شود؛ تبدیل خودکار آن‌ها به برچسب دقیق، عدم قطعیت سنجش را پنهان می‌کند.

۳-۲ داده‌های DTA و شرایط تعمیم

۳-۲-۱ منشأ داده و نسخه آماده‌شده

داده DTA از زوج‌های مشاهده‌شده و برچسب‌های آن‌ها تشکیل می‌شود. تعداد داروها و اهداف به‌تنهایی اندازه داده آموزش نیست؛ ممکن است تنها بخشی از ترکیب‌های ممکن اندازه‌گیری شده باشد. خانه خالی در ماتریس اتصال، معمولاً به معنای مقدار مجهول است و نباید بدون مبنای آزمایشگاهی به عدم تعامل یا میل اتصال صفر تعبیر شود. Davis بر سنجش اتصال مهارکننده‌های کیناز استوار است. مقاله اصلی مطالعه، تحلیل انتخاب‌پذیری مهارکننده‌ها را گزارش می‌کند [۵]. نسخه‌ای که در DeepDTA استفاده شده شامل ۶۸ ترکیب، ۴۴۲ هدف و ۵۶,۳۰ مشاهده است؛ این شمارش به نسخه آماده‌شده همان مطالعه مربوط است [۱۵]. بنابراین، نام یک مجموعه به‌تنهایی برای شناسایی فایل‌ها، پالایش و مقیاس برچسب کافی نیست.

KIBA یک امتیاز یکپارچه از اطلاعات زیست‌فعالیتی مرتبط با کینازهاست؛ مطالعه معرفی‌کننده، داده‌های مبتنی بر K_i ، K_d و IC_{50} را برای تحلیل و ادغام بررسی می‌کند [۲۰]. این امتیاز را نباید یک ثابت تفکیک مولار

یا همان pK_d نامید. DeepDTA نسخه پالایش شده‌ای با ۱۱۱,۲ ترکیب، ۲۲۹ هدف و ۲۵۴,۱۱۸ مشاهده به کار می‌برد [۱۵]. جهت و دامنه مقیاس خروجی باید از نسخه داده مورد استفاده بررسی شود. BindingDB پایگاهی از اندازه‌گیری‌های تجربی اتصال پروتئین-لیگاند است [۱۲]. PDBbind اطلاعات اتصال را در کنار کمپلکس‌های دارای ساختار سه‌بعدی گردآوری می‌کند [۲۱]. وجود ساختار در پایگاه به این معنا نیست که هر مدل آموزش دیده بر آن، ساختار سه‌بعدی را به‌عنوان ورودی استفاده می‌کند. نوع ورودی و نوع برچسب باید از روش آماده‌سازی همان مدل مشخص شود.

۲-۳-۲ زوج جدید و موجودیت جدید

تقسیم تصادفی زوج‌ها می‌تواند دارو و پروتئین هر زوج آزمون را در زوج‌های دیگری از آموزش نگه دارد. چنین آزمونی توان پیش‌بینی رابطه‌ای تازه میان موجودیت‌های آشنا را می‌سجد. در آزمون داروی جدید، داروی آزمون در آموزش دیده نشده است؛ در آزمون هدف جدید، همین شرط برای پروتئین برقرار است. جدید بودن هر دو طرف، شرط دیگری برای تعمیم ایجاد می‌کند. چارچوب Pahikkala و همکاران این تمایزها را در ارزیابی تعامل و اتصال برجسته می‌کند [۱۷].

این تفاوت برای بازنمایی‌های مولد نیز مهم است. اگر مدل در پیش‌آموزش بدون برچسب، توالی موجودیت آزمون را دیده باشد، وضعیت آن با حالتی که هیچ اطلاعاتی از آن موجودیت در اختیار نبوده یکسان نیست. چنین استفاده‌ای لزوماً نامعتبر نیست، اما باید با تعریف سناریوی ارزیابی سازگار و گزارش شود. مجموعه آموزش رگرسیون، داده پیش‌آموزش، اعتبارسنجی و آزمون چهار نقش متفاوت دارند؛ ثبت این نقش‌ها از ابهام در تفسیر تعمیم جلوگیری می‌کند.

۲-۳-۳ اعتبارسنجی و مقایسه

اعتبارسنجی برای انتخاب ابرپارامترها و وزن ترکیب است و آزمون نهایی برای گزارش کیفیت انتخاب انجام شده. محاسبه آمار نرمال‌سازی، انتخاب ویژگی یا تنظیم وزن با استفاده از برچسب‌های آزمون، استقلال ارزیابی را از بین می‌برد. مقایسه معتبر همچنین به نسخه یکسان داده، برچسب، تقسیم و تعریف معیار نیاز دارد. عدد بهتر در مقاله‌ای با داده یا سناریوی دیگر، شاهد برتری در آزمایش مشترک نیست.

۴-۲ نمایش دارو و پروتئین

۱-۴-۲ رشته SMILES و نمایش گرافی دارو

رشته SMILES ساختار مولکول را با قواعدی برای اتم‌ها، پیوندها، شاخه‌ها و حلقه‌ها رمزگذاری می‌کند. این نمایش در مقاله Weininger معرفی شده است [۲۲]. نزدیکی دو نویسه در رشته الزاماً معادل فاصله فضایی دو اتم نیست؛ ترتیب رشته مسیر بیان ساختار را نشان می‌دهد. در روش توالی‌محور، نویسه‌ها یا قطعه‌های رشته به شناسه‌های عددی تبدیل و سپس به بردارهای آموختنی نگاشت می‌شوند.

نمایش گرافی، اتم‌ها را به صورت گره و پیوندها را به صورت یال نگه می‌دارد. در GraphDTA شبکه گرافی ویژگی‌های دارو را از این نمایش می‌آموزد و آن‌ها را با ویژگی‌های پروتئین ترکیب می‌کند [۱۴]. تفاوت این انتخاب با ورودی رشته‌ای، در ساختار همسایگی ارائه شده به شبکه است. برتری یکی از آن‌ها به داده، ویژگی‌های گره و مدل وابسته است و از تعریف نمایش به تنهایی نتیجه نمی‌شود.

۲-۴-۲ توالی پروتئین، تعبیه و کانولوشن

در نمایش توالی، هر اسید آمینه به یک نماد و سپس به بردار عددی تبدیل می‌شود. تعبیه آموختنی، برای هر نماد یک بردار دارد که همراه با هدف آموزش تغییر می‌کند. توالی طول متغیر دارد؛ محدود کردن طول و افزودن نماد پرکننده، بخشی از آماده‌سازی ورودی‌اند. این تصمیم‌ها باید طوری ثبت شوند که معلوم باشد کدام بخش اطلاعات پروتئین به مدل رسیده است.

کانولوشن یک بعدی از پنجره‌های محلی توالی ویژگی استخراج می‌کند. فیلتر مشترک در موقعیت‌های مختلف به کار می‌رود و تجمیع، ویژگی‌های حاصل را به نمایش فشرده‌تر تبدیل می‌کند. این منطق در دو شاخه CNN و DeepDTA برای دارو و پروتئین استفاده شده است [۱۵]. فیلتر آموخته شده ممکن است به الگوهای ورودی حساس شود، اما نسبت دادن یک معنای زیستی مشخص به هر فیلتر نیازمند تحلیل جداگانه است.

۳-۴-۲ ورودی خام، ویژگی میانی و پیش‌بینی

سه سطح را باید جدا نگه داشت: ورودی رمزگذاری شده، بازنمایی حاصل از لایه‌های مدل و مقدار خروجی. ترکیب دو رشته ورودی، الحاق دو بردار نهان و میانگین‌گیری از دو پیش‌بینی، عملیات یکسانی نیستند. در الحاق، دو بردار کنار هم قرار می‌گیرند و بعد ورودی افزایش می‌یابد؛ جمع مؤلفه به مؤلفه به ابعاد سازگار نیاز دارد. این تمایز در مقایسه DCGAN-DTA، Co-VAE و طراحی ترکیب پایان‌نامه نقش مستقیم دارد.

۲-۵ از روش‌های مبتنی بر شباهت تا یادگیری عمیق

۲-۵-۱ کرنل و فاکتورگیری ماتریس

در روش‌های مبتنی بر شباهت، ارتباط محاسباتی میان داروها و ارتباط میان اهداف به اطلاعات مدل تبدیل می‌شوند. رگرسیون کمترین مربعات منظم‌شده با کرنل زوج‌ها در مطالعه Pahikkala و همکاران نمونه‌ای برای پیش‌بینی کمی اتصال است [۱۷]. این خانواده پیش از ساخت شبکه‌های عمیق نیز امکان استفاده هم‌زمان از اطلاعات دو طرف را فراهم می‌کند؛ محدودیت آن به کیفیت شباهت‌ها و فرض تعمیم مدل وابسته است.

فاکتورگیری ماتریس، هر موجودیت را با برداری کم‌بعد نمایش می‌دهد و رابطه زوج را از این بردارها برآورد می‌کند. نوع برجسب و تابع یادگیری تعیین می‌کنند که خروجی رگرسیونی است یا احتمالی دودویی. NRLMF، فاکتورگیری لجستیک و منظم‌سازی همسایگی را برای پیش‌بینی تعامل دودویی به کار می‌برد [۱۳]. این منبع شاهی برای سازوکار DTI است؛ نتایج آن در این متن نتیجه رگرسیون DTA محسوب نمی‌شوند.

۲-۵-۲ ویژگی‌های مهندسی شده و SimBoost

در یادگیری با ویژگی‌های مهندسی‌شده، پیش از آموزش رگرسور باید تصمیم گرفت چه توصیف‌گرهایی از دارو، پروتئین یا روابط میان آن‌ها استخراج شوند. SimBoost از ویژگی‌های مربوط به موجودیت‌ها، ساختار روابط و اطلاعات تعامل در چارچوب ماشین‌های تقویت گرادیانی برای پیش‌بینی affinity استفاده می‌کند. مقاله همچنین برآورد بازه‌های پیش‌بینی را بررسی می‌کند [۷]. نقش این روش در مسیر یادگیری، نشان دادن جدایی طراحی ویژگی از رگرسور و اهمیت اطلاعات روابط است.

۲-۵-۳ DeepDTA

DeepDTA نمایش دارو را از SMILES و نمایش پروتئین را از توالی می‌گیرد. دو شاخه کانولوشنی جداگانه، ویژگی‌های دو ورودی را استخراج می‌کنند؛ هر شاخه سه لایه کانولوشن و سپس تجمیع بیشینه دارد. ویژگی‌ها الحاق می‌شوند و به سه لایه کاملاً متصل با اندازه‌های ۱۰۲۴، ۱۰۲۴ و ۵۱۲ می‌رسند تا خروجی پیوسته پیش‌بینی شود. این شرح به معماری مقاله اصلی مربوط است [۱۵].

منطق آموزشی این معماری روشن است: هر شاخه الگوهای محلی یک نوع توالی را می‌آموزد و رگرسور از اطلاعات مشترک دو شاخه مقدار اتصال را برآورد می‌کند. هدف مستقیم آموزش، خطای پیش‌بینی برجسب است؛ بازسازی ورودی یا رقابت مولد و تمایزگر جزء این معماری نیست. نتایج Davis و KIBA در مقاله، با همان

آماده‌سازی و تقسیم داده تفسیر می‌شوند.

۴-۵-۲ WideDTA و GraphDTA

GraphDTA برای دارو، گراف مولکولی و برای پروتئین، نمایش توالی را استفاده می‌کند. مقاله چند نوع شبکه گرافی، از جمله، GCN، GIN GAT، و ترکیب GAT-GCN را بررسی می‌کند. ویژگی گراف دارو و ویژگی توالی پروتئین الحاق و به بخش پیش‌بینی داده می‌شوند [۱۴]. این طراحی امکان مقایسه اثر ساختار گرافی را فراهم می‌کند، اما به‌خودی‌خود رابطه فضایی کامل کمپلکس را در اختیار مدل نمی‌گذارد.

WideDTA در پیش‌چاپ بررسی شده، استفاده از اطلاعات در سطح قطعه‌ها یا واژه‌ها را برای ورودی‌های دارویی و پروتئینی دنبال می‌کند [۱۶]. در این فصل، این منبع برای نشان دادن تنوع واحد نمایش به کار می‌رود. مشخصات نسخه پیش‌چاپ در کتاب‌نامه حفظ شده‌اند.

۵-۵-۲ جمع‌بندی مسیر روش‌ها

جدول ۲-۲: مقایسه مفهومی مسیر استخراج ویژگی و نوع خروجی؛ جمع‌بندی این متن از منابع اصلی هر ردیف.

روش	مسیر اصلی اطلاعات	نوع مسئله
کرنل زوج‌ها [۱۷]	شباهت دارو و هدف، رگرسیون منظم‌شده	اتصال کمی
NRLMF [۱۳]	فاکتورگیری لجستیک و همسایگی	DTI دودویی
SimBoost [۷]	ویژگی‌های طراحی شده و تقویت گرادیانی	DTA
DeepDTA [۱۵]	دو CNN برای رشته دارو و توالی هدف	DTA
GraphDTA [۱۴]	گراف دارو و شاخه توالی پروتئین	DTA

این مسیر، تغییر از شباهت‌های از پیش تعریف‌شده به یادگیری ویژگی را نشان می‌دهد. پرسش بعدی آن است که بازنمایی فقط با خطای رگرسیون آموخته شود یا هدف مولد نیز آن را هدایت کند. دو بخش بعد مبانی لازم برای پاسخ را آموزش می‌دهند.

۶-۲ یادگیری تخصصی و DCGAN


۱-۶-۲ انگیزه و منطق GAN

در یادگیری نظارت‌شده، بازنمایی از خطای پیش‌بینی برچسب هدایت می‌شود. مدل مولد پرسش دیگری مطرح می‌کند: چگونه می‌توان نمونه‌هایی سازگار با توزیع داده تولید کرد؟ شبکه مولد تخصصی، با اختصار، GAN این هدف را از راه رقابت دو شبکه دنبال می‌کند. مولد G یک بردار نویز را به فضای داده نگاشت می‌کند و تمایزگر D برای تشخیص نمونه واقعی از تولیدشده آموزش می‌بیند. این رقابت، هدفی برای یادگیری ساختار داده بدون نیاز به برچسب رگرسیونی اتصال فراهم می‌کند [۶].


تمایزگر GAN با رگرسور DTA یکسان نیست. خروجی آن در آموزش تخصصی، امتیاز واقعی بودن نمونه است؛ مقدار میل اتصال نیست. بهره‌گیری از شبکه پیش‌آمخته در یک وظیفه دیگر به تعریف جداگانه ورودی، ویژگی و بخش پیش‌بینی نیاز دارد. شکل ۱-۲ جریان نمونه و ترتیب به‌روزرسانی را نشان می‌دهد.

GAN: sample flow and alternating training

Independent explanatory diagram — Goodfellow et al. (2014), Eq. 1 and Algorithm 1



Training cycle (Algorithm 1)



D's real/fake score is not a drug-target affinity prediction.

شکل ۱-۲: طرح آموزشی مستقل از جریان GAN و آموزش متناوب؛ بر اساس معادله ۱، صفحه ۳، و الگوریتم ۱، صفحه ۴ مقاله اصلی [۶]. مولد نویز را به نمونه تبدیل می‌کند؛ تمایزگر نمونه‌های واقعی و تولیدشده را دریافت می‌کند.

۲-۶-۲ هدف و آموزش متناوب

هدف اصلی بازی کمینه-بیشینه در معادله ۱ مقاله، GAN، صفحه ۳، چنین است [۶]:

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{\text{data}}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]. \quad (۳-۲)$$

در این رابطه، x نمونه واقعی، p_{data} توزیع داده، z بردار نویز، p_z توزیع نویز و $G(z)$ نمونه تولیدشده است. $D(x)$ خروجی تمایزگر برای نمونه x و V ارزش بازی است. تمایزگر می‌کوشد این ارزش را افزایش دهد و مولد آن را کاهش دهد. امید ریاضی، میانگین‌گیری نسبت به توزیع مشخص‌شده در زیرنویس را بیان می‌کند.

الگوریتم ۱ مقاله در صفحه ۴، چند گام به‌روزرسانی تمایزگر و سپس یک گام مولد را با نمونه‌های دسته‌ای توضیح می‌دهد. در گام تمایزگر، پارامترهای مولد ثابت نگه داشته می‌شوند؛ در گام مولد، پارامترهای تمایزگر ثابت‌اند. k تعداد گام‌های تمایزگر است. مقاله همچنین تغییر هدف مولد به بیشینه کردن $\log D(G(z))$ را برای فراهم کردن گرادین مناسب در آغاز آموزش مطرح می‌کند [۶]. این انتخاب آموزشی را نباید بدون شاهد به پیاده‌سازی مقاله DTA نسبت داد.

از هدف تخصصی، تضمین کارایی بازنمایی در DTA حاصل نمی‌شود. شبکه برای تمایز واقعی و تولیدشده آموزش دیده است؛ رابطه ویژگی‌های آن با اتصال باید در وظیفه پایین‌دستی سنجیده شود. این نکته، انگیزه استفاده از پیش‌آموزش را از ادعای نتیجه جدا می‌کند.

۲-۶-۳ از GAN به DCGAN


شبکه مولد تخصصی کانولوشنی عمیق، با اختصار، DCGAN، برای پیوند دادن یادگیری تخصصی با معماری کانولوشنی، مجموعه‌ای از انتخاب‌های معماری پیشنهاد می‌کند: کانولوشن با گام در تمایزگر، عملیات افزایش اندازه در مولد، استفاده کنترل‌شده از نرمال‌سازی دسته‌ای و انتخاب متفاوت فعال‌سازها در دو شبکه. در طرح اصلی، مولد از ReLU و در خروجی از tanh استفاده می‌کند؛ تمایزگر از LeakyReLU بهره می‌گیرد [۱۸].

شکل ۱ مقاله، DCGAN، صفحه ۴ نسخه محلی، یک مولد تصویری را از بردار نویز صدبُعدی تا تصویر $۳ \times ۶۴ \times ۶۴$ نشان می‌دهد. نمونه آموزشی شکل ۲-۲ همین زنجیره ابعاد را بازترسیم می‌کند. این اندازه‌ها به مثال تصویری مربوط‌اند و پارامترهای مدل DTA نیستند.

نام DCGAN به‌تنهایی مشخص نمی‌کند که تمام این انتخاب‌ها در کاربرد بعدی حفظ شده‌اند. برای داده توالی‌محور، بُعد کانولوشن، تعبیه و مسیر انتقال ویژگی باید از مقاله همان کاربرد بررسی شود. بخش ۲-۸ این

DCGAN: example image generator

Independent explanation of Radford et al., Figure 1, PDF / printed page 4



Generator: ReLU internally; tanh at the output.

These are image-model dimensions, not DCGAN-DTA settings.

شکل ۲-۲: بازترسیم مستقل مسیر افزایش اندازه در مولد تصویری DCGAN بر اساس شکل ۱، صفحه ۴ مقاله [۱۸]. این مثال منطق معماری را آموزش می‌دهد؛ ورودی‌ها و ابعاد مدل DCGAN-DTA جداگانه تعریف می‌شوند.

تغییرها را در DCGAN-DTA توضیح می‌دهد.

۷-۲ خودرمزگذار واریاسیونی و بازنمایی نهان


۱-۷-۲ از بازسازی به مدل احتمالاتی

خودرمزگذار ورودی را به بازنمایی فشرده می‌برد و از آن ورودی را بازسازی می‌کند. در VAE نمایش نهان تنها یک بردار قطعی نیست؛ رمزگذار پارامترهای یک توزیع را برآورد می‌کند. مدل مولد نیز توزیع پیشین متغیر نهان و توزیع شرطی داده با دانستن آن را تعریف می‌کند. این دیدگاه در مقاله Kingma و Welling با عنوان «خودرمزگذاری واریاسیونی بیزی»، صورت‌بندی شده است [۱۰].

اگر z متغیر نهان و x مشاهده باشد، $p_\theta(z)$ پیشین و $p_\theta(x | z)$ مدل تولید مشاهده از نهان است. پسین دقیق $p_\theta(z | x)$ می‌تواند محاسبه‌ناپذیر باشد؛ رمزگذار واریاسیونی $q_\phi(z | x)$ برای تقریب آن استفاده می‌شود. θ پارامترهای مدل مولد و ϕ پارامترهای استنتاج‌اند. شکل ۲-۳ مرز میان مسیر تولید و مسیر استنتاج را نشان می‌دهد.

VAE: inference, sampling and reconstruction

Independent explanation — AEVB, Figure 1 and the sampling expression in Eq. 10



شکل ۲-۳: طرح آموزشی مستقل از استنتاج، نمونه‌گیری و بازسازی VAE مبتنی بر شکل ۱، صفحه ۲، و بخش نمونه‌گیری معادله ۱۰، صفحه ۵ نسخه بررسی‌شده مقاله [۱۰]. پیکان پیوسته مسیر مولد و پیکان گسسته مسیر استنتاج را بیان می‌کند.

۲-۷-۲ کران پایین شواهد

هدف واریاسیونی، کرانی پایین برای لگاریتم احتمال مشاهده فراهم می‌کند. معادله ۳ مقاله اصلی، صفحه ۳، برای مشاهده $x^{(i)}$ به صورت زیر نوشته می‌شود [۱۰]:

$$\mathcal{L}(\theta, \phi; x^{(i)}) = -D_{\text{KL}}(q_{\phi}(z | x^{(i)}) || p_{\theta}(z)) + \mathbb{E}_{q_{\phi}(z | x^{(i)})}[\log p_{\theta}(x^{(i)} | z)]. \quad (۴-۲)$$

$\mathcal{L}$ کران پایین شواهد یا ELBO است و در این قرارداد پیشینه می‌شود. جمله امید ریاضی، سازگاری بازسازی با مشاهده را بر حسب درست‌نمایی شرطی بیان می‌کند. واگرایی کولبک-لایبلر، با نماد D_{KL} ، اختلاف توزیع استنتاج‌شده و پیشین را می‌سنجد؛ با علامت منفی در هدف وارد شده است.

این دو مؤلفه نقش متفاوت دارند. فقط مناسب بودن بازسازی کافی نیست، زیرا فضای نهان باید با پیشین انتخاب‌شده نیز سازگار شود. از طرف دیگر، نزدیک شدن به پیشین بدون حفظ اطلاعات مشاهده، هدف بازنمایی را برآورده نمی‌کند. منفی ELBO می‌تواند به عنوان هزینه کمینه‌سازی استفاده شود؛ در نقل فرمول باید قرارداد علامت و جهت بهینه‌سازی روشن بماند. MSE یک انتخاب عمومی اجباری برای همه VAEها نیست؛ شکل جمله بازسازی به مدل احتمال مشاهده وابسته است.

۳-۷-۲ بازپارامتردهی و نقش نمادها

برای پسین گاوسی با ساختار قطری، بخش نمونه‌گیری در معادله ۱۰ مقاله، صفحه ۵، به صورت

$$z^{(i,l)} = \mu^{(i)} + \sigma^{(i)} \odot \epsilon^{(l)}, \quad \epsilon^{(l)} \sim \mathcal{N}(\mathbf{0}, I) \quad (۵-۲)$$

است [۱۰]. در این رابطه، $\mu^{(i)}$ بردار میانگین و $\sigma^{(i)}$ بردار انحراف معیار برآورده شده برای مشاهده i هستند؛ σ واریانس نیست. $\odot$ ضرب مؤلفه‌به‌مؤلفه، I ماتریس همانی و l شماره نمونه نویز است. نویز از توزیعی مستقل از پارامترهای رمزگذار گرفته می‌شود و وابستگی به پارامترها در μ و σ باقی می‌ماند. این بازنویسی، مسیر محاسبه گرادیان را از نمونه‌گیری جدا می‌کند.

در DTA، ویژگی نهان می‌تواند به پیش‌بینی اتصال کمک کند، ولی هدف بازسازی به‌تنهایی آن را برای این وظیفه بهینه نمی‌کند. Co-VAE یک مؤلفه مرتبط با برجسب را نیز وارد چارچوب می‌کند. بنابراین، پیش از مقایسه با DCGAN-DTA باید روشن باشد که ویژگی نهان از کدام هدف‌ها تأثیر می‌گیرد و چگونه به رگرسیون می‌رسد.

۸-۲ معماری و روش DCGAN-DTA

۱-۸-۲ مسیر چهار مرحله‌ای پیش‌بینی

مقاله DCGAN-DTA، پیش‌بینی اتصال را در چهار مرحله توضیح می‌دهد: رمزگذاری و تعبیه، استخراج ویژگی، ادغام بردارهای دارو و پروتئین و پیش‌بینی DTA. شرح روش در صفحه ۴ و شکل ۱ در صفحه ۵ PDF آمده‌اند؛ شماره‌های چاپی نیز ۴ و ۵ هستند [۹]. شکل ۲-۴ معماری اصلی منتشرشده را نشان می‌دهد.

در مرحله نخست، نمادهای SMILES و توالی پروتئین به شناسه‌های عددی تبدیل و با پرکننده به طول ثابت رسانده می‌شوند. لایه تعبیه این شناسه‌ها را به بردار می‌برد. مقاله همچنین برای پروتئین، رمزگذاری BLOSUM با برداری ۲۵ بُعدی برای هر اسید آمینه را معرفی می‌کند. این دو مسیر ارائه اطلاعات باید از هدف رگرسیونی اتصال متمایز بمانند.

۲-۸-۲ پیش‌آموزش تخصصی و استخراج ویژگی


DCGAN به کاررفته در این مقاله برای توالی‌ها تنظیم شده است. مولد سه لایه کانولوشن ترانهاد یک بُعدی دارد؛ دو لایه اول از ReLU و آخرین لایه از tanh استفاده می‌کنند. تمایزگر پنج لایه کانولوشن یک بُعدی با ReLU، سپس تخت‌سازی و یک لایه تک‌گره‌ای با tanh دارد. حذف نرمال‌سازی دسته‌ای و استفاده از ReLU در تمایزگر، از تفاوت‌های صریح گزارش‌شده با معماری اصلی تصویری DCGAN هستند [۹].

آموزش تخصصی با داده‌های UniProt و ChEMBL انجام می‌شود و شبکه‌های آموخته‌شده در مرحله استخراج ویژگی، در کنار بلوک‌های CNN شامل سه کانولوشن و یک تجمیع بیشینه، به کار می‌روند. شکل ۲-۵ این جدایی پیش‌آموزش و پیش‌بینی اتصال را به صورت آموزشی نشان می‌دهد. استفاده از داده‌های بدون برچسب اتصال، انگیزه یادگیری بازنمایی است؛ میزان سود آن باید در آزمایش همان مدل بررسی شود.

۳-۸-۲ ادغام و خروجی رگرسیون

در مرحله ادغام، مقاله از لایه جمع برای ترکیب بردارهای دارو و پروتئین استفاده می‌کند. جمع مؤلفه‌به‌مؤلفه به سازگاری ابعاد نیاز دارد و، برخلاف الحاق، طول بردار خروجی را به مجموع طول دو ورودی افزایش نمی‌دهد. بخش کاملاً متصل، ویژگی ادغام‌شده را به خروجی affinity می‌برد. تفسیر کمتر بودن بعد ورودی، یک توضیح ساختاری است؛ نتیجه عملکرد باید از مقایسه گزارش‌شده خوانده شود.


در منبع، یک ناسازگاری معماری وجود دارد: شکل ۱ اندازه‌های ۱۰۲۴، ۱۰۲۴ و ۵۱۲ را برای لایه‌های



شکل ۲-۴: معماری اصلی DCGAN-DTA؛ بازنشر شکل ۱، صفحه ۵ PDF و صفحه چاپی ۵، از مقاله Kalematai و همکاران [۹] تحت مجوز CC BY 4.0. برای خوانایی، حاشیه و شرح انگلیسی در نمایش بریده شده‌اند؛ اجزای معماری تغییر نکرده‌اند.

DCGAN-DTA: pretraining and affinity prediction

Independent process explanation — method description and Figure 1 (Kalemati et al., 2024)




شکل ۲-۵: طرح آموزشی مستقل از پیش‌آموزش و پیش‌بینی در DCGAN-DTA؛ مبتنی بر شرح روش، صفحه ۴، و شکل ۱، صفحه ۵ مقاله [۹]. این نمودار ترتیب مراحل را خلاصه می‌کند و جایگزین جزئیات معماری شکل اصلی نیست.

کاملاً متصل نشان می‌دهد، اما متن ادامه روش در صفحه ۶ اندازه‌های ۱۰۲۴، ۵۱۲ و ۵۱۲ را ذکر می‌کند. در این فصل، این اختلاف با انتخاب دلخواه یا استناد به کد حل نمی‌شود. برای تعریف مدل پایه پایان‌نامه، نسخه معماری باید مشخص و این اختلاف مستند شود [نیازمند تعیین روش].


در صفحات بررسی‌شده، معادله صریحی برای تابع هدف اختصاصی آموزش GAN این مدل ارائه نشده است. معادله MSE در صفحه ۶، معادله ۳ مقاله، در بخش ارزیابی آمده و نباید به عنوان تابع هدف تخصصی معرفی شود. مبای عمومی GAN در رابطه (۲-۳) آموزش داده شد؛ نسبت دادن انتخاب خاص هدف یا بهینه‌ساز به آموزش تخصصی این مقاله به شاهد همان منبع نیاز دارد.

۲-۸-۴ دامنه نتایج منتشرشده

مقاله DCGAN-DTA را روی داده‌های آماده‌شده از BindingDB و PDBbind ارزیابی می‌کند. CI، MSE، AUPR و r_m^2 معیارهای گزارش‌شده‌اند و در بخش ۲-۱۰ تعریف می‌شوند. شکل‌های ۲ و ۳ مقاله نتایج این دو مجموعه را ارائه می‌کنند. شکل ۲-۶ نتیجه BindingDB و شکل ۲-۷ مقایسه پیکربندی‌ها در PDBbind را نگه می‌دارند.



شکل ۲-۶: نتایج منتشرشده؛ BindingDB بازنشر شکل ۲، صفحه ۷ PDF و صفحه چاپی ۷ مقاله [۹] تحت **CC BY 4.0**. حاشیه و شرح انگلیسی برای خوانایی بریده شده‌اند؛ پنل‌ها و راهنما حفظ شده‌اند. این اعداد نتیجه آزمایش پایان‌نامه نیستند.




شکل ۲-۷: نتایج منتشرشده PDBbind برای روش‌های مقایسه و پیکربندی‌های DCGAN-DTA؛ بازنشر شکل ۳، صفحه ۸ PDF و صفحه چاپی ۸ مقاله [۹] تحت CC BY 4.0. حاشیه و شرح انگلیسی در نمایش بریده شده‌اند؛ همه پل‌ها و راهنمای اصلی حفظ شده‌اند.

برای خواندن شکل ۳، توجه به جهت معیار ضروری است. مقدار CI برای پیکربندی‌های A، B و C به ترتیب 0.774، 0.764 و 0.768 است؛ مقدار MSE همان پیکربندی‌ها به ترتیب 2.343، 1.983 و 1.907 گزارش شده است. پس پیکربندی دارای کمترین MSE الزاماً بیشترین CI را ندارد. همچنین از این شکل نمی‌توان برتری یک پیکربندی در تمام معیارها و نسبت به تمام روش‌ها را نتیجه گرفت. این خوانش، تفسیر مقایسه درون مقاله است، نه رتبه‌بندی مشترک DCGAN-DTA و Co-VAE.

۹-۲ معماری و هدف یادگیری Co-VAE

۱-۹-۲ دو مسیر واریاسیونی و یک پیش‌بینی مشترک

Co-VAE دو خودرمزگذار واریاسیونی برای دارو و هدف را با یک بخش رگرسیونی مشترک پیوند می‌دهد. شکل ۴ مقاله، صفحه ۶ PDF و صفحه چاپی ۸۸۶۶، پنج جزء را نشان می‌دهد: رمزگذار دارو، رمزگذار هدف، رمزگشای دارو، رمزگشای هدف و بلوک رگرسیون [۱۱]. شکل ۲-۸ یک نمودار آموزشی مستقل از همین اجزاست؛ تصویر اصلی IEEE در متن پایان‌نامه باز نشر نشده است.



شکل ۲-۸: طرح آموزشی مستقل از پنج جزء Co-VAE، مبتنی بر شکل ۴ و شرح معماری، صفحه ۶ PDF، صفحه چاپی ۸۸۶۶ [۱۱]. دو مسیر بازسازی از مسیر رگرسیون متمایزند؛ چیدمان و رسم نمودار متعلق به این پایان‌نامه است.

در هر رمزگذار، ورودی رمزگذاری شده و تعبیه شده از سه لایه کانولوشن دروازه‌دار، تجمیع بیشینه و لایه کاملاً متصل عبور می‌کند تا پارامترهای توزیع نهان به دست آیند. نمونه نهان با بازپارامتردهی ساخته می‌شود. رمزگشا از لایه کاملاً متصل و سه لایه کانولوشن برای بازسازی استفاده می‌کند و خروجی را به اندازه ورودی می‌رساند. در بلوک رگرسیون، برای هر شاخه دو لایه کاملاً متصل به کار می‌رود و سپس اطلاعات دو طرف با لایه مشترک به مقدار اسکالر اتصال تبدیل می‌شود [۱۱].

این معماری به بازنمایی دو نقش می‌دهد: حفظ اطلاعات لازم برای بازسازی هر موجودیت و فراهم کردن اطلاعات مناسب برای پیش‌بینی رابطه زوج. اینکه این نقش‌ها در هر داده چگونه با یکدیگر سازگار می‌شوند، موضوع تجربی است. نهان یک شاخه به‌تنهایی همان خروجی DTA نیست؛ خروجی از رابطه دو نهان در بخش مشترک حاصل می‌شود.

۲-۹-۲ کران مشترک و تابع هدف

معادله ۵ مقاله، صفحه ۴ PDF و صفحه چاپی ۸۸۶۴، کران پایین لگاریتم احتمال مشترک دارو، هدف و برچسب را ارائه می‌کند [۱۱]. برای خوانایی، همان رابطه در دو سطر مفهومی جدا نمایش داده می‌شود:

$$\log p_{\theta}(\mathbf{x}_d^i, \mathbf{x}_t^i, y^i) \geq \mathcal{L}(\theta, \phi; \mathbf{x}_d^i, \mathbf{x}_t^i, y^i), \quad (۶-۲)$$

$$\mathcal{L} = \mathcal{L}_{\text{DrugVAE}} + \mathcal{L}_{\text{TargetVAE}} + \mathcal{L}_{\text{CoREG}}.$$

اجزای همین معادله عبارت‌اند از

$$\begin{aligned} \mathcal{L}_{\text{DrugVAE}} &= \mathbb{E}_{q_{\phi_d}(\mathbf{z}_d | \mathbf{x}_d^i)} [\log p_{\theta_d}(\mathbf{x}_d^i | \mathbf{z}_d)] \\ &\quad - D_{\text{KL}}(q_{\phi_d}(\mathbf{z}_d | \mathbf{x}_d^i) \| p_{\theta_d}(\mathbf{z}_d)), \\ \mathcal{L}_{\text{TargetVAE}} &= \mathbb{E}_{q_{\phi_t}(\mathbf{z}_t | \mathbf{x}_t^i)} [\log p_{\theta_t}(\mathbf{x}_t^i | \mathbf{z}_t)] \\ &\quad - D_{\text{KL}}(q_{\phi_t}(\mathbf{z}_t | \mathbf{x}_t^i) \| p_{\theta_t}(\mathbf{z}_t)), \end{aligned} \quad (۷-۲)$$


$$\mathcal{L}_{\text{CoREG}} = \mathbb{E}_{q_{\phi}(\mathbf{z}_d, \mathbf{z}_t | \mathbf{x}_d^i, \mathbf{x}_t^i)} [\log p_{\theta_y}(y^i | \mathbf{z}_d, \mathbf{z}_t)].$$

$\mathbf{x}_d^i$ و $\mathbf{x}_t^i$ ورودی‌های زوج i ، y^i برچسب آن و $\mathbf{z}_d$ و $\mathbf{z}_t$ متغیرهای نهان دارو و هدف‌اند. q_{ϕ_d} و q_{ϕ_t} توزیع‌های استنتاج، p_{θ_d} و p_{θ_t} توزیع‌های مولد شاخه‌ها و p_{θ_y} توزیع شرطی برچسب هستند. زیرنویس y در θ_y به پارامترهای مؤلفه پیش‌بینی مربوط است. q_{ϕ} در جمله سوم توزیع مشترک استنتاج دو نهان را بیان می‌کند. امیدهای ریاضی و واگرایی‌ها نسبت به توزیع‌های نوشته‌شده محاسبه می‌شوند.

دو مؤلفه اول، درست‌نمایی بازسازی و سازگاری با پیشین را برای هر شاخه نگه می‌دارند؛ جمله سوم، ارتباط نهان‌ها با برچسب را وارد می‌کند. هدف در این قرارداد پیشینه کردن کران مشترک است. این رابطه از مقاله Co-VAE استخراج شده و تابع هدف روش ترکیبی پایان‌نامه نیست. شکل ۲-۹ اجزای آن را در کنار وابستگی‌های احتمالاتی توضیح می‌دهد.

Co-VAE: latent dependencies and joint objective

Independent explanation — Figure 2 and Eq. 5; the original IEEE image is not reproduced



شکل ۲-۹: طرح آموزشی مستقل از وابستگی‌های مولد و سه مؤلفه کران Co-VAE؛ بر اساس معادله ۵، صفحه ۴ PDF، صفحه چاپی ۸۸۶۴ [۱۱]. هر نهان در بازسازی ورودی خود و هر دو نهان در پیش‌بینی برچسب مشارکت می‌کنند.

۲-۹-۳ آزمون موجودیت جدید و حدود نتایج


مقاله Co-VAE را روی Davis و KIBA در دو سناریوی داروی جدید و هدف جدید ارزیابی می‌کند. در سناریوی داروی جدید، داروها به شش بخش تقسیم می‌شوند و یک بخش برای آزمون کنار گذاشته می‌شود؛ در سناریوی هدف جدید همین کار برای اهداف انجام می‌شود. تقسیم تصادفی برای هر سناریو ده بار تکرار و میانگین و انحراف معیار گزارش می‌شوند. شکل ۶ مقاله، صفحه ۷ PDF و صفحه چاپی ۸۸۶۷، این تفکیک را در ماتریس اتصال نشان می‌دهد [۱۱].

جدول ۲-۳ بخش مرتبط جدول ۲ مقاله، صفحه ۹ PDF و صفحه چاپی ۸۸۶۹، را خلاصه می‌کند. اعداد، میانگین‌های منتشرشده Co-VAE هستند. انحراف معیارهای MSE CI و MAE در جدول اصلی وجود دارند و برای مقایسه آماری باید به همان گزارش و پروتکل مراجعه کرد؛ این جدول خلاصه برای نمایش دامنه سناریوهاست و آزمون معناداری ارائه نمی‌کند.

از جدول اصلی نمی‌توان برتری Co-VAE نسبت به همه روش‌ها در تمام معیارها را استنتاج کرد. همچنین این آزمایش موجودیت جدید با نمودارهای DCGAN-DTA در مجموعه‌های دیگر، مقایسه عددی مشترک ایجاد نمی‌کند. معیارهای اعتبار و یکتایی SMILES در بخش تولید داروی مقاله نیز به کیفیت تولید مربوطاند و جای

Co-VAE: entity-wise train, validation and test splits

Schematic illustration only — not an affinity matrix or a result of the thesis



شکل ۲-۱۰: طرح آموزشی مستقل برای تفکیک داروی جدید و هدف جدید، با الهام از مفهوم شکل ۶ مقاله، صفحه ۷، PDF، صفحه چاپی ۸۸۶۷ [۱۱]. اندازه شبکه و رنگ‌ها قراردادی‌اند: رنگ نقش آموزش، اعتبارسنجی یا آزمون را نشان می‌دهد؛ این تصویر ماتریس واقعی affinity یا نتیجه آزمایش نیست.

جدول ۲-۳: میانگین‌های منتشرشده Co-VAE در جدول ۲ مقاله [۱۱]؛ این جدول منتخب گزارش منبع است و حاصل آزمایش پایان‌نامه نیست.

داده	سناریو	CI	MSE	MAE	r_m^2
Davis	داروی جدید	0.712	0.724	0.550	0.107
Davis	هدف جدید	0.816	0.419	0.380	0.477
KIBA	داروی جدید	0.742	0.416	0.401	0.358
KIBA	هدف جدید	0.741	0.421	0.396	0.356

معیارهای پیش‌بینی اتصال را نمی‌گیرند.

۲-۱۰ معیارهای ارزیابی پیش‌بینی اتصال

۲-۱۰-۱ کمیت ارزیابی و قرارداد نمادها

معیارها به پرسش‌های متفاوت پاسخ می‌دهند: فاصله عددی پیش‌بینی از مشاهده، توافق ترتیب زوج‌ها و کیفیت شناسایی زوج‌های بالاتر از یک آستانه. استفاده از چند معیار زمانی مفید است که این نقش‌ها روشن باشد. در این بخش، Y_i مقدار مشاهده‌شده، P_i پیش‌بینی آن و n تعداد نمونه‌های آزمون است. تمام نمونه‌ها باید در یک مقیاس برجسب مقایسه شوند.

۲-۱۰-۲ خطای مربعی، خطای مطلق و RMSE

MSE به خطاهای بزرگ وزن بیشتری می‌دهد، زیرا سهم هر نمونه به مربع فاصله وابسته است. رابطه زیر معادله ۳ مقاله DCGAN-DTA، صفحه ۶ PDF و صفحه چاپی ۶، است [۹]:

$$MSE = \frac{1}{n} \sum_{i=1}^n (P_i - Y_i)^2. \quad (۸-۲)$$

MAE میانگین اندازه مطلق فاصله است و در معادله ۱ مقاله Chai و Draxler، صفحه ۲ PDF و صفحه چاپی ۱۲۴۸، تعریف شده است [۴]:

$$MAE = \frac{1}{n} \sum_{i=1}^n |P_i - Y_i|. \quad (۹-۲)$$

در هر دو معیار، مقدار کمتر مطلوب است و صفر به پیش‌بینی دقیق تمام نمونه‌های آزمون اشاره دارد. MAE در واحد برجسب و MSE در مربع آن واحد قرار دارد. از این رو، مقدار MSE روی pK_d را نباید با MSE روی ثابت غلظتی یا امتیاز KIBA بدون توجه به مقیاس مقایسه کرد. شکل ۲-۱۱ تفاوت سهم خطا را نشان می‌دهد.


RMSE جذر MSE است و مانند MAE واحدی مشابه برجسب دارد. معادله ۲ مقاله Chai و Draxler در همان صفحه، این معیار را تعریف می‌کند [۴]. مقایسه MAE و RMSE می‌تواند حساسیت ارزیابی به خطاهای بزرگ را روشن کند؛ هیچ‌یک به تنهایی ترتیب پیش‌بینی‌ها را تضمین نمی‌کند.

در صفحه ۷ PDF Co-VAE، صفحه چاپی ۸۸۶۷، روابط چاپ‌شده MSE و MAE به صورت مجموع و بدون عامل $1/n$ آمده‌اند. در این فصل، تعریف میانگین در روابط (۲-۸) و (۲-۹) به صراحت استفاده شده است. تفاوت فرمول چاپ‌شده نباید پنهان شود یا از روی آن درباره شیوه محاسبه تمام اعداد منبع نتیجه‌گیری قطعی شود؛ مقایسه اجرایی نیازمند کنترل قرارداد محاسبه است.

MSE and MAE: per-sample error contributions

Analytic curves in arbitrary error units — not article data or thesis results

Per-sample contribution



شکل ۲-۱۱: مقایسه آموزشی سهم e^2 و $|e|$ برای خطای $e = P - Y$ ؛ رسم تحلیلی این پایان نامه بر پایه تعریف MSE و MAE [۹، ۴]. محور خطا قراردادی است؛ منحنی ها داده تجربی نیستند.

۲-۱۰-۳ شاخص توافق رتبه‌ای

CI می‌سنجد که مدل برای زوج‌هایی با برچسب‌های متفاوت، ترتیب را تا چه اندازه حفظ می‌کند. معادله‌های ۱ و ۲ مقاله DCGAN-DTA، صفحه ۶، با نمادگذاری هماهنگ این فصل به صورت زیرند [۹]:


$$CI = \frac{1}{Z} \sum_{Y_i > Y_j} h(P_i - P_j), \quad h(u) = \begin{cases} 1, & u > 0, \\ 0.5, & u = 0, \\ 0, & u < 0. \end{cases} \quad (2-10)$$

Z تعداد زوج‌های قابل مقایسه با شرط $Y_i > Y_j$ و h امتیاز هر زوج است. پیش‌بینی هم‌جهت یک امتیاز، تساوی پیش‌بینی نیم‌امتیاز و ترتیب معکوس صفر می‌گیرد. زوج‌های دارای برچسب واقعی مساوی در این قرارداد وارد جمع نمی‌شوند. اگر هیچ زوج قابل مقایسه‌ای وجود نداشته باشد، این نسبت تعریف نمی‌شود.

CI بین صفر و یک است و مقدار بیشتر مطلوب است. این معیار به فاصله عددی پیش‌بینی از برچسب مستقیماً حساس نیست؛ حفظ ترتیب می‌تواند با خطای عددی همراه شود. همچنین میانگین CI دسته‌ها لزوماً CI محاسبه‌شده روی تمام پیش‌بینی‌های آزمون نیست، زیرا زوج‌های میان دسته‌ها در محاسبه اول حضور ندارند. قرارداد کلی یا دسته‌ای باید در گزارش روشن باشد.

Concordance index: scoring a comparable pair

Observed ordering: $Y_i > Y_j$ — independent illustration of DCGAN-DTA Eqs. 1–2



CI averages these scores over comparable pairs; no experimental values are plotted.

شکل ۲-۱۲: سه حالت امتیازدهی یک زوج در CI؛ نمودار آموزشی مستقل مبتنی بر معادله‌های ۱ و ۲، صفحه ۶ مقاله DCGAN-DTA [۹]. ترتیب واقعی در هر پنل ثابت است و تنها ترتیب پیش‌بینی تغییر می‌کند.

۲-۱۰-۴ معیار r_m^2

معیار r_m^2 برای بررسی عملکرد پیش‌بینی در مدل‌های رابطه کمی ساختار-فعالیت به کار رفته است. صورت چاپ‌شده آن در معادله ۴ مقاله DCGAN-DTA، صفحه ۶، و نیز بخش معیارهای Co-VAE، صفحه چاپی ۸۸۶۷، چنین است [۹، ۱۱]:


$$r_m^2 = r^2 \left(1 - \sqrt{r^2 - r^2} \right). \quad (2-11)$$

در توضیح دو منبع، r^2 و r_m^2 به کمیت‌های همبستگی مربعی با و بدون عرض از مبدأ مربوط‌اند. شکل ۲-۱۳ نقش این دو کمیت در فرمول را نشان می‌دهد. این شاخص همان ضریب تعیین معمولی نیست و مقدار بیشتر در کاربرد گزارش شده مطلوب است.

در نسخه‌های بررسی‌شده، عبارت زیر رادیکال بدون قدرمطلق چاپ شده است. بنابراین، در نقل آن قدرمطلق افزوده نشده است. تعریف عملی r_m^2 ، جهت برازش و برخورد با حالت‌های تباهیده باید از پیاده‌سازی معیار کنترل شود؛ افزودن تغییر به فرمول باید به‌عنوان قرارداد جدید مستند شود. آستانه پذیرش نقل‌شده در یک مقاله نیز تضمین اعتبار زیستی یک مدل در هر داده نیست.

RM2: two source quantities and the reported expression

Independent explanation of DCGAN-DTA Eq. 4 — not a fitted example

Source notation is retained; RM2 is not ordinary R².

شکل ۲-۱۳: طرح آموزشی مستقل از اجزای r_m^2 ، بر اساس معادله ۴، صفحه ۶ مقاله DCGAN-DTA [۹]. صورت چاپ شده بدون قدر مطلق حفظ شده است؛ این نمودار محاسبه برازش روی داده نمونه نیست.

۲-۱۰-۵ AUPR و معیارهای طبقه‌بندی مکمل

AUPR مساحت زیر منحنی دقت-بازخوانی است. برای استفاده از آن در DTA ابتدا یک تعریف دودویی از زوج مثبت لازم است؛ مثلاً بالاتر بودن برجسب از آستانه مشخص. سپس امتیاز پیوسته مدل برای رتبه‌بندی استفاده می‌شود. این کار یک ارزیابی مکمل طبقه‌بندی می‌سازد و مسئله اصلی رگرسیونی را حذف نمی‌کند.

اگر TP تعداد مثبت‌های درست، FP تعداد مثبت‌های کاذب و FN تعداد مثبت‌های از دست‌رفته باشند، با نمادگذاری این متن و بر اساس جدول تعاریف Saito و Rehmsmeier داریم [۱۹]:

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}. \quad (2-12)$$

دقت، سهم مثبت‌های درست در میان پیش‌بینی‌های مثبت است؛ بازخوانی، سهم مثبت‌های بازبایی شده از کل مثبت‌های واقعی. تغییر آستانه امتیاز پیش‌بینی، منحنی PR را می‌سازد. AUPR بیشتر مطلوب است؛ روش محاسبه مساحت، تعریف کلاس مثبت و نسبت مثبت‌ها باید گزارش شوند. مقاله یادشده اهمیت PR را برای داده‌های نامتوازن توضیح می‌دهد.

ROC-AUC معیار دیگری برای ارزیابی رتبه‌بندی مثبت‌ها و منفی‌هاست و با AUPR یکسان نیست. در مقاله DCGAN-DTA، آستانه ۷ برای دودویی کردن affinity ذکر شده است؛ مقاله Co-VAE، AUC را برای KIBA و آستانه‌های 10.5 تا 12.5 با گام 0.1 بررسی می‌کند. این دو قرارداد، ارزیابی یکسانی تعریف نمی‌کنند. پیش از انتقال هر آستانه باید معنای برجسب و نسخه داده کنترل شود.

۲-۱۰-۶ معیارهای موجود در اجرای پروژه

در خروجی‌های اجرای فعلی، DCGAN-DTA شامل r_m^2 MSE، CI، AUPR و MAE به صورت تشخیصی گزارش شده است. برای Co-VAE، r_m^2 MSE، CI، ROC-AUC و وجود دارد و MAE در کنترل بیرونی محاسبه شده است. این فهرست از خروجی‌های موجود استخراج شده؛ پروتکل مشترک نهایی پایان‌نامه محسوب نمی‌شود. RMSE در این فصل برای شناخت خانواده معیارهای خطا معرفی شد و جزو خروجی‌های یادشده نیست.

برای ارزیابی روش پیشنهادی، تعریف ثابت معیارها و شرایط محاسبه ضروری است. محور اصلی می‌تواند خطای عددی و توافق رتبه‌ای باشد؛ معیار طبقه‌بندی تنها با آستانه و کاربرد مشخص معنا دارد. انتخاب نهایی مجموعه معیارها و تعریف طبقه‌بندی باید در فصل روش ثبت شود [نیازمند تعیین روش].

۱۱-۲ مقایسه مفهومی و مبنای ترکیب بازنمایی‌ها

۱-۱۱-۲ تفاوت هدف‌ها و محل ترکیب

جدول ۴-۲ تفاوت دو مدل منتخب را در سطح سازوکار خلاصه می‌کند. این مقایسه، رتبه‌بندی عددی عملکرد نیست؛ هدف آن روشن کردن تصمیم‌هایی است که برای طراحی روش ترکیبی لازم‌اند.

جدول ۴-۲: مقایسه مفهومی دو مدل منتخب؛ جمع‌بندی از مقاله‌های اصلی [۹، ۱۱].

وجه مقایسه	DCGAN-DTA	Co-VAE
هدف بازنمایی	پیش‌آموزش تخصصی و استخراج ویژگی برای پیش‌بینی	بازسازی واریاسیونی همراه با مؤلفه برچسب
ساختار شاخه‌ها	ویژگی‌های توالی با شبکه‌های پیش‌آمورخته و CNN	دو رمزگذار و دو رمزگشا با نهان‌های احتمالاتی
ادغام در مدل اصلی	جمع بردارهای سازگار و بلوک کاملاً متصل	شاخه‌های پردازش نهان و بخش رگرسیون مشترک
داده‌های ارزیابی مقاله	PDBbind و BindingDB	KIBA و Davis
شاهد قابل انتقال	شرح معماری و نتایج با پروتکل همان مقاله	کران مشترک و آزمون‌های موجودیت جدید همان مقاله

برداشت تحلیلی این پایان‌نامه آن است که دو هدف یادگیری می‌توانند اطلاعات متفاوتی را در بازنمایی نگه دارند. این برداشت انگیزه ترکیب است؛ اثبات مکمل بودن به تحلیل ویژگی‌ها یا آزمایش نقش اجزا نیاز دارد. همچنین جمع دو ویژگی یا الحاق آن‌ها بدون کنترل مقیاس، امکان تفسیر وزن را کاهش می‌دهد. انتخاب لایه، تعیین تبدیل ابعاد و تعریف رگرسور، اجزای لازم یک روش قابل ارزیابی‌اند.

۲-۱۱-۲ معنای محدب بودن در مسئله وزن

بهینه‌سازی محدب زمانی معنا دارد که هم مجموعه انتخاب‌های مجاز محدب باشد و هم تابع هدف روی آن مجموعه محدب باشد. با نمادگذاری عمومی، برای تابع f ، دو نقطه شدنی u و v و هر $\lambda \in [0, 1]$ ، تعریف محدب بودن عبارت است از [۲]:

$$f(\lambda u + (1 - \lambda)v) \leq \lambda f(u) + (1 - \lambda)f(v). \quad (۱۳-۲)$$

ترکیب $\lambda u + (1 - \lambda)v$ باید در دامنه شدنی قرار بگیرد. این رابطه تعریف ریاضی یک ویژگی است؛ تابع هدف پیشنهادی پایان‌نامه نیست.

برای وزن ترکیب، باید مشخص شود چه چیزهایی هنگام انتخاب وزن ثابت‌اند. اگر بازنمایی‌ها ثابت باشند ولی یک شبکه غیرخطی هم‌زمان آموزش داده شود، محدب بودن صرفاً از خطی بودن ترکیب اولیه حاصل نمی‌شود. همچنین مربع خطا نسبت به یک خروجی آفین با مربع خطا نسبت به خروجی یک شبکه آموزش‌پذیر یک وضعیت ریاضی ندارد. تحلیل باید تابع نهایی وابسته به وزن، قیود و نقش سایر پارامترها را بررسی کند. در مسیر پیشنهادی، ترکیب به بازنمایی‌ها مربوط است؛ میانگین‌گیری از خروجی دو مدل می‌تواند یک خط پایه جداگانه برای مقایسه باشد. تعریف وزن، هزینه و قیود در فصل روش تکمیل خواهد شد. در این مرحله، فرم ناشناخته آن به عنوان یک معادله اثبات‌شده ارائه نمی‌شود.

۲-۱۲ جمع‌بندی پیشینه و پیوند با پژوهش

این فصل نشان داد که DTA از معنای برجسته شروع می‌شود. ثابت اتصال، ثابت مهار، غلظت مهار و امتیاز یکپارچه باید در مقیاس و شرایط خود خوانده شوند. انتخاب نمایش رشته‌ای یا گرافی نیز تعیین می‌کند که چه ساختاری به مدل ارائه شود. روش‌های شباهت‌محور، مهندسی ویژگی و شبکه‌های عمیق مسیرهای متفاوت استفاده از این اطلاعات‌اند.

در مدل‌های مولد، هدف یادگیری فراتر از خطای مستقیم رگرسیون است. GAN از رقابت مولد و تمایزگر و VAE از درست‌نمایی بازسازی و تقریب واریاسیونی استفاده می‌کند. DCGAN-DTA این مسیر تخصصی را در استخراج ویژگی توالی‌ها به کار می‌گیرد؛ Co-VAE بازسازی دو طرف را با یک مؤلفه مشترک پیش‌بینی پیوند می‌دهد. شرح معماری و معادلات، امکان مقایسه منطقی این دو مسیر را فراهم می‌کند، اما نتایج مقاله‌ها به دلیل تفاوت داده و شرایط آزمون یک رتبه‌بندی مشترک نمی‌سازند.

شکاف مورد بررسی در این پایان‌نامه، تعریف و ارزیابی ترکیبی مشخص از این بازنمایی‌هاست. سهم پیشنهادی به انتخاب ویژگی، سازگار کردن دو مسیر و تعیین وزن با یک مسئله بهینه‌سازی وابسته است. بررسی تازگی این ترکیب به مرور متمرکز روش‌های ادغام بازنمایی مولد در DTA نیاز دارد [نیازمند منبع]؛ اثبات ریاضی و نتیجه عملکرد نیز به تعریف روش و آزمایش مشترک وابسته‌اند [نیازمند نتیجه آزمایش]. فصل روش باید این تصمیم‌ها را به پروتکلی بازتولیدپذیر تبدیل کند.

- [1] BENTO, A. P., GAULTON, A., HERSEY, A., BELLIS, L. J., CHAMBERS, J., DAVIES, M., KRÜGER, F. A., LIGHT, Y., MAK, L., MCGLINCHY, S., NOWOTKA, M., PAPADATOS, G., SANTOS, R., AND OVERINGTON, J. P. The ChEMBL bioactivity database: an update. *Nucleic Acids Research* 42, D1 (2014), D1083–D1090.
- [2] BOYD, S., AND VANDENBERGHE, L. *Convex Optimization*. Cambridge University Press, 2004.
- [3] CAMPBELL, R. M., DYMSHITZ, J., EASTWOOD, B. J., EMKEY, R., GREENEN, D. P., HEERDING, J. M., JOHNSON, D., LARGE, T. H., LITTLEJOHN, T., MONTROSE, C., NUTTER, S. E., SAWYER, B. D., SIGMUND, S. K., SMITH, M., WEIDNER, J. R., AND ZINK, R. W. Data standardization for results management. in *Assay Guidance Manual*. Eli Lilly & Company and the National Center for Advancing Translational Sciences, Bethesda (MD), 2012. NCBI Bookshelf ID: NBK91993; updated October 20, 2017.
- [4] CHAI, T., AND DRAXLER, R. R. Root mean square error (RMSE) or mean absolute error (MAE)? – arguments against avoiding RMSE in the literature. *Geoscientific Model Development* 7, 3 (2014), 1247–1250.
- [5] DAVIS, M. I., HUNT, J. P., HERRGARD, S., CICERI, P., WODICKA, L. M., PALLARES, G., HOCKER, M., TREIBER, D. K., AND ZARRINKAR, P. P. Comprehensive analysis of kinase inhibitor selectivity. *Nature Biotechnology* 29, 11 (2011), 1046–1051.
- [6] GOODFELLOW, I. J., POUGET-ABADIE, J., MIRZA, M., XU, B., WARDE-FARLEY, D., OZAIR, S., COURVILLE, A., AND BENGIO, Y. Generative adversarial nets. in *Advances in Neural Information Processing Systems* (2014), volume 27.
- [7] HE, T., HEIDEMEYER, M., BAN, F., CHERKASOV, A., AND ESTER, M. SimBoost: a read-across approach for predicting drug–target binding affinities using gradient boosting machines. *Journal of Cheminformatics* 9 (2017), 24.
- [8] HULME, E. C., AND TREVETHICK, M. A. Ligand binding assays at equilibrium: validation and interpretation. *British Journal of Pharmacology* 161, 6 (2010), 1219–1237.
- [9] KALEMATI, M., EMANI, M. Z., AND KOOHI, S. DCGAN-DTA: Predicting drug-target binding affinity with deep convolutional generative adversarial networks. *BMC Genomics* 25 (2024), 411.
- [10] KINGMA, D. P., AND WELLING, M. Auto-encoding variational bayes. in *International Conference on Learning Representations (ICLR)* (2014).
- [11] LI, T., ZHAO, X.-M., AND LI, L. Co-VAE: Drug-target binding affinity prediction by co-regularized variational autoencoders. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 44, 12 (2022), 8861–8873.

- [12] LIU, T., LIN, Y., WEN, X., JORISSEN, R. N., AND GILSON, M. K. BindingDB: a web-accessible database of experimentally determined protein-ligand binding affinities. *Nucleic Acids Research* 35, suppl. 1 (2007), D198–D201.
- [13] LIU, Y., WU, M., MIAO, C., ZHAO, P., AND LI, X.-L. Neighborhood regularized logistic matrix factorization for drug-target interaction prediction. *PLOS Computational Biology* 12, 2 (2016), e1004760.
- [14] NGUYEN, T., LE, H., QUINN, T. P., NGUYEN, T., LE, T. D., AND VENKATESH, S. GraphDTA: predicting drug-target binding affinity with graph neural networks. *Bioinformatics* 37, 8 (2021), 1140–1147.
- [15] ÖZTÜRK, H., ÖZGÜR, A., AND OZKIRIMLI, E. DeepDTA: deep drug-target binding affinity prediction. *Bioinformatics* 34, 17 (2018), i821–i829.
- [16] ÖZTÜRK, H., OZKIRIMLI, E., AND ÖZGÜR, A. WideDTA: prediction of drug-target binding affinity. arXiv preprint arXiv:1902.04166, 2019.
- [17] PAHIKKALA, T., AIROLA, A., PIETILÄ, S., SHAKYAWAR, S., SZWAJDA, A., TANG, J., AND AITTOKALLIO, T. Toward more realistic drug-target interaction predictions. *Briefings in Bioinformatics* 16, 2 (2015), 325–337.
- [18] RADFORD, A., METZ, L., AND CHINTALA, S. Unsupervised representation learning with deep convolutional generative adversarial networks. in *International Conference on Learning Representations (ICLR)* (2016).
- [19] SAITO, T., AND REHMSMEIER, M. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE* 10, 3 (2015), e0118432.
- [20] TANG, J., SZWAJDA, A., SHAKYAWAR, S., XU, T., HINTSANEN, P., WENNERBERG, K., AND AITTOKALLIO, T. Making sense of large-scale kinase inhibitor bioactivity data sets: A comparative and integrative analysis. *Journal of Chemical Information and Modeling* 54, 3 (2014), 735–743.
- [21] WANG, R., FANG, X., LU, Y., AND WANG, S. The PDBbind database: collection of binding affinities for protein-ligand complexes with known three-dimensional structures. *Journal of Medicinal Chemistry* 47, 12 (2004), 2977–2980.
- [22] WEININGER, D. SMILES, a chemical language and information system. 1. introduction to methodology and encoding rules. *Journal of Chemical Information and Computer Sciences* 28, 1 (1988), 31–36.
- [23] ZENG, X., LI, S.-J., LV, S.-Q., WEN, M.-L., AND LI, Y. A comprehensive review of the recent advances on predicting drug-target affinity based on deep learning. *Frontiers in Pharmacology* 15 (2024), 1375522.

Abstract

Drug–Target Binding Affinity (DTA) prediction is an important problem in computational drug discovery, aiming to quantitatively estimate the binding strength between a drug compound and a target protein. The high cost and time requirements of experimental approaches, together with the large space of potential compounds and biological targets, have motivated the use of machine learning and deep learning methods as complementary approaches to this problem. This thesis investigates deep learning methods for drug–target binding affinity prediction, with a particular focus on generative models and representation learning. In this context, the representation of drugs and proteins, model architectures, training procedures, and evaluation methods are studied. Two generative approaches based on Generative Adversarial Networks and Variational Autoencoders are analyzed and compared through the DCGAN-DTA and Co-VAE models, respectively. A main objective of this study is to systematically examine the reproducibility and fair comparability of these approaches. To this end, data preprocessing, dataset splitting, model architectures, training parameters, and evaluation procedures are carefully investigated and documented. The models are also evaluated and compared on commonly used DTA benchmark datasets, including Davis and KIBA. Finally, the strengths and limitations of the investigated approaches are analyzed in terms of representation quality, predictive performance, training complexity, and reproducibility, providing a basis for the development of more effective methods for drug–target binding affinity prediction.

Keywords : Drug–Target Binding Affinity Prediction, Deep Learning, Generative Learning, Generative Adversarial Network, Variational Autoencoder



University of Tehran
College of Engineering
Faculty of Engineering Science



A Comparative Study of Adversarial Autoencoders and Variation-al Autoencoders for Drug-Drug and Drug-Protein Interaction Pre-diction

A thesis submitted to the Graduate Studies Office

In partial fulfillment of the requirements for

The degree of master in

Algorithms and Computation

By:

Mohsen Kashefikia

Supervisor:

Dr. Sayeh Mirzaei

September 2026